

Submersión Espectral de Lenguajes Perdidos

Pseudoinversa de Moore–Penrose, SVD, Procrustes, Transporte Óptimo y Geometría Latente para el Desciframiento Probabilístico de Sistemas Simbólicos de Bajo Recurso

Autor: *[Nombre del autor]*

Afiliación: *[Institución / Laboratorio]*

Contacto: *[correo]*

27 de abril de 2026

Resumen

Este artículo propone un marco matemático para estudiar sistemas simbólicos perdidos o no descifrados mediante una combinación de análisis espectral, pseudoinversa de Moore–Penrose, alineamiento Procrustes, transporte óptimo relacional y modelos probabilísticos de lenguaje. La tesis central es que un sistema de signos funcional, si codifica regularidades de un mundo cultural o físico compartido, induce una geometría estadística interna parcialmente observable. Esta geometría puede extraerse desde matrices de co-ocurrencia, PMI/PPMI, grafos de transición y tensores de contexto; puede comprimirse mediante descomposición en valores singulares; y puede alinearse, bajo hipótesis explícitas, con espacios latentes de lenguas conocidas. El resultado no es un “traductor mágico” ni un desciframiento concluyente, sino una máquina de generación, ranking y falsación de hipótesis de equivalencia semántica. Formalizamos el problema como inferencia bajo simetrías, demostramos imposibilidades sin anclajes o restricciones externas, caracterizamos soluciones lineales de mínimos cuadrados mediante Moore–Penrose, derivamos el alineamiento ortogonal mediante SVD, y planteamos una extensión geométrica como submersión entre variedades semánticas de distinta dimensión. El caso Rongorongo se usa como motivación de bajo recurso extremo, no como afirmación de desciframiento. La contribución principal es una arquitectura rigurosa, verificable y falsable para pasar desde frecuencia de símbolos al estilo de Al-Kindi hacia una teoría moderna de desciframiento espectral probabilístico.

Palabras clave: Moore–Penrose, SVD, pseudoinversa, Procrustes, embeddings cross-linguales, traducción no supervisada, Rongorongo, Al-Kindi, geometría diferencial, transporte óptimo, inferencia bayesiana, lenguajes perdidos, análisis espectral.

Índice

1. Introducción	4
2. Motivación histórica y técnica	4
2.1. De Al-Kindi al aprendizaje no supervisado	4
2.2. Rongorongo como motivación de bajo recurso extremo	5

3. Planteamiento formal del problema	5
3.1. Sistema simbólico observado	5
3.2. Matriz de co-ocurrencia	6
3.3. Embedding espectral	6
4. Axiomas epistémicos	7
5. Moore–Penrose y la inversión lineal mínima	7
5.1. La pseudoinversa como solución canónica	7
5.2. Traducción lineal de mínimos cuadrados	8
6. Bajo rango, compresión semántica y Eckart–Young	9
7. Alineamiento Procrustes	9
7.1. Mapa ortogonal	9
8. Teorema de no-desciframiento gratuito	11
8.1. Simetría por permutación	11
9. Diccionario blando y transporte óptimo	12
9.1. Asignación probabilística	12
9.2. Costo geométrico	12
9.3. Costo relacional tipo Gromov–Wasserstein	12
9.4. Regularización entrópica	12
10. Submersión entre variedades semánticas	13
10.1. Lenguajes como variedades estadísticas	13
10.2. Pseudoinversa diferencial	13
11. Regularización, estabilidad y ruido	14
11.1. Tikhonov espectral	14
12. Modelo probabilístico completo	15
12.1. Posterior de traducción de signos	15
12.2. Decodificación secuencial	15
12.3. Principio de auditabilidad	16
13. Algoritmo propuesto	16
14. Diseño experimental	16
14.1. Experimento sintético controlado	16
14.2. Controles negativos	17
14.3. Métricas	17

15. Aplicación exploratoria a sistemas tipo Rongorongo	17
15.1. Advertencia metodológica	17
15.2. Unidades candidatas	18
15.3. Hipótesis candidatas	18
16. Teoría de identificabilidad parcial	19
17. Relación con LLMs e inferencia moderna	19
17.1. LLMs como priors, no como oráculos	19
17.2. RAG para desciframiento	20
18. Arquitectura computacional reproducible	20
18.1. Estructura de repositorio	20
18.2. Componentes	21
19. Discusión	21
19.1. Qué puede demostrar el método	21
19.2. Qué no puede demostrar solo	22
19.3. Belleza matemática del enfoque	22
20. Conclusión	22
A. Apéndice A: derivación matricial del gradiente de mínimos cuadrados	22
B. Apéndice B: índice de anisotropía espectral	23
C. Apéndice C: plantilla de reporte de hipótesis	23
D. Apéndice D: glosario	24

1. Introducción

El desciframiento de un sistema simbólico perdido puede entenderse como un problema inverso: se observa una secuencia finita de signos, pero se desconoce la aplicación que conecta esos signos con unidades semánticas, fonológicas, rituales, calendáricas o administrativas. En su versión más simple, el problema recuerda al criptoanálisis por frecuencia asociado históricamente a Al-Kindi: un texto cifrado conserva regularidades estadísticas del idioma original, y esas regularidades pueden explotarse para proponer correspondencias entre signos y letras [1]. Sin embargo, un sistema como Rongorongo no es un cifrado monoalfabético con una lengua original conocida; es un objeto de bajo recurso, culturalmente situado, con corpus pequeño, sin bilingües confirmados y con múltiples fuentes de incertidumbre [2].

La pregunta de este trabajo es más general:

¿Puede una geometría estadística inducida por un sistema simbólico perdido alinearse con la geometría estadística de una o varias lenguas conocidas, de modo que se generen hipótesis de traducción probabilísticas, auditables y falsables?

La respuesta propuesta es condicional. Sí, si se cumplen restricciones fuertes: existencia de estructura lingüística o semiótica no trivial, corpus suficiente para estimar relaciones de co-ocurrencia, espacios comparables, anclajes débiles, regularización cultural y validación negativa. No, si se espera recuperar significado completo desde frecuencias marginales aisladas.

El marco que desarrollamos combina cinco niveles.

N1. Nivel estadístico: frecuencias, co-ocurrencias, PMI, transición y grafos de contexto.

N2. Nivel espectral: SVD, rango efectivo, pseudoinversa y aproximaciones de bajo rango.

N3. Nivel geométrico: alineamientos ortogonales, Procrustes, variedades latentes, submersión y fibras semánticas.

N4. Nivel probabilístico: diccionarios blandos, posterior semántico, decodificación secuencial y calibración.

N5. Nivel epistémico: límites de identificabilidad, imposibilidad sin anclajes, validación por controles negativos.

La idea central puede expresarse informalmente así:

La traducción perdida no es una clave única; es una geometría latente parcialmente invertible.

2. Motivación histórica y técnica

2.1. De Al-Kindi al aprendizaje no supervisado

El criptoanálisis por frecuencia parte de una observación simple: si una sustitución simbólica conserva el orden textual, entonces las letras más frecuentes del idioma base tienden a seguir siendo frecuentes, aunque aparezcan con otros símbolos. Esta idea no descifra por sí sola lenguajes

completos, pero inaugura una familia de métodos estadísticos: inferir estructura invisible desde distribuciones observables.

En NLP moderno, una idea análoga aparece en embeddings multilingües y traducción no supervisada. Métodos como los de Artetxe, Labaka y Agirre [8, 9], Conneau et al. [10], Lample et al. [11] y Alvarez-Melis y Jaakkola [12] exploran cómo alinear espacios vectoriales monolingües sin grandes corpus paralelos. Muchos de estos métodos dependen de una hipótesis geométrica: lenguas distintas que describen mundos comparables inducen espacios semánticos con estructura relacional parcialmente isomorfa.

Este trabajo traslada esa intuición a un régimen más extremo: sistemas simbólicos pequeños, posiblemente no fonéticos, sin corpus paralelo y con semántica culturalmente densa.

2.2. Rongorongo como motivación de bajo recurso extremo

Rongorongo, escritura asociada a Rapa Nui, permanece sin descifrar. La literatura reciente destaca que los objetos conservados son escasos y que su origen histórico sigue siendo tema de investigación [2]. Por ello, cualquier propuesta de desciframiento debe distinguir cuidadosamente entre:

- (I) **desciframiento fuerte:** lectura semántica o fonética verificable;
- (II) **desciframiento débil:** segmentación, direccionalidad, clases funcionales, repeticiones;
- (III) **desciframiento probabilístico:** ranking de hipótesis con incertidumbre;
- (IV) **análisis estructural:** evidencia de que el sistema posee regularidades no aleatorias.

Nuestro marco apunta primero a los niveles débil, probabilístico y estructural. El nivel fuerte requiere evidencia externa adicional.

3. Planteamiento formal del problema

3.1. Sistema simbólico observado

Sea X un sistema simbólico perdido. Observamos un corpus finito

$$\mathcal{C}_X = (s_1, s_2, \dots, s_T), \quad s_t \in \mathcal{V}_X, \quad (3.1)$$

donde $\mathcal{V}_X = \{x_1, \dots, x_{n_X}\}$ es el vocabulario de signos, glifos, variantes normalizadas o unidades segmentadas.

Sea Y una lengua conocida o un conjunto de lenguas conocidas:

$$\mathcal{C}_Y = (w_1, w_2, \dots, w_M), \quad w_m \in \mathcal{V}_Y, \quad (3.2)$$

donde $\mathcal{V}_Y = \{y_1, \dots, y_{n_Y}\}$.

El objetivo no es encontrar una función determinista

$$\tau : \mathcal{V}_X \rightarrow \mathcal{V}_Y$$

sino una distribución posterior

$$\Pi_{ij} = p(y_j \mid x_i, \mathcal{C}_X, \mathcal{C}_Y, \mathcal{K}), \quad (3.3)$$

donde $\mathcal{K}$ representa conocimiento adicional: iconografía, arqueología, lengua comparada, direccionalidad, soporte material, calendario, genealogía, tradición oral o restricciones antropológicas.

3.2. Matriz de co-ocurrencia

Definimos una función de contexto $K : \mathbb{N} \rightarrow \mathbb{R}_{\geq 0}$, por ejemplo

$$K(d) = \mathbb{1}\{1 \leq d \leq h\} \quad \text{o} \quad K(d) = \exp(-d/\rho).$$

La matriz de co-ocurrencia de X es

$$C_{ij}^{(X)} = \sum_{t=1}^T \mathbb{1}\{s_t = x_i\} \sum_{\substack{u=1 \\ u \neq t}}^T K(|u - t|) \mathbb{1}\{s_u = x_j\}. \quad (3.4)$$

Análogamente se define $C^{(Y)}$. A partir de C se construyen probabilidades suavizadas:

$$\hat{p}_{ij} = \frac{C_{ij} + \epsilon}{\sum_{a,b} C_{ab} + \epsilon n^2}, \quad \hat{p}_{i\cdot} = \sum_j \hat{p}_{ij}, \quad \hat{p}_{\cdot j} = \sum_i \hat{p}_{ij}. \quad (3.5)$$

La matriz PMI es

$$\text{PMI}_{ij} = \log \frac{\hat{p}_{ij}}{\hat{p}_{i\cdot} \hat{p}_{\cdot j}}. \quad (3.6)$$

La versión positiva se define como

$$\text{PPMI}_{ij} = \max\{\text{PMI}_{ij}, 0\}. \quad (3.7)$$

3.3. Embedding espectral

Sea $M_X \in \mathbb{R}^{n_X \times n_X}$ una matriz estructural del sistema perdido: co-ocurrencia normalizada, PMI, PPMI, transición, Laplaciano de grafo o una combinación ponderada. Su descomposición en valores singulares es

$$M_X = U_X \Sigma_X V_X^\top. \quad (3.8)$$

Para dimensión latente k , definimos el embedding espectral

$$E_X(k, \alpha) = U_{X,k} \Sigma_{X,k}^\alpha, \quad \alpha \in [0, 1]. \quad (3.9)$$

Cuando M_X es simétrica positiva semidefinida, esto coincide con una descomposición espectral clásica. Cuando no lo es, U y V capturan roles direccionales distintos: contexto izquierdo/derecho, emisor/receptor, signo actual/siguiente signo.

4. Axiomas epistémicos

Axioma 4.1 (Suficiencia descriptiva). *Un sistema simbólico X es descifrable en sentido débil solo si existe una variable latente R , representando estados relevantes del mundo cultural o físico, tal que*

$$I(X; R) > 0. \quad (4.1)$$

Este axioma no dice que todo signo tenga significado léxico. Dice que el sistema completo debe transportar información no nula sobre algo externo o interno: eventos, nombres, conteos, clases rituales, secuencias, taxonomías o instrucciones.

Teorema 4.2 (Independencia implica imposibilidad inferencial). *Si X y R son independientes, entonces ningún procedimiento basado únicamente en X puede actualizar racionalmente la creencia sobre R . En particular,*

$$p(R | X) = p(R). \quad (4.2)$$

Demostración. Por independencia,

$$p(X, R) = p(X)p(R).$$

Si $p(X) > 0$, la regla de Bayes entrega

$$p(R | X) = \frac{p(X, R)}{p(X)} = \frac{p(X)p(R)}{p(X)} = p(R).$$

Por lo tanto, observar X no modifica la distribución posterior de R . Cualquier algoritmo que afirme recuperar R desde X en este caso está introduciendo información externa no declarada o ruido interpretativo. $\square$

Corolario 4.3 (Frecuencia sin estructura no basta). *Las frecuencias marginales $p(x_i)$ pueden sugerir clases funcionales, pero no identifican semántica por sí solas. Dos sistemas con las mismas frecuencias y estructuras relacionales distintas pueden tener interpretaciones incompatibles.*

5. Moore–Penrose y la inversión lineal mínima

5.1. La pseudoinversa como solución canónica

Sea $A \in \mathbb{R}^{m \times n}$. Si A es rectangular o singular, no existe en general una inversa clásica. La pseudoinversa de Moore–Penrose A^+ es la única matriz que satisface las cuatro ecuaciones:

$$AA^+A = A, \quad (5.1)$$

$$A^+AA^+ = A^+, \quad (5.2)$$

$$(AA^+)^T = AA^+, \quad (5.3)$$

$$(A^+A)^T = A^+A. \quad (5.4)$$

Teorema 5.1 (Pseudoinversa vía SVD). *Sea $A \in \mathbb{R}^{m \times n}$ una matriz de rango r con SVD*

$$A = U\Sigma V^T, \quad (5.5)$$

donde

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots), \quad \sigma_1 \geq \dots \geq \sigma_r > 0.$$

Entonces

$$A^+ = V\Sigma^+U^\top, \quad (5.6)$$

donde Σ^+ reemplaza cada $\sigma_i > 0$ por $1/\sigma_i$ y transpone la forma rectangular.

Demostración. Como U y V son ortogonales, basta verificar las cuatro condiciones de Moore–Penrose para Σ . Para cada valor singular no nulo,

$$\sigma_i \cdot \sigma_i^{-1} \cdot \sigma_i = \sigma_i, \quad \sigma_i^{-1} \cdot \sigma_i \cdot \sigma_i^{-1} = \sigma_i^{-1}.$$

Para valores singulares nulos, los productos permanecen nulos. Además, $\Sigma\Sigma^+$ y $\Sigma^+\Sigma$ son matrices diagonales con entradas 0 o 1, luego son simétricas. Multiplicar por U, V preserva las identidades correspondientes, pues $U^\top U = I$ y $V^\top V = I$. $\square$

5.2. Traducción lineal de mínimos cuadrados

Supongamos que existen representaciones $X \in \mathbb{R}^{n \times d_X}$ y $Y \in \mathbb{R}^{n \times d_Y}$ de n unidades alineadas parcialmente. Buscamos

$$W^* = \arg \min_{W \in \mathbb{R}^{d_X \times d_Y}} \|XW - Y\|_F^2. \quad (5.7)$$

Teorema 5.2 (Solución Moore–Penrose matricial). *El conjunto de minimizadores de (5.7) contiene*

$$W^* = X^+Y. \quad (5.8)$$

Además, X^+Y es el minimizador de norma Frobenius mínima.

Demostración. El problema se separa por columnas. Sea $Y = [y_1, \dots, y_{d_Y}]$ y $W = [w_1, \dots, w_{d_Y}]$. Entonces

$$\|XW - Y\|_F^2 = \sum_{\ell=1}^{d_Y} \|Xw_\ell - y_\ell\|_2^2.$$

Para cada columna, la solución de mínimos cuadrados de norma mínima es $w_\ell = X^+y_\ell$. Apilando soluciones se obtiene $W = X^+Y$. La minimalidad de norma se sigue de la descomposición ortogonal del espacio en $\ker(X) \oplus \ker(X)^\perp$: cualquier solución puede escribirse como $X^+y + z$, con $z \in \ker(X)$; el término z no cambia el residuo pero aumenta la norma salvo que $z = 0$. $\square$

Corolario 5.3 (Decodificador lineal canónico). *Si E_X y E_Y son embeddings espectrales comparables, entonces*

$$W_{\text{MP}} = E_X^+ E_Y \quad (5.9)$$

es el traductor lineal de mínimos cuadrados de norma mínima entre ambos espacios.

Observación 5.4. *Este corolario no afirma que W_{MP} sea una traducción semántica correcta. Afirma que, bajo la elección de representaciones y pares alineados, es el mapa lineal canónico que minimiza error cuadrático. Su valor científico depende de la calidad de los embeddings, anclajes y validaciones.*

6. Bajo rango, compresión semántica y Eckart–Young

Teorema 6.1 (Eckart–Young–Mirsky). *Sea $M \in \mathbb{R}^{m \times n}$ con SVD $M = U\Sigma V^\top$. La mejor aproximación de rango k en norma Frobenius es*

$$M_k = U_k \Sigma_k V_k^\top, \quad (6.1)$$

y satisface

$$M_k = \arg \min_{\text{rank}(B) \leq k} \|M - B\|_F. \quad (6.2)$$

Además,

$$\|M - M_k\|_F^2 = \sum_{i>k} \sigma_i^2. \quad (6.3)$$

Demostración. Por invariancia unitaria de la norma Frobenius,

$$\|M - B\|_F = \|\Sigma - U^\top B V\|_F.$$

Si $\text{rank}(B) \leq k$, entonces $U^\top B V$ también tiene rango a lo más k . La mejor matriz de rango k que aproxima una diagonal con entradas decrecientes conserva las k entradas diagonales más grandes y anula el resto. Esto entrega M_k y el error indicado. $\square$

Corolario 6.2 (Rango efectivo como complejidad simbólica). *Si los valores singulares de M_X decaen rápidamente, entonces la estructura estadística observable del sistema X puede comprimirse en pocas dimensiones. Si decaen lentamente, el sistema requiere una geometría de mayor dimensión o contiene ruido, heterogeneidad o múltiples subsistemas mezclados.*

Definimos el rango efectivo entrópico como

$$r_{\text{eff}}(M) = \exp \left(- \sum_i p_i \log p_i \right), \quad p_i = \frac{\sigma_i}{\sum_j \sigma_j}. \quad (6.4)$$

Este número sirve como indicador de complejidad latente, aunque no debe interpretarse directamente como número de categorías semánticas.

7. Alineamiento Procrustes

7.1. Mapa ortogonal

El mapa lineal general W puede deformar escalas, ángulos y distancias. Para traducción entre embeddings, muchas arquitecturas imponen una transformación ortogonal $Q \in O(d)$:

$$Q^\top Q = I. \quad (7.1)$$

Esto conserva productos internos:

$$\langle x_i Q, x_j Q \rangle = \langle x_i, x_j \rangle.$$

Por ello, si creemos que dos lenguas comparten estructura relacional, una rotación/reflexión es menos arbitraria que una transformación libre.

Teorema 7.1 (Procrustes ortogonal). *Sean $X, Y \in \mathbb{R}^{n \times d}$. El problema*

$$Q^* = \arg \min_{Q^T Q = I} \|XQ - Y\|_F^2 \quad (7.2)$$

se resuelve mediante la SVD

$$X^T Y = U \Sigma V^T, \quad (7.3)$$

con

$$Q^* = UV^T. \quad (7.4)$$

Demostración. Expandimos:

$$\|XQ - Y\|_F^2 = \text{tr}(Q^T X^T X Q) - 2 \text{tr}(Q^T X^T Y) + \text{tr}(Y^T Y).$$

Como $Q^T Q = I$,

$$\text{tr}(Q^T X^T X Q) = \text{tr}(X^T X),$$

que no depende de Q . Minimizar equivale a maximizar

$$\text{tr}(Q^T X^T Y).$$

Sea $X^T Y = U \Sigma V^T$. Entonces

$$\text{tr}(Q^T U \Sigma V^T) = \text{tr}(V^T Q^T U \Sigma).$$

Definiendo $Z = U^T Q V$, se tiene que Z es ortogonal y

$$\text{tr}(V^T Q^T U \Sigma) = \text{tr}(Z^T \Sigma) = \sum_i \sigma_i Z_{ii}.$$

Como $|Z_{ii}| \leq 1$, el máximo es $\sum_i \sigma_i$, alcanzado cuando $Z = I$. Por tanto,

$$U^T Q V = I \quad \Rightarrow \quad Q = UV^T.$$

□

Corolario 7.2 (Alineamiento exacto bajo isometría). *Si existe $Q_0 \in O(d)$ tal que $Y = XQ_0$, y X tiene rango columna completo, entonces el problema Procrustes recupera Q_0 de manera única.*

Demostración. Para $Q = Q_0$, el residuo es cero:

$$\|XQ_0 - Y\|_F = 0.$$

Si otro Q también alcanza residuo cero, entonces $XQ = XQ_0$, luego

$$X(Q - Q_0) = 0.$$

Como X tiene rango columna completo, su núcleo derecho es trivial y $Q = Q_0$. $\square$

8. Teorema de no-desciframiento gratuito

8.1. Simetría por permutación

Un peligro central en desciframiento es la ilusión de identificabilidad. Sin anclajes, todo sistema simbólico es invariante bajo renombramiento de símbolos.

Teorema 8.1 (No-free-decipherment). *Sea $X = (s_1, \dots, s_T)$ un corpus sobre vocabulario $\mathcal{V}_X$. Sea $\pi : \mathcal{V}_X \rightarrow \mathcal{V}_X$ una permutación. Defina $\pi(X) = (\pi(s_1), \dots, \pi(s_T))$. Cualquier estadístico puramente estructural que sea invariante a nombres de símbolos no puede distinguir X de $\pi(X)$. Por tanto, no puede identificar una semántica absoluta sin anclajes externos.*

Demostración. Un estadístico puramente estructural depende de patrones de igualdad, distancias, repeticiones, co-ocurrencias o topología relacional, pero no de los nombres arbitrarios de los símbolos. Si aplicamos π , las relaciones de igualdad se preservan:

$$s_t = s_u \iff \pi(s_t) = \pi(s_u).$$

Las matrices de co-ocurrencia se transforman por conjugación:

$$C_{\pi(X)} = P_\pi C_X P_\pi^\top,$$

donde P_π es una matriz de permutación. Los valores singulares, espectro del Laplaciano, distancias relacionales y rangos se preservan. Luego todo método que observe solo estructura interna obtiene la misma evidencia para X y $\pi(X)$. Cualquier elección entre ambas requiere información externa. $\square$

Corolario 8.2 (Necesidad de anclajes). *Para pasar de estructura a semántica se requiere al menos uno de los siguientes tipos de anclaje:*

- (I) *anclaje bilingüe;*
- (II) *anclaje iconográfico;*
- (III) *anclaje arqueológico;*
- (IV) *anclaje fonético;*
- (V) *anclaje numérico/calendárico;*
- (VI) *anclaje comparativo con lenguas emparentadas;*
- (VII) *anclaje por regularidad pragmática.*

Observación 8.3. *Este resultado es deliberadamente restrictivo. Protege contra una mala práctica común: presentar una traducción única donde matemáticamente solo existe una clase de equivalencia bajo simetrías.*

9. Diccionario blando y transporte óptimo

9.1. Asignación probabilística

En lugar de una función $\tau : \mathcal{V}_X \rightarrow \mathcal{V}_Y$, usamos una matriz estocástica

$$\Pi \in \mathbb{R}_{\geq 0}^{n_X \times n_Y}, \quad \sum_{j=1}^{n_Y} \Pi_{ij} = 1. \quad (9.1)$$

La interpretación es

$$\Pi_{ij} = p(y_j \mid x_i).$$

Una versión con masas marginales $a \in \Delta^{n_X}$, $b \in \Delta^{n_Y}$ exige

$$\Pi \mathbf{1} = a, \quad \Pi^\top \mathbf{1} = b. \quad (9.2)$$

9.2. Costo geométrico

Dado un alineamiento ortogonal Q , definimos

$$D_{ij}(Q) = \|e_i^{(X)} Q - e_j^{(Y)}\|_2^2. \quad (9.3)$$

El transporte óptimo clásico resolvería

$$\min_{\Pi \in U(a,b)} \sum_{i,j} \Pi_{ij} D_{ij}(Q), \quad (9.4)$$

donde

$$U(a,b) = \{\Pi \geq 0 : \Pi \mathbf{1} = a, \Pi^\top \mathbf{1} = b\}.$$

9.3. Costo relacional tipo Gromov–Wasserstein

Si los espacios no son directamente comparables, se comparan relaciones internas:

$$\min_{\Pi \in U(a,b)} \sum_{i,i',j,j'} |\Delta_X(i,i') - \Delta_Y(j,j')|^2 \Pi_{ij} \Pi_{i'j'}. \quad (9.5)$$

Esto es especialmente atractivo en desciframiento porque no exige coordenadas equivalentes: exige que pares de signos relacionados en X correspondan a pares de palabras relacionadas en Y . Esta idea es coherente con el uso de distancias Gromov–Wasserstein para alineamiento de espacios de embeddings [12].

9.4. Regularización entrópica

Para evitar soluciones degeneradas, agregamos entropía:

$$\min_{\Pi \in U(a,b)} \langle \Pi, D \rangle + \varepsilon \sum_{i,j} \Pi_{ij} (\log \Pi_{ij} - 1). \quad (9.6)$$

Cuando ε es grande, Π es difusa; cuando $\varepsilon \rightarrow 0$, se aproxima a un acoplamiento duro.

10. Submersión entre variedades semánticas

10.1. Lenguajes como variedades estadísticas

Modelamos un idioma o sistema simbólico como una nube de puntos en un espacio latente. En el límite ideal, esa nube aproxima una variedad:

$$\mathcal{M}_X \subset \mathbb{R}^{d_X}, \quad \mathcal{M}_Y \subset \mathbb{R}^{d_Y}.$$

Si Y es una lengua rica con gran corpus y X un sistema pequeño, es razonable suponer

$$\dim(\mathcal{M}_Y) \geq \dim(\mathcal{M}_X).$$

Una aplicación

$$F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$$

puede interpretarse como una compresión semántica: muchas palabras o conceptos de Y colapsan a una unidad de X .

Definición 10.1 (Submersión semántica). *Sea $F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$ suave. Decimos que F es una submersión semántica local si para todo $y \in \mathcal{M}_Y$,*

$$\text{rank}(dF_y) = \dim(\mathcal{M}_X).$$

Teorema 10.2 (Fibras de una submersión). *Si $F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$ es una submersión y $x \in \mathcal{M}_X$, entonces la fibra*

$$F^{-1}(x) = \{y \in \mathcal{M}_Y : F(y) = x\}$$

es una subvariedad de $\mathcal{M}_Y$ de dimensión

$$\dim(F^{-1}(x)) = \dim(\mathcal{M}_Y) - \dim(\mathcal{M}_X).$$

Demostración. Este es un caso del teorema del valor regular. Como F es submersión, todo $x \in \mathcal{M}_X$ es valor regular. Por el teorema del valor regular, $F^{-1}(x)$ es una subvariedad de codimensión $\dim(\mathcal{M}_X)$ dentro de $\mathcal{M}_Y$. Por tanto su dimensión es $\dim(\mathcal{M}_Y) - \dim(\mathcal{M}_X)$. $\square$

Corolario 10.3 (La traducción como fibra). *Si un glifo $x \in \mathcal{V}_X$ corresponde a una región comprimida de una lengua conocida, entonces su significado no es necesariamente un punto y , sino una fibra semántica:*

$$\mathcal{F}_x = \{y \in \mathcal{M}_Y : F(y) = x\}.$$

Por tanto, un desciframiento responsable debe devolver conjuntos o distribuciones de significados, no equivalencias absolutas prematuras.

10.2. Pseudoinversa diferencial

Si localmente

$$x \approx F(y_0) + J_F(y_0)(y - y_0),$$

entonces recuperar y desde x requiere invertir J_F , que puede ser rectangular. La solución de mínima norma es

$$y - y_0 = J_F(y_0)^+(x - F(y_0)). \quad (10.1)$$

Aquí aparece Moore–Penrose como inversa local de una submersión linealizada.

11. Regularización, estabilidad y ruido

11.1. Tikhonov espectral

Para corpus pequeños, los valores singulares pequeños son inestables. La pseudoinversa cruda amplifica ruido:

$$\sigma_i \mapsto \frac{1}{\sigma_i}.$$

Por eso se usa regularización de Tikhonov:

$$W_\lambda = (X^\top X + \lambda I)^{-1} X^\top Y. \quad (11.1)$$

Si $X = U\Sigma V^\top$, entonces

$$W_\lambda = V \operatorname{diag} \left(\frac{\sigma_i}{\sigma_i^2 + \lambda} \right) U^\top Y. \quad (11.2)$$

Teorema 11.1 (Contracción espectral de Tikhonov). *El operador regularizado reemplaza el factor $1/\sigma_i$ de la pseudoinversa por*

$$g_\lambda(\sigma_i) = \frac{\sigma_i}{\sigma_i^2 + \lambda}.$$

Además,

$$0 \leq g_\lambda(\sigma_i) \leq \frac{1}{2\sqrt{\lambda}}.$$

Demostración. La expresión (11.2) se obtiene sustituyendo la SVD de X :

$$X^\top X = V\Sigma^\top \Sigma V^\top.$$

Luego

$$(X^\top X + \lambda I)^{-1} X^\top = V(\Sigma^\top \Sigma + \lambda I)^{-1} \Sigma^\top U^\top.$$

Para cada $\sigma \geq 0$,

$$g_\lambda(\sigma) = \frac{\sigma}{\sigma^2 + \lambda}.$$

La cota máxima se obtiene derivando:

$$g'_\lambda(\sigma) = \frac{\lambda - \sigma^2}{(\sigma^2 + \lambda)^2},$$

cuyo máximo ocurre en $\sigma = \sqrt{\lambda}$, dando

$$g_\lambda(\sqrt{\lambda}) = \frac{\sqrt{\lambda}}{2\lambda} = \frac{1}{2\sqrt{\lambda}}.$$

□

Corolario 11.2 (Bajo recurso exige regularización). *En corpus pequeños, donde muchas direcciones espectrales tienen σ_i bajo, la pseudoinversa sin regularización puede transformar ruido en hipótesis semánticas artificiales. Tikhonov limita esta amplificación.*

12. Modelo probabilístico completo

12.1. Posterior de traducción de signos

Proponemos el siguiente posterior no normalizado:

$$p(y_j \mid x_i) \propto \exp\left(-\frac{\|e_i^{(X)}Q - e_j^{(Y)}\|^2}{\tau}\right) \cdot \psi_{\text{freq}}(x_i, y_j) \cdot \psi_{\text{icon}}(x_i, y_j) \cdot \psi_{\text{morph}}(x_i, y_j) \cdot \psi_{\text{anth}}(x_i, y_j), \quad (12.1)$$

donde:

- (I) $\tau > 0$ controla temperatura;
- (II) ψ_{freq} compara frecuencias;
- (III) ψ_{icon} incorpora semejanza visual o iconográfica;
- (IV) ψ_{morph} incorpora restricciones morfológicas;
- (V) ψ_{anth} incorpora conocimiento cultural explícito.

La normalización es

$$p(y_j \mid x_i) = \frac{\exp(-D_{ij}/\tau) \prod_r \psi_r(x_i, y_j)}{\sum_\ell \exp(-D_{i\ell}/\tau) \prod_r \psi_r(x_i, y_\ell)}.$$

12.2. Decodificación secuencial

Para una secuencia $x_{1:T}$, buscamos una secuencia $y_{1:T}$ maximizando:

$$\begin{aligned} \mathcal{S}(y_{1:T} \mid x_{1:T}) &= \sum_{t=1}^T \log p(y_t \mid x_t) \\ &\quad + \beta \sum_{t=1}^T \log p_Y(y_t \mid y_{<t}) \\ &\quad + \gamma \sum_{t=1}^T \log \phi_{\text{syntax}}(y_t, y_{t-1}, x_t, x_{t-1}) \\ &\quad - \Omega(y_{1:T}). \end{aligned} \quad (12.2)$$

Aquí p_Y puede ser un modelo de lenguaje entrenado en lenguas candidatas; ϕ_{syntax} impone compatibilidad estructural; y Ω penaliza soluciones demasiado libres, anacrónicas o semánticamente extravagantes.

12.3. Principio de auditabilidad

Cada hipótesis debe almacenar:

hipótesis = (glifo, candidatos, probabilidades, evidencia, contraevidencia, incertidumbre).

Nunca se debe reportar solo:

$$x_i = y_j.$$

La forma correcta es:

$$p(y_j \mid x_i, \mathcal{E}) = \rho,$$

junto con la evidencia $\mathcal{E}$.

13. Algoritmo propuesto

Algorithm 1 Spectral Submersion Decipherment

Require: Corpus perdido $\mathcal{C}_X$, corpus candidato $\mathcal{C}_Y$, conocimiento externo $\mathcal{K}$, dimensión k

Ensure: Diccionario probabilístico Π , hipótesis secuenciales, reporte de incertidumbre

- 1: Normalizar signos de X : variantes, orientación, segmentación, metadatos
 - 2: Construir matrices C_X, C_Y de co-ocurrencia con múltiples ventanas
 - 3: Calcular $M_X = \text{PPMI}(C_X)$, $M_Y = \text{PPMI}(C_Y)$
 - 4: Obtener SVD truncada: $M_X \approx U_X \Sigma_X V_X^\top$, $M_Y \approx U_Y \Sigma_Y V_Y^\top$
 - 5: Construir embeddings $E_X = U_{X,k} \Sigma_{X,k}^\alpha$, $E_Y = U_{Y,k} \Sigma_{Y,k}^\alpha$
 - 6: Estimar anclajes débiles $A = \{(x_i, y_j)\}$ desde $\mathcal{K}$
 - 7: **if** hay anclajes suficientes **then**
 - 8: Resolver Procrustes $Q^* = \arg \min_{Q^\top Q = I} \|E_X^A Q - E_Y^A\|_F^2$
 - 9: **else**
 - 10: Inicializar Q por alineamiento relacional o Gromov–Wasserstein
 - 11: **end if**
 - 12: Resolver transporte blando Π con costos geométricos, relacionales y priors
 - 13: Calibrar Π mediante bootstrap y controles negativos
 - 14: Decodificar secuencias con (12.2)
 - 15: Reportar hipótesis rankeadas y falsables, no traducciones absolutas
-

14. Diseño experimental

14.1. Experimento sintético controlado

Para validar el método antes de aplicarlo a un sistema real, se crea una lengua conocida Y , luego se genera una escritura artificial X mediante:

$$x_t = g(y_t, \eta_t), \tag{14.1}$$

donde g puede colapsar categorías, permutar símbolos, eliminar vocales, fusionar morfemas o introducir ruido.

Se evalúa si el algoritmo recupera:

- (I) clases funcionales;
- (II) vecinos semánticos;
- (III) anclajes;
- (IV) secuencias probables;
- (V) fibras semánticas.

14.2. Controles negativos

Un marco serio debe fallar cuando debe fallar. Proponemos:

- (I) **corpus permutado:** destruir orden pero mantener frecuencias;
- (II) **corpus aleatorio:** muestrear signos i.i.d.;
- (III) **lengua no relacionada:** usar corpus candidato incompatible;
- (IV) **anclajes falsos:** introducir priors incorrectos;
- (V) **bootstrap extremo:** medir sensibilidad a subconjuntos del corpus.

14.3. Métricas

$$\text{GraphDistortion} = \sum_{i,i',j,j'} |\Delta_X(i,i') - \Delta_Y(j,j')|^2 \Pi_{ij} \Pi_{i'j'}, \quad (14.2)$$

$$\text{Entropy}(\Pi_i) = - \sum_j \Pi_{ij} \log \Pi_{ij}, \quad (14.3)$$

$$\text{AnchorAcc@k} = \frac{1}{|A|} \sum_{(i,j) \in A} \mathbb{1}\{j \in \text{TopK}(\Pi_i)\}, \quad (14.4)$$

$$\text{Stability} = \mathbb{E}_b \left[\text{sim}(\Pi, \Pi^{(b)}) \right]. \quad (14.5)$$

La entropía alta indica incertidumbre; entropía baja con controles negativos malos indica sobreconfianza.

15. Aplicación exploratoria a sistemas tipo Rongorongo

15.1. Advertencia metodológica

Este artículo no afirma descifrar Rongorongo. Propone una metodología para estudiar su estructura bajo incertidumbre. Dado el bajo número de objetos conservados y la falta de bilingües confirmados, cualquier lectura semántica fuerte sería prematura sin evidencia externa robusta.

15.2. Unidades candidatas

Para un corpus rongorongo normalizado, se pueden construir varias granularidades:

- (I) glifo individual;
- (II) variante paleográfica;
- (III) biglifo;
- (IV) bloque repetido;
- (V) línea;
- (VI) secuencia entre separadores visuales;
- (VII) patrón direccional.

Cada granularidad induce una matriz $M_X^{(g)}$. El análisis espectral debe comparar la estabilidad entre granularidades:

$$\mathcal{S}_g = \{\sigma_1^{(g)}, \dots, \sigma_k^{(g)}\}.$$

15.3. Hipótesis candidatas

Lenguas o espacios candidatos:

- (I) rapanui moderno;
- (II) otras lenguas polinesias;
- (III) proto-polinesio reconstruido;
- (IV) vocabularios rituales/calendáricos;
- (V) taxonomías de fauna, navegación, genealogía y parentesco;
- (VI) sistemas numéricos o calendáricos.

El método debe tratar estos candidatos como modelos rivales:

$$\mathcal{M}_1, \dots, \mathcal{M}_K.$$

Se compara evidencia marginal:

$$p(\mathcal{C}_X \mid \mathcal{M}_k)$$

o aproximaciones mediante criterios de distorsión y validación.

16. Teoría de identificabilidad parcial

Definición 16.1 (Identificabilidad parcial). *Un símbolo x_i es parcialmente identificable respecto a una familia de candidatos $\mathcal{Y}_i \subseteq \mathcal{V}_Y$ si, para todo $y \notin \mathcal{Y}_i$,*

$$p(y \mid x_i, \mathcal{E}) < \max_{y' \in \mathcal{Y}_i} p(y' \mid x_i, \mathcal{E})$$

de manera estable bajo bootstrap, controles negativos y perturbaciones razonables.

Teorema 16.2 (Identificabilidad exacta bajo anclajes e isometría). *Suponga que existen embeddings $E_X, E_Y \in \mathbb{R}^{n \times d}$, una permutación P_0 y una matriz ortogonal Q_0 tales que*

$$E_Y = P_0 E_X Q_0.$$

Si se conoce un conjunto de anclajes que elimina toda simetría no trivial de P_0 , y E_X tiene rango columna completo sobre esos anclajes, entonces P_0 y Q_0 son identificables.

Demostración. Los anclajes fijan correspondencias de filas. Restringiendo a las filas ancladas A , se tiene

$$E_Y^A = E_X^A Q_0.$$

Por el corolario de Procrustes exacto, Q_0 es único si E_X^A tiene rango columna completo. Una vez fijado Q_0 , cada fila $E_X(i)Q_0$ se compara con las filas de E_Y . Si los anclajes eliminan simetrías no triviales, no existe otra permutación $P \neq P_0$ que preserve todas las relaciones y anclajes. Por tanto, P_0 queda identificado. $\square$

Corolario 16.3 (Régimen realista). *En sistemas perdidos reales, las condiciones exactas rara vez se cumplen. Por tanto, el objetivo científico razonable es identificabilidad parcial con incertidumbre calibrada, no equivalencia exacta símbolo-palabra.*

17. Relación con LLMs e inferencia moderna

17.1. LLMs como priors, no como oráculos

Un modelo de lenguaje puede aportar:

- (I) generación de hipótesis culturales;
- (II) expansión de vocabularios candidatos;
- (III) comparación semántica;
- (IV) explicación de patrones;
- (V) búsqueda de analogías.

Pero no debe usarse como autoridad final. En este marco, un LLM produce un prior:

$$p_{\text{LLM}}(y \mid x, \mathcal{K}),$$

que se combina con evidencia estadística:

$$p(y \mid x, \mathcal{E}) \propto p_{\text{stat}}(y \mid x)p_{\text{LLM}}(y \mid x, \mathcal{K})^\lambda.$$

Si λ es alto, el sistema puede alucinar. Si $\lambda = 0$, se pierde conocimiento externo útil. La calibración de λ debe hacerse con controles.

17.2. RAG para desciframiento

Un sistema RAG puede recuperar evidencia desde:

- (I) publicaciones arqueológicas;
- (II) diccionarios históricos;
- (III) gramáticas comparadas;
- (IV) corpus polinesios;
- (v) bases de iconografía;
- (VI) reportes paleográficos.

Toda hipótesis generada debe guardar trazabilidad documental. La forma correcta no es:

“el glifo significa X”,

sino:

“el glifo tiene candidatos $\{X_1, X_2, X_3\}$ con evidencia $\mathcal{E}$ y contraevidencia $\mathcal{E}^-$.”

18. Arquitectura computacional reproducible

18.1. Estructura de repositorio

```
spectral-submersion-decipherment/  
  README.md  
  pyproject.toml  
  data/  
    raw/  
    interim/  
    processed/  
  configs/  
    rongorongong.yaml  
    synthetic.yaml  
  src/  
    normalization/  
    cooccurrence/
```

spectral/
alignment/
transport/
decoding/
evaluation/
reporting/
notebooks/
tests/
reports/
figures/
tables/
hypotheses/

18.2. Componentes

- C1. Normalizer:** convierte imágenes, transcripciones o variantes a tokens normalizados.
- C2. ContextBuilder:** genera C_X , PMI, PPMI y tensores direccionales.
- C3. SpectralEngine:** calcula SVD, rango efectivo, embeddings y estabilidad.
- C4. AlignmentEngine:** ejecuta Procrustes, Moore–Penrose, GW y OT.
- C5. Decoder:** genera hipótesis símbolo-palabra y secuencia-secuencia.
- C6. Evaluator:** aplica controles negativos, bootstrap y métricas.
- C7. ReportGenerator:** produce reportes auditables.

19. Discusión

19.1. Qué puede demostrar el método

El método puede demostrar:

- (I) que un corpus tiene estructura no aleatoria;
- (II) que ciertos signos cumplen roles funcionales;
- (III) que ciertas segmentaciones son más estables que otras;
- (IV) que una lengua candidata explica mejor la estructura que controles;
- (V) que ciertos candidatos semánticos son más plausibles que otros;
- (VI) que algunas hipótesis deben descartarse.

19.2. Qué no puede demostrar solo

El método no puede demostrar por sí solo:

- (I) una traducción definitiva;
- (II) pronunciación;
- (III) correspondencia uno-a-uno entre glifos y palabras;
- (IV) intención cultural exacta;
- (V) historicidad de una lectura sin evidencia externa.

19.3. Belleza matemática del enfoque

La pseudoinversa aparece como una forma de humildad matemática: cuando una inversión exacta no existe, se elige la solución mínima compatible con la evidencia. La SVD aparece como instrumento de visión: separa direcciones dominantes de ruido. Procrustes aparece como respeto geométrico: no deforma arbitrariamente una lengua para que encaje con otra. La submersión aparece como metáfora formal: un sistema pequeño puede ser sombra de una semántica más rica, y cada signo puede corresponder a una fibra, no a un punto.

20. Conclusión

Este trabajo formula un marco matemático para el desciframiento probabilístico de sistemas simbólicos perdidos mediante geometría espectral. La propuesta parte de una intuición antigua, la frecuencia como huella estadística, y la eleva a una arquitectura moderna basada en SVD, Moore–Penrose, Procrustes, transporte óptimo, submersión de variedades e inferencia bayesiana.

La conclusión principal es doble. Primero, la estadística interna de un sistema simbólico puede revelar estructura significativa si el sistema codifica información no trivial. Segundo, esa estructura no basta para traducción fuerte sin anclajes externos. Por ello, el método propuesto no busca reemplazar a la filología, arqueología o lingüística histórica; busca entregarles una máquina rigurosa de hipótesis, falsación y ranking probabilístico.

En una frase:

descifrar no es invertir una matriz; es construir una inversa regularizada de la evidencia.

A. Apéndice A: derivación matricial del gradiente de mínimos cuadrados

Sea

$$f(W) = \|XW - Y\|_F^2.$$

Usando traza:

$$f(W) = \text{tr}((XW - Y)^\top (XW - Y)) \quad (\text{A.1})$$

$$= \text{tr}(W^\top X^\top XW) - 2 \text{tr}(W^\top X^\top Y) + \text{tr}(Y^\top Y). \quad (\text{A.2})$$

El gradiente es

$$\nabla_W f = 2X^\top XW - 2X^\top Y.$$

La ecuación normal es

$$X^\top XW = X^\top Y.$$

Si $X^\top X$ es invertible:

$$W = (X^\top X)^{-1} X^\top Y.$$

Si no es invertible, la solución de norma mínima es

$$W = X^+ Y.$$

B. Apéndice B: índice de anisotropía espectral

Definimos

$$A_k(M) = \frac{\sigma_1}{\frac{1}{k} \sum_{i=1}^k \sigma_i}.$$

Si A_k es alto, una dirección domina la estructura. En lenguaje, esto puede corresponder a:

- (I) frecuencia extrema de signos funcionales;
- (II) artefactos de segmentación;
- (III) direccionalidad mal normalizada;
- (IV) tema ritual repetitivo;
- (V) corpus demasiado pequeño.

C. Apéndice C: plantilla de reporte de hipótesis

Para cada signo x_i , el sistema debe producir:

```
glyph_id: x_i
frequency_rank: ...
spectral_coordinates: [...]
top_candidates:
  - candidate: y_1
    probability: 0.31
    evidence:
      - geometric_nearest_neighbor
      - compatible_frequency_class
```

```

    - supported_by_iconographic_prior
counterevidence:
    - unstable_under_bootstrap_window_3
- candidate: y_2
  probability: 0.22
uncertainty:
  entropy: ...
  bootstrap_variance: ...
decision:
  status: partial / unstable / rejected / strong_candidate

```

D. Apéndice D: glosario

Pseudoinversa	Generalización de la inversa para matrices rectangulares o singulares.
SVD	Factorización $A = U\Sigma V^\top$ que separa direcciones ortogonales y escalas.
Procrustes	Problema de encontrar la rotación/reflexión que mejor alinea dos nubes de puntos.
PMI	Medida de asociación entre dos eventos basada en cuánto supera su co-ocurrencia a la independencia.
Transporte óptimo	Marco para acoplar distribuciones minimizando costo.
Gromov–Wasserstein	Variante de transporte que compara estructuras relacionales internas.
Submersión	Mapa suave cuyo diferencial tiene rango máximo en el codominio.
Fibra	Conjunto de puntos que colapsan a un mismo valor bajo una aplicación.
Anclaje	Evidencia externa que rompe simetrías de permutación.

Referencias

- [1] L. D. Broemeling. An account of early statistical inference in Arab cryptology. *The American Statistician*, 65(4):255–257, 2011.
- [2] S. Ferrara, R. S. R. et al. The invention of writing on Rapa Nui (Easter Island). New radiocarbon dates on the Rongorongo script. *Scientific Reports*, 14, 2024.
- [3] E. H. Moore. On the reciprocal of the general algebraic matrix. *Bulletin of the American Mathematical Society*, 26:394–395, 1920.
- [4] R. Penrose. A generalized inverse for matrices. *Mathematical Proceedings of the Cambridge Philosophical Society*, 51(3):406–413, 1955.

- [5] G. H. Golub and C. F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, 4th edition, 2013.
- [6] C. Eckart and G. Young. The approximation of one matrix by another of lower rank. *Psychometrika*, 1:211–218, 1936.
- [7] P. H. Schönemann. A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31:1–10, 1966.
- [8] M. Artetxe, G. Labaka, and E. Agirre. Learning bilingual word embeddings with (almost) no bilingual data. In *Proceedings of ACL*, pages 451–462, 2017.
- [9] M. Artetxe, G. Labaka, and E. Agirre. Generalizing and improving bilingual word embedding mappings with a multi-step framework of linear transformations. In *Proceedings of AAAI*, 2018.
- [10] A. Conneau, G. Lample, M. Ranzato, L. Denoyer, and H. Jégou. Word translation without parallel data. In *International Conference on Learning Representations*, 2018.
- [11] G. Lample, A. Conneau, L. Denoyer, and M.-A. Ranzato. Unsupervised machine translation using monolingual corpora only. In *International Conference on Learning Representations*, 2018.
- [12] D. Alvarez-Melis and T. S. Jaakkola. Gromov-Wasserstein alignment of word embedding spaces. In *Proceedings of EMNLP*, pages 1881–1890, 2018.
- [13] G. Dinu, A. Lazaridou, and M. Baroni. Improving zero-shot learning by mitigating the hubness problem. In *ICLR Workshop*, 2015.
- [14] T. Mikolov, K. Chen, G. Corrado, and J. Dean. Efficient estimation of word representations in vector space. *arXiv:1301.3781*, 2013.
- [15] O. Levy and Y. Goldberg. Neural word embedding as implicit matrix factorization. In *Advances in Neural Information Processing Systems*, 2014.
- [16] G. Peyré and M. Cuturi. Computational optimal transport. *Foundations and Trends in Machine Learning*, 11(5–6):355–607, 2019.
- [17] C. Villani. *Optimal Transport: Old and New*. Springer, 2009.
- [18] J. M. Lee. *Introduction to Smooth Manifolds*. Springer, 2nd edition, 2013.
- [19] T. M. Cover and J. A. Thomas. *Elements of Information Theory*. Wiley, 2nd edition, 2006.