

Geometría Espectral e Identificabilidad Parcial en Sistemas Simbólicos No Descifrados

Un Marco Auditable para Hipótesis Rongorongo: Submersión Espectral, Procrustes, Transporte Óptimo y Teoría de Claim Levels

David Alexander Astudillo Muñoz

CEO & CTO, Baskerville AI

Ingeniero Civil Matemático, Universidad de Chile

Deep Learning para Trading Cuantitativo

Arquitecturas Neurales + RL + Time Series Forecasting

david@baskerville.ai

29 de abril de 2026

Resumen

Este artículo propone un marco matemático formal, auditable y falsable para el análisis estructural y la generación probabilística de hipótesis sobre sistemas simbólicos no descifrados bajo escasez extrema de datos. La tesis central no es que podamos traducir Rongorongo, sino que podemos construir una *teoría de identificabilidad parcial*: formalicemos por qué la traducción fuerte es no identificable sin anclajes externos (Teorema de No-Free-Decipherment bajo acción de grupos), caractericemos cuánta ambigüedad elimina cada anclaje (AnchorPower), derivemos condiciones bajo las cuales los embeddings espectrales son estables (estabilidad Davis–Kahan/Wedin para corpus finitos), y definamos niveles explícitos de claim admisibles (C_0 – C_5) que prohíban toda afirmación semántica no respaldada por evidencia, estabilidad y controles negativos.

El marco combina: co-ocurrencia y PPMI regularizado con priors estructurales (SPPMI); descomposición en valores singulares con diagnóstico de estabilidad espectral (SpectralReliability); alineamiento Procrustes con análisis de perturbación bajo anclajes ruidosos (AnchorCondition); transporte óptimo con descomposición auditable de costos (geometría, relación, prior, entropía); transporte Gromov–Wasserstein con estabilidad multi-inicialización; y un modelo generativo probabilístico que produce un *ledger de hipótesis* rankeado con evidencia, contraevidencia, nivel de claim máximo y riesgo de sobreinterpretación. Rongorongo se trata como caso de motivación de bajo recurso: la salida no es una traducción verificada, sino una familia de hipótesis parcialmente identificables, falsables y auditables.

La contribución matemática principal es triple: (1) un teorema de no-identificabilidad que formaliza que todo estadístico puramente estructural es invariante bajo renombramiento del vocabulario, haciendo la semántica absoluta inalcanzable sin anclajes; (2) una teoría de estabilidad espectral y Procrustes que acota cuándo los embeddings son confiables bajo perturbación de corpus finito; (3) un sistema de claim levels C_0 – C_5 con umbrales monótonos de admisibilidad que convierte la investigación en un sistema de inferencia responsable.

Palabras clave: Moore–Penrose, SVD, pseudoinversa, Procrustes, embeddings cross-linguales,

traducción no supervisada, Rongorongo, Al-Kindi, geometría diferencial, transporte óptimo, inferencia bayesiana, lenguajes perdidos, análisis espectral.

Índice

1. Introducción	6
2. Desciframiento como problema inverso mal puesto	6
3. Niveles de claim y admisibilidad	7
4. Motivación histórica y técnica	8
4.1. De Al-Kindi al aprendizaje no supervisado	8
4.2. Rongorongo como motivación de bajo recurso extremo	8
5. Planteamiento formal del problema	9
5.1. Sistema simbólico observado	9
5.2. Matriz de co-ocurrencia	9
5.3. Embedding espectral	10
6. Axiomas epistémicos	10
7. Moore–Penrose y la inversión lineal mínima	11
7.1. La pseudoinversa como solución canónica	11
7.2. Traducción lineal de mínimos cuadrados	12
8. Bajo rango, compresión semántica y Eckart–Young	12
9. Alineamiento Procrustes	13
9.1. Mapa ortogonal	13
10.No-desciframiento gratuito e identificabilidad bajo acción de grupos	14
10.1. Acción de permutación	14
10.2. No-identificabilidad absoluta	15
10.3. Anclajes como ruptura de simetría	16
11.Diccionario blando y transporte óptimo	17
11.1. Asignación probabilística	17
11.2. Costo geométrico	17
11.3. Costo relacional tipo Gromov–Wasserstein	17
11.4. Regularización entrópica	17
12.Submersión entre variedades semánticas	18
12.1. Lenguajes como variedades estadísticas	18
12.2. Pseudoinversa diferencial	18
13.Estabilidad espectral bajo corpus finito	19

14. Concentración de co-ocurrencias y suficiencia de datos	20
15. PPMI regularizado con priors estructurales	20
16. Estabilidad de Procrustes bajo anclajes ruidosos	20
17. Transporte óptimo auditable	21
17.1. Tikhonov espectral	22
18. Modelo probabilístico completo	23
18.1. Posterior de traducción de signos	23
18.2. Decodificación secuencial	23
18.3. Principio de auditabilidad	23
19. Algoritmo propuesto	24
20. Diseño experimental	24
20.1. Experimento sintético controlado	24
20.2. Controles negativos	25
20.3. Métricas	25
21. Aplicación exploratoria a sistemas tipo Rongorongo	25
21.1. Advertencia metodológica	25
21.2. Unidades candidatas	25
21.3. Hipótesis candidatas	26
22. Resultados Empíricos	26
22.1. Benchmark sintético PCFG (control estructurado)	27
22.2. Corpus sintético con sesgo posicional	27
22.3. Corpus real del Indo (Parpola CISI)	28
22.3.1. Descripción del corpus	28
22.3.2. Sanity check espectral	28
22.3.3. Entropía condicional de pares	29
22.3.4. Sesgo posicional: el hallazgo más fuerte	29
22.3.5. Comunidades de co-ocurrencia	30
22.3.6. Embeddings mejorados con priors iconográficos	31
22.3.7. Patrones de repetición de signos	31
22.3.8. Significancia estadística del sesgo posicional	32
22.3.9. Modelos n-gram y perplexity	33
22.3.10. Clasificador supervisado de posición	34
22.4. Aplicación a Rongorongo	35
22.4.1. Situación del corpus	35
22.4.2. Benchmark Rongorongo-like	35
22.5. Embeddings de features estructurales	35
22.6. GW multi-marginal y expansión a 17 lenguas candidatas	36

22.7. Features iconográficos del RR-corpus	37
22.8. Síntesis comparativa	38
23.Resultados adicionales	40
23.1. GPA truncado vs. Gromov–Wasserstein pareado	40
23.2. Búsqueda de anclas bilingües mediante sesgo posicional	40
23.3. SVD conjunta de features estructurales e iconográficos	41
23.4. Modelado boustrophedon	42
24.Consenso multi-idioma y reducción de fibras semánticas	42
24.1. Intuición: múltiples vistas de un mundo compartido	42
24.2. Formalización del espacio consenso	43
24.3. Proyección del sistema perdido al consenso	43
24.4. Teorema de reducción de fibra	43
24.5. Alineamiento relacional multi-vista	44
25.Teoría de identificabilidad parcial	44
26.Relación con LLMs e inferencia moderna	45
26.1. LLMs como priors, no como oráculos	45
26.2. RAG para desciframiento	45
27.Arquitectura computacional reproducible	46
27.1. Estructura de repositorio	46
27.2. Componentes	46
28.Auditoría PhD: Resultados cuantitativos completos	47
28.1. Cobertura de co-ocurrencias y suficiencia de datos (Proposición 14.1)	47
28.2. Estabilidad espectral (Teorema 13.2)	47
28.3. Espectros singulares por tipo de matriz	48
28.4. Controles negativos multi-métrica (Sección 30)	49
28.5. Experimentos sintéticos	49
28.6. Verificación de no-identificabilidad (Teorema 10.1)	50
28.7. Auditoría de niveles de claim	50
28.8. Estabilidad de Procrustes bajo anclajes ruidosos (Teorema 16.1)	51
28.9. Descomposición de costos de transporte y estabilidad OT	51
28.10Validación bilingüe en idiomas conocidos	51
28.11Resumen de hallazgos cuantitativos	52
29.Discusión	53
29.1. Qué puede demostrar el método	53
29.2. Qué no puede demostrar solo	54
29.3. Implicaciones para Rongorongo	54
29.4. Belleza matemática del enfoque	55

30. Métricas de auditabilidad y principio de ledger de hipótesis	55
30.1. Gap contra controles negativos	55
30.2. Estabilidad bootstrap	55
30.3. Calibración	55
30.4. Índice de sobreinterpretación	56
30.5. Ledger de hipótesis	56
31. Conclusión	56
32. Corrigenda	57
A. Apéndice A: derivación matricial del gradiente de mínimos cuadrados	58
B. Apéndice B: índice de anisotropía espectral	58
C. Apéndice C: plantilla de reporte de hipótesis	59
D. Apéndice D: glosario	59

1. Introducción

El desciframiento de un sistema simbólico perdido puede entenderse como un problema inverso: se observa una secuencia finita de signos, pero se desconoce la aplicación que conecta esos signos con unidades semánticas, fonológicas, rituales, calendáricas o administrativas. En su versión más simple, el problema recuerda al criptoanálisis por frecuencia asociado históricamente a Al-Kindi: un texto cifrado conserva regularidades estadísticas del idioma original, y esas regularidades pueden explotarse para proponer correspondencias entre signos y letras [1]. Sin embargo, un sistema como Rongorongo no es un cifrado monoalfabético con una lengua original conocida; es un objeto de bajo recurso, culturalmente situado, con corpus pequeño, sin bilingües confirmados y con múltiples fuentes de incertidumbre [2].

La pregunta de este trabajo es más general:

¿Puede una geometría estadística inducida por un sistema simbólico perdido alinearse con la geometría estadística de una o varias lenguas conocidas, de modo que se generen hipótesis de traducción probabilísticas, auditables y falsables?

La respuesta propuesta es condicional. Sí, si se cumplen restricciones fuertes: existencia de estructura lingüística o semiótica no trivial, corpus suficiente para estimar relaciones de co-ocurrencia, espacios comparables, anclajes débiles, regularización cultural y validación negativa. No, si se espera recuperar significado completo desde frecuencias marginales aisladas.

El marco que desarrollamos combina cinco niveles.

N1. Nivel estadístico: frecuencias, co-ocurrencias, PMI, transición y grafos de contexto.

N2. Nivel espectral: SVD, rango efectivo, pseudoinversa y aproximaciones de bajo rango.

N3. Nivel geométrico: alineamientos ortogonales, Procrustes, variedades latentes, submersión y fibras semánticas.

N4. Nivel probabilístico: diccionarios blandos, posterior semántico, decodificación secuencial y calibración.

N5. Nivel epistémico: límites de identificabilidad, imposibilidad sin anclajes, validación por controles negativos.

La idea central puede expresarse informalmente así:

La traducción perdida no es una clave única; es una geometría latente parcialmente invertible.

2. Desciframiento como problema inverso mal puesto

El desciframiento no es solo un problema difícil; es, en ausencia de anclajes, un *problema inverso mal puesto* en el sentido de Hadamard. Un problema inverso es bien puesto si cumple tres condiciones: existencia de solución, unicidad, y dependencia continua de los datos. En Rongorongo, las tres fallan o son dudosas.

Proposición 2.1 (Desciframiento no anclado como problema inverso mal puesto). *Sea X un corpus finito de signos no descifrados y sea $\mathcal{Y}$ una familia de corpus candidatos. Definamos un operador de observación*

$$\mathcal{O} : \Theta \rightarrow \mathcal{D}_X, \quad (2.1)$$

donde Θ parametriza traducciones, segmentaciones, valores fonéticos, clases funcionales y modelos generativos, y $\mathcal{D}_X$ representa los datos observables: secuencias de glifos, posiciones, frecuencias, co-ocurrencias y metadatos. El problema de desciframiento consiste en recuperar $\theta \in \Theta$ desde $\mathcal{O}(\theta) = X$.

En ausencia de anclajes externos, $\mathcal{O}$ no es inyectivo. Por tanto, el problema no tiene solución única.

La existencia es dudosa porque puede no haber correspondencia léxica simple entre glifos y palabras modernas. La unicidad falla por el Teorema 10.1 a continuación. La estabilidad falla porque pequeñas variaciones paleográficas alteran co-ocurrencias, grafos y embeddings. El objetivo científico correcto no es una traducción única, sino una *distribución posterior sobre clases de equivalencia de hipótesis*.

3. Niveles de claim y admisibilidad

Para evitar sobreinterpretación, todo resultado debe declarar explícitamente qué tipo de afirmación sustenta. Definimos un espacio de claims jerárquico:

$$\mathcal{C} = \{C_0, C_1, C_2, C_3, C_4, C_5\}, \quad (3.1)$$

donde cada nivel requiere más evidencia:

Nivel	Label	Lo permitido	Lo prohibido
C_0	Paleográfico	Este trazo/glifo existe con probabilidad p	significado
C_1	Estructural	frecuencia, posición, repetición, co-ocurrencia	función semántica
C_2	Funcional	marcador inicial/final, clasificador, numeral posible	traducción léxica
C_3	Semántico débil	compatible con dominio lunar/genealógico/ritual	lectura literal
C_4	Fonético parcial	compatible con sílaba/sonido bajo anclaje externo	desciframiento completo
C_5	Traducción fuerte	lectura verificable	(requiere evidencia independiente)

Definición 3.1 (Claim admisible). *Un claim $c \in \mathcal{C}$ es admisible para una hipótesis h si existe*

evidencia E , contraevidencia B , controles negativos N y nivel de anclaje A tales que

$$\text{Admissible}(h, c) = \mathbf{1}[S(h; E) - \mathbb{E}_{n \sim N} S(h; n) > \lambda_c \sigma_N] \cdot \mathbf{1}[\text{AnchorLevel}(h) \geq a_c] \cdot \mathbf{1}[\text{Stability}(h) \geq s_c], \quad (3.2)$$

donde λ_c , a_c , s_c aumentan con el nivel del claim.

Teorema 3.2 (Monotonía de admisibilidad). *Si los umbrales satisfacen $\lambda_0 \leq \lambda_1 \leq \dots \leq \lambda_5$, $a_0 \leq a_1 \leq \dots \leq a_5$, $s_0 \leq s_1 \leq \dots \leq s_5$, entonces:*

$$\text{Admissible}(h, C_j) = 1 \implies \text{Admissible}(h, C_i) = 1 \quad \forall i < j. \quad (3.3)$$

Demostración. Si h satisface los umbrales de un nivel superior j , satisface automáticamente todos los umbrales menores o iguales de los niveles inferiores, por la monotonía de λ , a y s . $\square$

Esta jerarquía protege contra sobreinterpretación: un resultado puramente espectral puede sostener claims C_0 y C_1 , pero no C_3 o superiores sin anclajes. Un claim C_5 (traducción fuerte) requiere evidencia externa independiente verificable.

4. Motivación histórica y técnica

4.1. De Al-Kindi al aprendizaje no supervisado

El criptoanálisis por frecuencia parte de una observación simple: si una sustitución simbólica conserva el orden textual, entonces las letras más frecuentes del idioma base tienden a seguir siendo frecuentes, aunque aparezcan con otros símbolos. Esta idea no descifra por sí sola lenguajes completos, pero inaugura una familia de métodos estadísticos: inferir estructura invisible desde distribuciones observables.

En NLP moderno, una idea análoga aparece en embeddings multilingües y traducción no supervisada. Métodos como los de Artetxe, Labaka y Agirre [8, 9], Conneau et al. [10], Lample et al. [11] y Alvarez-Melis y Jaakkola [12] exploran cómo alinear espacios vectoriales monolingües sin grandes corpus paralelos. Muchos de estos métodos dependen de una hipótesis geométrica: lenguas distintas que describen mundos comparables inducen espacios semánticos con estructura relacional parcialmente isomorfa.

Este trabajo traslada esa intuición a un régimen más extremo: sistemas simbólicos pequeños, posiblemente no fonéticos, sin corpus paralelo y con semántica culturalmente densa.

4.2. Rongorongo como motivación de bajo recurso extremo

Rongorongo, escritura asociada a Rapa Nui, permanece sin descifrar. La literatura reciente destaca que los objetos conservados son escasos y que su origen histórico sigue siendo tema de investigación [2]. Por ello, cualquier propuesta de desciframiento debe distinguir cuidadosamente entre:

- (1) **desciframiento fuerte:** lectura semántica o fonética verificable;

- (II) **desciframiento débil:** segmentación, direccionalidad, clases funcionales, repeticiones;
- (III) **desciframiento probabilístico:** ranking de hipótesis con incertidumbre;
- (IV) **análisis estructural:** evidencia de que el sistema posee regularidades no aleatorias.

Nuestro marco apunta primero a los niveles débil, probabilístico y estructural. El nivel fuerte requiere evidencia externa adicional.

5. Planteamiento formal del problema

5.1. Sistema simbólico observado

Sea X un sistema simbólico perdido. Observamos un corpus finito

$$\mathcal{C}_X = (s_1, s_2, \dots, s_T), \quad s_t \in \mathcal{V}_X, \quad (5.1)$$

donde $\mathcal{V}_X = \{x_1, \dots, x_{n_X}\}$ es el vocabulario de signos, glifos, variantes normalizadas o unidades segmentadas.

Sea Y una lengua conocida o un conjunto de lenguas conocidas:

$$\mathcal{C}_Y = (w_1, w_2, \dots, w_M), \quad w_m \in \mathcal{V}_Y, \quad (5.2)$$

donde $\mathcal{V}_Y = \{y_1, \dots, y_{n_Y}\}$.

El objetivo no es encontrar una función determinista

$$\tau : \mathcal{V}_X \rightarrow \mathcal{V}_Y$$

sino una distribución posterior

$$\Pi_{ij} = p(y_j \mid x_i, \mathcal{C}_X, \mathcal{C}_Y, \mathcal{K}), \quad (5.3)$$

donde $\mathcal{K}$ representa conocimiento adicional: iconografía, arqueología, lengua comparada, direccionalidad, soporte material, calendario, genealogía, tradición oral o restricciones antropológicas.

5.2. Matriz de co-ocurrencia

Definimos una función de contexto $K : \mathbb{N} \rightarrow \mathbb{R}_{\geq 0}$, por ejemplo

$$K(d) = \mathbf{1}\{1 \leq d \leq h\} \quad \text{o} \quad K(d) = \exp(-d/\rho).$$

La matriz de co-ocurrencia de X es

$$C_{ij}^{(X)} = \sum_{t=1}^T \mathbf{1}\{s_t = x_i\} \sum_{\substack{u=1 \\ u \neq t}}^T K(|u - t|) \mathbf{1}\{s_u = x_j\}. \quad (5.4)$$

Análogamente se define $C^{(Y)}$. A partir de C se construyen probabilidades suavizadas:

$$\hat{p}_{ij} = \frac{C_{ij} + \epsilon}{\sum_{a,b} C_{ab} + \epsilon n^2}, \quad \hat{p}_{i\cdot} = \sum_j \hat{p}_{ij}, \quad \hat{p}_{\cdot j} = \sum_i \hat{p}_{ij}. \quad (5.5)$$

La matriz PMI es

$$\text{PMI}_{ij} = \log \frac{\hat{p}_{ij}}{\hat{p}_{i\cdot} \hat{p}_{\cdot j}}. \quad (5.6)$$

La versión positiva se define como

$$\text{PPMI}_{ij} = \max\{\text{PMI}_{ij}, 0\}. \quad (5.7)$$

5.3. Embedding espectral

Sea $M_X \in \mathbb{R}^{n_X \times n_X}$ una matriz estructural del sistema perdido: co-ocurrencia normalizada, PMI, PPMI, transición, Laplaciano de grafo o una combinación ponderada. Su descomposición en valores singulares es

$$M_X = U_X \Sigma_X V_X^\top. \quad (5.8)$$

Para dimensión latente k , definimos el embedding espectral

$$E_X(k, \alpha) = U_{X,k} \Sigma_{X,k}^\alpha, \quad \alpha \in [0, 1]. \quad (5.9)$$

Cuando M_X es simétrica positiva semidefinida, esto coincide con una descomposición espectral clásica. Cuando no lo es, U y V capturan roles direccionales distintos: contexto izquierdo/derecho, emisor/receptor, signo actual/siguiente signo.

6. Axiomas epistémicos

Axioma 6.1 (Suficiencia descriptiva). *Un sistema simbólico X es descifrable en sentido débil solo si existe una variable latente R , representando estados relevantes del mundo cultural o físico, tal que*

$$I(X; R) > 0. \quad (6.1)$$

Este axioma no dice que todo signo tenga significado léxico. Dice que el sistema completo debe transportar información no nula sobre algo externo o interno: eventos, nombres, conteos, clases rituales, secuencias, taxonomías o instrucciones.

Teorema 6.2 (Independencia implica imposibilidad inferencial). *Si X y R son independientes, entonces ningún procedimiento basado únicamente en X puede actualizar racionalmente la creencia sobre R . En particular,*

$$p(R | X) = p(R). \quad (6.2)$$

Demostración. Por independencia,

$$p(X, R) = p(X)p(R).$$

Si $p(X) > 0$, la regla de Bayes entrega

$$p(R | X) = \frac{p(X, R)}{p(X)} = \frac{p(X)p(R)}{p(X)} = p(R).$$

Por lo tanto, observar X no modifica la distribución posterior de R . Cualquier algoritmo que afirme recuperar R desde X en este caso está introduciendo información externa no declarada o ruido interpretativo. $\square$

Corolario 6.3 (Frecuencia sin estructura no basta). *Las frecuencias marginales $p(x_i)$ pueden sugerir clases funcionales, pero no identifican semántica por sí solas. Dos sistemas con las mismas frecuencias y estructuras relacionales distintas pueden tener interpretaciones incompatibles.*

7. Moore–Penrose y la inversión lineal mínima

7.1. La pseudoinversa como solución canónica

Sea $A \in \mathbb{R}^{m \times n}$. Si A es rectangular o singular, no existe en general una inversa clásica. La pseudoinversa de Moore–Penrose A^+ es la única matriz que satisface las cuatro ecuaciones:

$$AA^+A = A, \tag{7.1}$$

$$A^+AA^+ = A^+, \tag{7.2}$$

$$(AA^+)^T = AA^+, \tag{7.3}$$

$$(A^+A)^T = A^+A. \tag{7.4}$$

Teorema 7.1 (Pseudoinversa vía SVD). *Sea $A \in \mathbb{R}^{m \times n}$ una matriz de rango r con SVD*

$$A = U\Sigma V^T, \tag{7.5}$$

donde

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots), \quad \sigma_1 \geq \dots \geq \sigma_r > 0.$$

Entonces

$$A^+ = V\Sigma^+U^T, \tag{7.6}$$

donde Σ^+ reemplaza cada $\sigma_i > 0$ por $1/\sigma_i$ y transpone la forma rectangular.

Demostración. Como U y V son ortogonales, basta verificar las cuatro condiciones de Moore–Penrose para Σ . Para cada valor singular no nulo,

$$\sigma_i \cdot \sigma_i^{-1} \cdot \sigma_i = \sigma_i, \quad \sigma_i^{-1} \cdot \sigma_i \cdot \sigma_i^{-1} = \sigma_i^{-1}.$$

Para valores singulares nulos, los productos permanecen nulos. Además, $\Sigma\Sigma^+$ y $\Sigma^+\Sigma$ son matrices diagonales con entradas 0 o 1, luego son simétricas. Multiplicar por U, V preserva las identidades correspondientes, pues $U^T U = I$ y $V^T V = I$. $\square$

7.2. Traducción lineal de mínimos cuadrados

Supongamos que existen representaciones $X \in \mathbb{R}^{n \times d_X}$ y $Y \in \mathbb{R}^{n \times d_Y}$ de n unidades alineadas parcialmente. Buscamos

$$W^* = \arg \min_{W \in \mathbb{R}^{d_X \times d_Y}} \|XW - Y\|_F^2. \quad (7.7)$$

Teorema 7.2 (Solución Moore–Penrose matricial). *El conjunto de minimizadores de (7.7) contiene*

$$W^* = X^+Y. \quad (7.8)$$

Además, X^+Y es el minimizador de norma Frobenius mínima.

Demostración. El problema se separa por columnas. Sea $Y = [y_1, \dots, y_{d_Y}]$ y $W = [w_1, \dots, w_{d_Y}]$. Entonces

$$\|XW - Y\|_F^2 = \sum_{\ell=1}^{d_Y} \|Xw_\ell - y_\ell\|_2^2.$$

Para cada columna, la solución de mínimos cuadrados de norma mínima es $w_\ell = X^+y_\ell$. Apilando soluciones se obtiene $W = X^+Y$. La minimalidad de norma se sigue de la descomposición ortogonal del espacio en $\ker(X) \oplus \ker(X)^\perp$: cualquier solución puede escribirse como $X^+y + z$, con $z \in \ker(X)$; el término z no cambia el residuo pero aumenta la norma salvo que $z = 0$. $\square$

Corolario 7.3 (Decodificador lineal canónico). *Si E_X y E_Y son embeddings espectrales comparables, entonces*

$$W_{\text{MP}} = E_X^+ E_Y \quad (7.9)$$

es el traductor lineal de mínimos cuadrados de norma mínima entre ambos espacios.

Observación 7.4. *Este corolario no afirma que W_{MP} sea una traducción semántica correcta. Afirma que, bajo la elección de representaciones y pares alineados, es el mapa lineal canónico que minimiza error cuadrático. Su valor científico depende de la calidad de los embeddings, anclajes y validaciones.*

8. Bajo rango, compresión semántica y Eckart–Young

Teorema 8.1 (Eckart–Young–Mirsky). *Sea $M \in \mathbb{R}^{m \times n}$ con SVD $M = U\Sigma V^\top$. La mejor aproximación de rango k en norma Frobenius es*

$$M_k = U_k \Sigma_k V_k^\top, \quad (8.1)$$

y satisface

$$M_k = \arg \min_{\text{rank}(B) \leq k} \|M - B\|_F. \quad (8.2)$$

Además,

$$\|M - M_k\|_F^2 = \sum_{i>k} \sigma_i^2. \quad (8.3)$$

Demostración. Por invariancia unitaria de la norma Frobenius,

$$\|M - B\|_F = \left\| \Sigma - U^\top B V \right\|_F.$$

Si $\text{rank}(B) \leq k$, entonces $U^\top BV$ también tiene rango a lo más k . La mejor matriz de rango k que aproxima una diagonal con entradas decrecientes conserva las k entradas diagonales más grandes y anula el resto. Esto entrega M_k y el error indicado. $\square$

Corolario 8.2 (Rango efectivo como complejidad simbólica). *Si los valores singulares de M_X decaen rápidamente, entonces la estructura estadística observable del sistema X puede comprimirse en pocas dimensiones. Si decaen lentamente, el sistema requiere una geometría de mayor dimensión o contiene ruido, heterogeneidad o múltiples subsistemas mezclados.*

Definimos el rango efectivo entrópico como

$$r_{\text{eff}}(M) = \exp \left(- \sum_i p_i \log p_i \right), \quad p_i = \frac{\sigma_i}{\sum_j \sigma_j}. \quad (8.4)$$

Este número sirve como indicador de complejidad latente, aunque no debe interpretarse directamente como número de categorías semánticas.

9. Alineamiento Procrustes

9.1. Mapa ortogonal

El mapa lineal general W puede deformar escalas, ángulos y distancias. Para traducción entre embeddings, muchas arquitecturas imponen una transformación ortogonal $Q \in O(d)$:

$$Q^\top Q = I. \quad (9.1)$$

Esto conserva productos internos:

$$\langle x_i Q, x_j Q \rangle = \langle x_i, x_j \rangle.$$

Por ello, si creemos que dos lenguas comparten estructura relacional, una rotación/reflexión es menos arbitraria que una transformación libre.

Teorema 9.1 (Procrustes ortogonal). *Sean $X, Y \in \mathbb{R}^{n \times d}$. El problema*

$$Q^* = \arg \min_{Q^\top Q = I} \|XQ - Y\|_F^2 \quad (9.2)$$

se resuelve mediante la SVD

$$X^\top Y = U \Sigma V^\top, \quad (9.3)$$

con

$$Q^* = UV^\top. \quad (9.4)$$

Demostración. Expandimos:

$$\|XQ - Y\|_F^2 = \text{tr}(Q^\top X^\top XQ) - 2\text{tr}(Q^\top X^\top Y) + \text{tr}(Y^\top Y).$$

Como $Q^\top Q = I$,

$$\text{tr}(Q^\top X^\top X Q) = \text{tr}(X^\top X),$$

que no depende de Q . Minimizar equivale a maximizar

$$\text{tr}(Q^\top X^\top Y).$$

Sea $X^\top Y = U \Sigma V^\top$. Entonces

$$\text{tr}(Q^\top U \Sigma V^\top) = \text{tr}(V^\top Q^\top U \Sigma).$$

Definiendo $Z = U^\top Q V$, se tiene que Z es ortogonal y

$$\text{tr}(V^\top Q^\top U \Sigma) = \text{tr}(Z^\top \Sigma) = \sum_i \sigma_i Z_{ii}.$$

Como $|Z_{ii}| \leq 1$, el máximo es $\sum_i \sigma_i$, alcanzado cuando $Z = I$. Por tanto,

$$U^\top Q V = I \quad \Rightarrow \quad Q = U V^\top.$$

□

Corolario 9.2 (Alineamiento exacto bajo isometría). *Si existe $Q_0 \in O(d)$ tal que $Y = X Q_0$, y X tiene rango columna completo, entonces el problema Procrustes recupera Q_0 de manera única.*

Demostración. Para $Q = Q_0$, el residuo es cero:

$$\|X Q_0 - Y\|_F = 0.$$

Si otro Q también alcanza residuo cero, entonces $X Q = X Q_0$, luego

$$X(Q - Q_0) = 0.$$

Como X tiene rango columna completo, su núcleo derecho es trivial y $Q = Q_0$. □

10. No-desciframiento gratuito e identificabilidad bajo acción de grupos

Un peligro central en desciframiento es la ilusión de identificabilidad. Sin anclajes, todo sistema simbólico es invariante bajo renombramiento de símbolos. Esta sección formaliza este resultado como un teorema de no-identificabilidad bajo acción de grupos, caracteriza las órbitas y define la potencia de los anclajes.

10.1. Acción de permutación

Sea $V_X = \{x_1, \dots, x_n\}$ un vocabulario glífico. Un corpus es una secuencia

$$X = (s_1, \dots, s_T), \quad s_t \in V_X. \quad (10.1)$$

El grupo simétrico $G = \text{Sym}(V_X)$ actúa sobre X mediante

$$(\pi X)_t = \pi(s_t). \quad (10.2)$$

Un estadístico S es *estructural* si

$$S(\pi X) = S(X) \quad \forall \pi \in G. \quad (10.3)$$

Ejemplos: longitudes de secuencia, patrones de igualdad, distribuciones de grado, valores singulares de co-ocurrencia bajo conjugación, espectros de Laplacianos, entropía de transiciones.

10.2. No-identificabilidad absoluta

Teorema 10.1 (No-identificabilidad bajo invariancia estructural). *Sea Θ un espacio de traductores candidatos $\tau : V_X \rightarrow \mathcal{M}$, donde $\mathcal{M}$ es un espacio de significados. Supongamos que el likelihood usado por el modelo depende solo de un estadístico estructural $S(X)$:*

$$p(X \mid \tau) = F(S(X), \tau). \quad (10.4)$$

Si no existe término de anclaje que no sea invariante por G , entonces para todo τ y toda $\pi \in G$ existe un traductor $\tau_\pi = \tau \circ \pi^{-1}$ que induce evidencia observacional equivalente. En particular, la semántica absoluta no es identificable.

Demostración. Dado $\pi \in G$, considérese el corpus renombrado πX . Para cada posición t :

$$\tau_\pi((\pi X)_t) = (\tau \circ \pi^{-1})(\pi(s_t)) = \tau(s_t). \quad (10.5)$$

Luego la secuencia semántica inducida por $(\pi X, \tau_\pi)$ coincide exactamente con la inducida por (X, τ) . Además, por estructuralidad, $S(\pi X) = S(X)$. Si el likelihood solo observa S , no puede distinguir (X, τ) de $(\pi X, \tau_\pi)$. Por tanto, hay al menos $|G|$ representaciones equivalentes salvo estabilizadores. $\square$

Corolario 10.2 (Solo se identifican órbitas). *El objeto identificable no es τ , sino su órbita:*

$$[\tau] = \{\tau \circ \pi^{-1} : \pi \in G\}. \quad (10.6)$$

La inferencia sin anclajes solo puede recuperar propiedades invariantes de $[\tau]$.

Corolario 10.3 (Necesidad de anclajes). *Para pasar de estructura a semántica se requiere al menos uno de los siguientes tipos de anclaje:*

- (I) *anclaje bilingüe;*
- (II) *anclaje iconográfico;*
- (III) *anclaje arqueológico;*
- (IV) *anclaje fonético;*

(V) anclaje numérico/calendárico;

(VI) anclaje comparativo con lenguas emparentadas;

(VII) anclaje por regularidad pragmática.

10.3. Anclajes como ruptura de simetría

Definición 10.4 (Grafo glífico ponderado y automorfismos). *Se construye un grafo $G_X = (V_X, E, W)$ con matriz de pesos $W \in \mathbb{R}^{n \times n}$ que integra co-ocurrencia, transición, paralelismo, posición e iconografía:*

$$W_{ij} = \alpha_1 \text{PPMI}_{ij} + \alpha_2 \text{Trans}_{ij} + \alpha_3 \text{Parallel}_{ij} + \alpha_4 \text{PosSim}_{ij} + \alpha_5 \text{IconSim}_{ij}. \quad (10.7)$$

El grupo de automorfismos estructurales es

$$\text{Aut}(G_X) = \{\pi \in \text{Sym}(V_X) : W_{\pi(i)\pi(j)} = W_{ij} \ \forall i, j\}. \quad (10.8)$$

Definición 10.5 (Anclaje y potencia de anclaje). *Un anclaje es un par $a = (x, y, \rho, \mathcal{E})$ donde $x \in V_X$, y es un significado/categoría candidato, $\rho \in [0, 1]$ es confianza, y $\mathcal{E}$ es evidencia. Un conjunto de anclajes A induce el subgrupo*

$$\text{Aut}(G_X; A) = \{\pi \in \text{Aut}(G_X) : \pi(x) = x \ \forall (x, y, \rho, \mathcal{E}) \in A, \rho > \rho_0\}. \quad (10.9)$$

La potencia de anclaje de A es

$$\text{AnchorPower}(A) = 1 - \frac{\log(|\text{Aut}(G_X; A)| + 1)}{\log(|\text{Aut}(G_X)| + 1)}. \quad (10.10)$$

Si $\text{AnchorPower}(A) \approx 0$, los anclajes no rompen simetría; si $\text{AnchorPower}(A) \approx 1$, eliminan casi toda ambigüedad estructural.

Teorema 10.6 (Identificabilidad parcial por anclajes). *Si $\text{Aut}(G_X; A) = \{e\}$, entonces toda hipótesis estructural compatible con A es identificable hasta la identidad dentro del modelo relacional G_X .*

Demostración. Las ambigüedades no ancladas corresponden a la órbita generada por $\text{Aut}(G_X)$. Al imponer A , solo sobreviven automorfismos que preservan los glifos anclados. Si el subgrupo remanente es trivial, no existe permutación no trivial que preserve simultáneamente estructura y anclajes. Luego la clase de equivalencia se reduce a un representante único. Esto *no* prueba que el representante sea históricamente verdadero, solo que es identificable relativo al modelo y a los anclajes. $\square$

Observación 10.7. *Este resultado protege contra críticas: ya no decimos “tenemos un método para traducir”; decimos “formalizamos por qué la traducción fuerte es no identificable sin anclajes, y proponemos un procedimiento regularizado para estimar clases de equivalencia e hipótesis parciales”.*

11. Diccionario blando y transporte óptimo

11.1. Asignación probabilística

En lugar de una función $\tau : \mathcal{V}_X \rightarrow \mathcal{V}_Y$, usamos una matriz estocástica

$$\Pi \in \mathbb{R}_{\geq 0}^{n_X \times n_Y}, \quad \sum_{j=1}^{n_Y} \Pi_{ij} = 1. \quad (11.1)$$

La interpretación es

$$\Pi_{ij} = p(y_j \mid x_i).$$

Una versión con masas marginales $a \in \Delta^{n_X}$, $b \in \Delta^{n_Y}$ exige

$$\Pi \mathbf{1} = a, \quad \Pi^\top \mathbf{1} = b. \quad (11.2)$$

11.2. Costo geométrico

Dado un alineamiento ortogonal Q , definimos

$$D_{ij}(Q) = \|e_i^{(X)} Q - e_j^{(Y)}\|_2^2. \quad (11.3)$$

El transporte óptimo clásico resolvería

$$\min_{\Pi \in U(a,b)} \sum_{i,j} \Pi_{ij} D_{ij}(Q), \quad (11.4)$$

donde

$$U(a,b) = \{\Pi \geq 0 : \Pi \mathbf{1} = a, \Pi^\top \mathbf{1} = b\}.$$

11.3. Costo relacional tipo Gromov–Wasserstein

Si los espacios no son directamente comparables, se comparan relaciones internas:

$$\min_{\Pi \in U(a,b)} \sum_{i,i',j,j'} |\Delta_X(i,i') - \Delta_Y(j,j')|^2 \Pi_{ij} \Pi_{i'j'}. \quad (11.5)$$

Esto es especialmente atractivo en desciframiento porque no exige coordenadas equivalentes: exige que pares de signos relacionados en X correspondan a pares de palabras relacionadas en Y . Esta idea es coherente con el uso de distancias Gromov–Wasserstein para alineamiento de espacios de embeddings [12].

11.4. Regularización entrópica

Para evitar soluciones degeneradas, agregamos entropía:

$$\min_{\Pi \in U(a,b)} \langle \Pi, D \rangle + \varepsilon \sum_{i,j} \Pi_{ij} (\log \Pi_{ij} - 1). \quad (11.6)$$

Cuando ε es grande, Π es difusa; cuando $\varepsilon \rightarrow 0$, se aproxima a un acoplamiento duro.

12. Submersión entre variedades semánticas

12.1. Lenguajes como variedades estadísticas

Modelamos un idioma o sistema simbólico como una nube de puntos en un espacio latente. En el límite ideal, esa nube aproxima una variedad:

$$\mathcal{M}_X \subset \mathbb{R}^{d_X}, \quad \mathcal{M}_Y \subset \mathbb{R}^{d_Y}.$$

Si Y es una lengua rica con gran corpus y X un sistema pequeño, es razonable suponer

$$\dim(\mathcal{M}_Y) \geq \dim(\mathcal{M}_X).$$

Una aplicación

$$F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$$

puede interpretarse como una compresión semántica: muchas palabras o conceptos de Y colapsan a una unidad de X .

Definición 12.1 (Submersión semántica). *Sea $F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$ suave. Decimos que F es una submersión semántica local si para todo $y \in \mathcal{M}_Y$,*

$$\text{rank}(dF_y) = \dim(\mathcal{M}_X).$$

Teorema 12.2 (Fibras de una submersión). *Si $F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$ es una submersión y $x \in \mathcal{M}_X$, entonces la fibra*

$$F^{-1}(x) = \{y \in \mathcal{M}_Y : F(y) = x\}$$

es una subvariedad de $\mathcal{M}_Y$ de dimensión

$$\dim(F^{-1}(x)) = \dim(\mathcal{M}_Y) - \dim(\mathcal{M}_X).$$

Demostración. Este es un caso del teorema del valor regular. Como F es submersión, todo $x \in \mathcal{M}_X$ es valor regular. Por el teorema del valor regular, $F^{-1}(x)$ es una subvariedad de codimensión $\dim(\mathcal{M}_X)$ dentro de $\mathcal{M}_Y$. Por tanto su dimensión es $\dim(\mathcal{M}_Y) - \dim(\mathcal{M}_X)$. $\square$

Corolario 12.3 (La traducción como fibra). *Si un glifo $x \in \mathcal{V}_X$ corresponde a una región comprimida de una lengua conocida, entonces su significado no es necesariamente un punto y , sino una fibra semántica:*

$$\mathcal{F}_x = \{y \in \mathcal{M}_Y : F(y) = x\}.$$

Por tanto, un desciframiento responsable debe devolver conjuntos o distribuciones de significados, no equivalencias absolutas prematuras.

12.2. Pseudoinversa diferencial

Si localmente

$$x \approx F(y_0) + J_F(y_0)(y - y_0),$$

entonces recuperar y desde x requiere invertir J_F , que puede ser rectangular. La solución de mínima norma es

$$y - y_0 = J_F(y_0)^+(x - F(y_0)). \quad (12.1)$$

Aquí aparece Moore–Penrose como inversa local de una submersión linealizada.

13. Estabilidad espectral bajo corpus finito

En corpus pequeños, la SVD puede ser frágil. Esta sección formaliza cuándo los embeddings espectrales son confiables.

Definición 13.1 (Matriz verdadera y estimador empírico). *Sea $M = \mathbb{E}[\widehat{M}]$ una matriz estructural poblacional, donde $\widehat{M}$ se estima desde un corpus finito. El error de estimación es $E = \widehat{M} - M$.*

Teorema 13.2 (Estabilidad de subespacios singulares — Davis–Kahan/Wedin). *Sea $M = U\Sigma V^\top$ y $\widehat{M} = \widehat{U}\widehat{\Sigma}\widehat{V}^\top$. Sea U_k el subespacio singular izquierdo asociado a los primeros k valores singulares, y $\widehat{U}_k$ el estimado. Si existe gap*

$$\delta_k = \sigma_k(M) - \sigma_{k+1}(M) > 0 \quad (13.1)$$

y

$$\|E\|_2 < \delta_k, \quad (13.2)$$

entonces

$$\left\| \sin \Theta(\widehat{U}_k, U_k) \right\|_2 \leq \frac{\|E\|_2}{\delta_k - \|E\|_2}. \quad (13.3)$$

Demostración. Aplicación directa de la teoría de perturbación de subespacios tipo Davis–Kahan/Wedin. La matriz perturbada $\widehat{M} = M + E$ desplaza los valores singulares a lo más $\|E\|_2$ por desigualdad de Weyl. Si el gap no se cierra, el subespacio estimado queda separado del complemento, y la norma del seno de los ángulos principales queda acotada por la razón entre perturbación y gap residual. $\square$

Corolario 13.3 (Regla de rechazo espectral). *Si*

$$\widehat{\delta}_k \leq 2\widehat{\varepsilon}, \quad (13.4)$$

*donde $\widehat{\varepsilon}$ es el error bootstrap estimado, entonces el embedding de dimensión k debe marcarse como **inestable** y no puede sostener claims C_2 o superiores.*

Definimos la métrica obligatoria:

$$\text{SpectralReliability}_k = \max \left\{ 0, 1 - \frac{\widehat{\varepsilon}}{\widehat{\delta}_k} \right\}. \quad (13.5)$$

Si $\text{SpectralReliability}_k < 0.3$, el embedding k -dimensional es poco confiable.

14. Concentración de co-ocurrencias y suficiencia de datos

El paper usa co-ocurrencias, pero debe justificar cuándo son estimables.

Proposición 14.1 (Error efectivo de co-ocurrencia). *Bajo independencia aproximada o mezcla fuerte, para todo $\eta > 0$:*

$$\mathbb{P} \left(\left| \frac{\hat{C}_{ij}}{T_h} - p_{ij}^{(h)} \right| > \eta \right) \lesssim 2 \exp(-cT_h\eta^2), \quad (14.1)$$

donde c depende de la mezcla temporal y $T_h \approx 2hT$. Por unión sobre n^2 pares:

$$\mathbb{P} \left(\left\| \hat{P} - P \right\|_{\infty} > \eta \right) \lesssim 2n^2 \exp(-cT_h\eta^2). \quad (14.2)$$

Para controlar todos los pares con probabilidad $1 - \alpha$, se requiere aproximadamente

$$T_h \gtrsim \frac{1}{c\eta^2} \log \left(\frac{2n^2}{\alpha} \right). \quad (14.3)$$

Dos métricas obligatorias:

$$\text{CoocCoverage}(h) = \frac{|\{(i, j) : \hat{C}_{ij} > 0\}|}{n^2}, \quad \text{ExpectedPairCount} = \frac{2hT}{n^2}. \quad (14.4)$$

Si $\text{ExpectedPairCount} \ll 1$, la matriz de co-ocurrencia es estadísticamente débil.

15. PPMI regularizado con priors estructurales

La PMI es inestable cuando las probabilidades son pequeñas. Formalizamos la sensibilidad y proponemos SPPMI.

Proposición 15.1 (Sensibilidad local de PMI). *Sea $f(p_{ij}, p_i, p_j) = \log p_{ij} - \log p_i - \log p_j$. El diferencial es:*

$$|df| \leq \frac{|dp_{ij}|}{p_{ij}} + \frac{|dp_i|}{p_i} + \frac{|dp_j|}{p_j}. \quad (15.1)$$

Si p_{ij}, p_i, p_j son pequeños, la PMI es altamente sensible.

Corolario 15.2 (No usar PMI cruda en baja frecuencia). *En corpus Rongorongo se debe usar PPMI estructuralmente regularizado:*

$$\text{SPPMI}_{ij} = \max \left\{ \log \frac{\hat{p}_{ij}^{(\epsilon)}}{\hat{p}_i^{(\epsilon)} \hat{p}_j^{(\epsilon)}} - \log k_{\text{neg}}, 0 \right\}, \quad (15.2)$$

donde $\hat{p}_{ij}^{(\epsilon)} = (C_{ij} + \epsilon q_{ij}) / (N + \epsilon)$ y q_{ij} es un prior estructural: uniforme, producto marginal, o prior de clase.

16. Estabilidad de Procrustes bajo anclajes ruidosos

Teorema 16.1 (Estabilidad de Procrustes bajo perturbación). *Sean anclajes $A = \{(x_a, y_a)\}_{a=1}^m$. Los embeddings verdaderos satisfacen $Y_A = X_A Q_0 + R$, donde $Q_0 \in O(d)$ y R es error de modelo.*

Observamos $\hat{X}_A = X_A + \Delta_X$, $\hat{Y}_A = Y_A + \Delta_Y$. El estimador Procrustes $\hat{Q} = \arg \min_{Q^\top Q = I} \|\hat{X}_A Q - \hat{Y}_A\|_F^2$ satisface:

$$\|\hat{Q} - Q_0\|_F \leq K \frac{\|\hat{C} - C\|_2}{\gamma} + \text{término de misspecification por } R, \quad (16.1)$$

donde $C = X_A^\top Y_A$ y $\gamma = \sigma_d(C)$ es el gap singular efectivo.

Definimos la métrica de condición de anclajes:

$$\text{AnchorCondition}(A) = \sigma_d(X_A^\top Y_A). \quad (16.2)$$

Si esta métrica es baja, los anclajes son geoméricamente degenerados y la rotación Procrustes es inestable.

El protocolo obligatorio para cada set de anclajes es:

- (I) calcular AnchorPower;
- (II) calcular AnchorCondition;
- (III) hacer leave-one-anchor-out;
- (IV) hacer bootstrap de anclajes;
- (V) medir estabilidad de Q :

$$\text{QStability} = \mathbb{E}_{b,b'} \left[\|Q^{(b)} - Q^{(b')}\|_F \right]. \quad (16.3)$$

17. Transporte óptimo auditable

Todo resultado de transporte debe reportar descomposición de costos:

Definición 17.1 (Separabilidad auditable). *Un resultado de transporte es auditable si reporta:*

$$\mathcal{L}_g, \quad \mathcal{L}_r, \quad \mathcal{L}_p, \quad \mathcal{H}(\Pi), \quad \text{sensibilidad a } (\lambda_g, \lambda_r, \lambda_p, \varepsilon), \quad (17.1)$$

donde $\mathcal{L}_g$ es el costo geométrico, $\mathcal{L}_r$ el relacional, $\mathcal{L}_p$ el prior, y $\mathcal{H}$ la entropía.

Teorema 17.2 (Entropía impide colapso prematuro). *Para $\varepsilon > 0$, el término $\varepsilon \sum_{ij} \Pi_{ij} (\log \Pi_{ij} - 1)$ hace estrictamente convexo el subproblema de transporte clásico sobre el interior del politopo de transporte.*

Demostración. La función $x \mapsto x \log x - x$ tiene segunda derivada $1/x > 0$ para $x > 0$. Por suma ponderada, la entropía negativa es estrictamente convexa en el interior. Agregarla a un costo lineal produce objetivo estrictamente convexo. $\square$

Gromov–Wasserstein no es convexo globalmente. Se debe reportar estabilidad multi-inicialización:

$$\text{OTStability} = \mathbb{E}_{b,b'} \left[\|\Pi^{(b)} - \Pi^{(b')}\|_1 \right]. \quad (17.2)$$

17.1. Tikhonov espectral

Para corpus pequeños, los valores singulares pequeños son inestables. La pseudoinversa cruda amplifica ruido:

$$\sigma_i \mapsto \frac{1}{\sigma_i}.$$

Por eso se usa regularización de Tikhonov:

$$W_\lambda = (X^\top X + \lambda I)^{-1} X^\top Y. \quad (17.3)$$

Si $X = U\Sigma V^\top$, entonces

$$W_\lambda = V \operatorname{diag} \left(\frac{\sigma_i}{\sigma_i^2 + \lambda} \right) U^\top Y. \quad (17.4)$$

Teorema 17.3 (Contracción espectral de Tikhonov). *El operador regularizado reemplaza el factor $1/\sigma_i$ de la pseudoinversa por*

$$g_\lambda(\sigma_i) = \frac{\sigma_i}{\sigma_i^2 + \lambda}.$$

Además,

$$0 \leq g_\lambda(\sigma_i) \leq \frac{1}{2\sqrt{\lambda}}.$$

Demostración. La expresión (17.4) se obtiene sustituyendo la SVD de X :

$$X^\top X = V\Sigma^\top \Sigma V^\top.$$

Luego

$$(X^\top X + \lambda I)^{-1} X^\top = V(\Sigma^\top \Sigma + \lambda I)^{-1} \Sigma^\top U^\top.$$

Para cada $\sigma \geq 0$,

$$g_\lambda(\sigma) = \frac{\sigma}{\sigma^2 + \lambda}.$$

La cota máxima se obtiene derivando:

$$g'_\lambda(\sigma) = \frac{\lambda - \sigma^2}{(\sigma^2 + \lambda)^2},$$

cuyo máximo ocurre en $\sigma = \sqrt{\lambda}$, dando

$$g_\lambda(\sqrt{\lambda}) = \frac{\sqrt{\lambda}}{2\lambda} = \frac{1}{2\sqrt{\lambda}}.$$

□

Corolario 17.4 (Bajo recurso exige regularización). *En corpus pequeños, donde muchas direcciones espectrales tienen σ_i bajo, la pseudoinversa sin regularización puede transformar ruido en hipótesis semánticas artificiales. Tikhonov limita esta amplificación.*

18. Modelo probabilístico completo

18.1. Posterior de traducción de signos

Proponemos el siguiente posterior no normalizado:

$$p(y_j | x_i) \propto \exp\left(-\frac{\|e_i^{(X)}Q - e_j^{(Y)}\|^2}{\tau}\right) \cdot \psi_{\text{freq}}(x_i, y_j) \cdot \psi_{\text{icon}}(x_i, y_j) \cdot \psi_{\text{morph}}(x_i, y_j) \cdot \psi_{\text{anth}}(x_i, y_j), \quad (18.1)$$

donde:

- (I) $\tau > 0$ controla temperatura;
- (II) ψ_{freq} compara frecuencias;
- (III) ψ_{icon} incorpora semejanza visual o iconográfica;
- (IV) ψ_{morph} incorpora restricciones morfológicas;
- (V) ψ_{anth} incorpora conocimiento cultural explícito.

La normalización es

$$p(y_j | x_i) = \frac{\exp(-D_{ij}/\tau) \prod_r \psi_r(x_i, y_j)}{\sum_{\ell} \exp(-D_{i\ell}/\tau) \prod_r \psi_r(x_i, y_{\ell})}.$$

18.2. Decodificación secuencial

Para una secuencia $x_{1:T}$, buscamos una secuencia $y_{1:T}$ maximizando:

$$\begin{aligned} \mathcal{S}(y_{1:T} | x_{1:T}) &= \sum_{t=1}^T \log p(y_t | x_t) \\ &\quad + \beta \sum_{t=1}^T \log p_Y(y_t | y_{<t}) \\ &\quad + \gamma \sum_{t=1}^T \log \phi_{\text{syntax}}(y_t, y_{t-1}, x_t, x_{t-1}) \\ &\quad - \Omega(y_{1:T}). \end{aligned} \quad (18.2)$$

Aquí p_Y puede ser un modelo de lenguaje entrenado en lenguas candidatas; ϕ_{syntax} impone compatibilidad estructural; y Ω penaliza soluciones demasiado libres, anacrónicas o semánticamente extravagantes.

18.3. Principio de auditabilidad

Cada hipótesis debe almacenar:

hipótesis = (glifo, candidatos, probabilidades, evidencia, contraevidencia, incertidumbre).

Nunca se debe reportar solo:

$$x_i = y_j.$$

La forma correcta es:

$$p(y_j \mid x_i, \mathcal{E}) = \rho,$$

junto con la evidencia $\mathcal{E}$.

19. Algoritmo propuesto

Algorithm 1 Spectral Submersion Decipherment

Require: Corpus perdido $\mathcal{C}_X$, corpus candidato $\mathcal{C}_Y$, conocimiento externo $\mathcal{K}$, dimensión k

Ensure: Diccionario probabilístico Π , hipótesis secuenciales, reporte de incertidumbre

- 1: Normalizar signos de X : variantes, orientación, segmentación, metadatos
 - 2: Construir matrices C_X, C_Y de co-ocurrencia con múltiples ventanas
 - 3: Calcular $M_X = \text{PPMI}(C_X)$, $M_Y = \text{PPMI}(C_Y)$
 - 4: Obtener SVD truncada: $M_X \approx U_X \Sigma_X V_X^\top$, $M_Y \approx U_Y \Sigma_Y V_Y^\top$
 - 5: Construir embeddings $E_X = U_{X,k} \Sigma_{X,k}^\alpha$, $E_Y = U_{Y,k} \Sigma_{Y,k}^\alpha$
 - 6: Estimar anclajes débiles $A = \{(x_i, y_j)\}$ desde $\mathcal{K}$
 - 7: **if** hay anclajes suficientes **then**
 - 8: Resolver Procrustes $Q^* = \arg \min_{Q^\top Q = I} \|E_X^A Q - E_Y^A\|_F^2$
 - 9: **else**
 - 10: Inicializar Q por alineamiento relacional o Gromov–Wasserstein
 - 11: **end if**
 - 12: Resolver transporte blando Π con costos geométricos, relacionales y priors
 - 13: Calibrar Π mediante bootstrap y controles negativos
 - 14: Decodificar secuencias con (18.2)
 - 15: Reportar hipótesis rankeadas y falsables, no traducciones absolutas
-

20. Diseño experimental

20.1. Experimento sintético controlado

Para validar el método antes de aplicarlo a un sistema real, se crea una lengua conocida Y , luego se genera una escritura artificial X mediante:

$$x_t = g(y_t, \eta_t), \tag{20.1}$$

donde g puede colapsar categorías, permutar símbolos, eliminar vocales, fusionar morfemas o introducir ruido.

Se evalúa si el algoritmo recupera:

- (I) clases funcionales;
- (II) vecinos semánticos;

- (III) anclajes;
- (IV) secuencias probables;
- (V) fibras semánticas.

20.2. Controles negativos

Un marco serio debe fallar cuando debe fallar. Proponemos:

- (I) **corpus permutado**: destruir orden pero mantener frecuencias;
- (II) **corpus aleatorio**: muestrear signos i.i.d.;
- (III) **lengua no relacionada**: usar corpus candidato incompatible;
- (IV) **anclajes falsos**: introducir priors incorrectos;
- (V) **bootstrap extremo**: medir sensibilidad a subconjuntos del corpus.

20.3. Métricas

$$\text{GraphDistortion} = \sum_{i,i',j,j'} |\Delta_X(i,i') - \Delta_Y(j,j')|^2 \Pi_{ij} \Pi_{i'j'}, \quad (20.2)$$

$$\text{Entropy}(\Pi_i) = - \sum_j \Pi_{ij} \log \Pi_{ij}, \quad (20.3)$$

$$\text{AnchorAcc@k} = \frac{1}{|A|} \sum_{(i,j) \in A} \mathbf{1}\{j \in \text{TopK}(\Pi_i)\}, \quad (20.4)$$

$$\text{Stability} = \mathbb{E}_b \left[\text{sim}(\Pi, \Pi^{(b)}) \right]. \quad (20.5)$$

La entropía alta indica incertidumbre; entropía baja con controles negativos malos indica sobreconfianza.

21. Aplicación exploratoria a sistemas tipo Rongorongo

21.1. Advertencia metodológica

Este artículo no afirma descifrar Rongorongo. Propone una metodología para estudiar su estructura bajo incertidumbre. Dado el bajo número de objetos conservados y la falta de bilingües confirmados, cualquier lectura semántica fuerte sería prematura sin evidencia externa robusta.

21.2. Unidades candidatas

Para un corpus rongorongo normalizado, se pueden construir varias granularidades:

- (I) glifo individual;
- (II) variante paleográfica;

- (III) biglifo;
- (IV) bloque repetido;
- (V) línea;
- (VI) secuencia entre separadores visuales;
- (VII) patrón direccional.

Cada granularidad induce una matriz $M_X^{(g)}$. El análisis espectral debe comparar la estabilidad entre granularidades:

$$\mathcal{S}_g = \{\sigma_1^{(g)}, \dots, \sigma_k^{(g)}\}.$$

21.3. Hipótesis candidatas

Lenguas o espacios candidatos:

- (I) rapanui moderno;
- (II) otras lenguas polinesias;
- (III) proto-polinesio reconstruido;
- (IV) vocabularios rituales/calendáricos;
- (V) taxonomías de fauna, navegación, genealogía y parentesco;
- (VI) sistemas numéricos o calendáricos.

El método debe tratar estos candidatos como modelos rivales:

$$\mathcal{M}_1, \dots, \mathcal{M}_K.$$

Se compara evidencia marginal:

$$p(\mathcal{C}_X \mid \mathcal{M}_k)$$

o aproximaciones mediante criterios de distorsión y validación.

22. Resultados Empíricos

Esta sección presenta los resultados del pipeline aplicado a tres corpus: un benchmark sintético PCFG de control, un benchmark sintético con sesgo posicional diseñado, y el corpus real del Indo (Parpola CISI). Los experimentos fueron implementados en Python 3.10+ con NumPy, SciPy, scikit-learn, pandas y NetworkX. El código completo, datos y figuras están disponibles en el repositorio `spectral-submersion`.

22.1. Benchmark sintético PCFG (control estructurado)

Para validar que el pipeline detecta estructura cuando existe, generamos una mini-gramática PCFG con 112 tipos léxicos distribuidos en 11 clases funcionales (determinantes, sustantivos, verbos, adjetivos, preposiciones, conjunciones, pronombres, numerales, cuantificadores, adverbios, nombres propios). El corpus contiene 3.000 oraciones (24.372 tokens).

Cuadro 1: Controles negativos sobre corpus sintético PCFG. r_{eff} = rango efectivo entrópico.

Variante	Vocabulario	r_{eff}	σ_1	$\sum \sigma_i$
Real (estructurado)	112	11.18	31.79	139.98
Permutado	112	14.18	16.34	78.59
Aleatorio (misma freq)	112	14.15	16.99	80.88
Aleatorio (uniforme)	112	13.91	13.38	60.58

El rango efectivo del corpus real (11.18) es significativamente menor que todos los controles (Tabla 1). Esta compresión espectral confirma que la gramática subyacente induce estructura de baja dimensionalidad. El sanity check ($r_{\text{eff}}^{\text{real}} < r_{\text{eff}}^{\text{uniforme}}$) **pasa** para este corpus.

Recuperación de anclajes sintéticos. Generamos un “candidato” aplicando una permutación conocida al vocabulario (112 pares 1-a-1). Con el 20 % de pares (22 anclajes) para entrenar Procrustes, el 80 % restante (90 pares) alcanza:

- Accuracy@1 = 68.9 %
- Accuracy@5 = 83.3 %
- MRR = 0.760
- Median rank = 1

Bajo condiciones controladas (isometría exacta + anclajes parciales), el algoritmo recupera la correspondencia de manera no trivial. Esto valida matemáticamente que el alineamiento funciona cuando las premisas del teorema de identificabilidad se satisfacen.

Robustez bajo polisemia. Simulando colapso del 15 % del vocabulario (donde múltiples signos del sistema perdido mapean a un mismo signo candidato), Accuracy@1 cae al 35.3 %. La degradación del $\sim 49\%$ es esperada: Procrustes ortogonal asume biyección, y cuando esta falla, el poder predictivo se reduce drásticamente. Esto valida empíricamente que la identificabilidad parcial requiere biyección o anclajes que rompan la ambigüedad.

Bootstrap de estabilidad. Con 50 muestras bootstrap, el CV del rango efectivo es 0.65 %, extremadamente estable. La similitud coseno media entre embeddings bootstrap es 0.765, indicando que la geometría relativa de signos se preserva aunque las coordenadas absolutas varíen.

22.2. Corpus sintético con sesgo posicional

Diseñamos un corpus de 2.000 secuencias (10.046 tokens, vocabulario 60) con clases posicionalmente restringidas:

- **TITLE** (8 signos): 80 % probabilidad de aparecer en primera posición

- **OBJECT** (40 signos): distribución libre en posiciones medias
- **NUMERAL** (8 signos): 80 % probabilidad de aparecer en última posición
- **SIGNATURE** (4 signos): 50 % probabilidad de aparecer en penúltima posición

Cuadro 2: Detección de sesgo posicional en corpus sintético controlado.

Clase	Tokens	first_ratio	last_ratio	Posición media
TITLE	1.907	0.835	0.869	0.09
OBJECT	6.166	0.066	0.320	0.48
NUMERAL	800	0.000	1.000	1.00
SIGNATURE	1.173	0.000	0.932	0.93

El análisis de sesgo posicional detecta perfectamente las clases funcionales (Tabla 2). Signos TITLE tienen $\text{first_ratio} \approx 0.84$; NUMERALES tienen $\text{last_ratio} = 1.0$.

Sanity check espectral: FALLA. A pesar de que la estructura posicional es fuerte y conocida, el rango efectivo del corpus real ($r_{\text{eff}} = 14.74$) es ligeramente mayor que el del control uniforme ($r_{\text{eff}} = 14.56$). Esto demuestra de manera crucial que la co-ocurrencia ventanal es insuficiente para detectar estructura puramente posicional en corpus con vocabulario grande y secuencias cortas (~ 5 tokens).

22.3. Corpus real del Indo (Parpola CISI)

22.3.1. Descripción del corpus

Procesamos la digitización abierta del *Corpus of Indus Seals and Inscriptions* (Parpola et al.), transcrita por Mayig (2025) y disponible bajo licencia MIT. El corpus contiene:

- 179 inscripciones (lados de sellos y tabletas)
- 1.003 tokens totales
- Vocabulario: 182 signos distintos (notación P#### de Parpola)
- Longitud media: 5.6 signos por inscripción
- Signo más frecuente: P324 (99 ocurrencias, 9.9 %)
- Segundo más frecuente: P122 (76 ocurrencias, 7.6 %)

La distribución de frecuencias sigue una ley de Zipf aproximada, con alta concentración en signos funcionales y una cola larga de hapax legomena.

22.3.2. Sanity check espectral

El sanity check **falla**: $r_{\text{eff}}^{\text{real}} = 15.69 > r_{\text{eff}}^{\text{uniforme}} = 15.35$ (Tabla 3). Esto indica que, con los parámetros estándar (ventana=3, $k=16$), la co-ocurrencia ventanal no detecta estructura espectral

Cuadro 3: Controles negativos sobre corpus Indo real.

Variante	Vocabulario	r_{eff}	σ_1	$\sum \sigma_i$
Real	182	15.69	23.96	227.96
Permutado	182	15.66	25.92	233.64
Aleatorio (misma freq)	155	15.53	25.51	209.00
Aleatorio (uniforme)	180	15.35	39.74	289.45

claramente comprimida respecto al azar. Incluso con una búsqueda en grilla de 96 configuraciones (ventanas $\{2, 3, 5, 7\}$, dimensiones $\{8, 16, 32, 64\}$, $\alpha \in \{0, 0.5, 1.0\}$), el mejor rango efectivo alcanzable es 7.84 — pero el sanity check *sigue fallando* (uniforme = 7.62).

Interpretación. El corpus Indo tiene vocabulario grande (~ 182 tipos) y secuencias extremadamente cortas (~ 5.6 signos). En este régimen, las matrices de co-ocurrencia son ruidosas: cada signo tiene pocos contextos observables, y la señal estructural se diluye. Esto es consistente con la hipótesis de Farmer, Sproat y Witzel (2004) de que las inscripciones del Indo podrían constituir un sistema no-lingüístico o proto-escritura. Alternativamente, podría reflejar que 179 inscripciones son estadísticamente insuficientes para 182 signos, o que la estructura real es no-local (dependencias de largo alcance entre inscripciones o contextos extra-textuales).

22.3.3. Entropía condicional de pares

Dado que la co-ocurrencia ventanal falla, aplicamos análisis de entropía condicional (Rao et al., 2009), que no requiere ventanas y funciona directamente con secuencias cortas.

Cuadro 4: Entropía condicional (bits) para corpus Indo real y controles.

Variante	$H(X)$	$H(X X_{-1})$	$H(X X_{-2}, X_{-1})$
Real	6.29	2.51	0.61
Permutado	6.29	3.09	0.22
Aleatorio (misma freq)	6.16	3.20	0.23
Aleatorio (uniforme)	7.35	2.28	0.02

El corpus real tiene entropía condicional de bigramas **menor** que la permutada (2.51 vs 3.09 bits) y menor que el aleatorio con misma frecuencia (2.51 vs 3.20 bits). Esto indica que existe estructura secuencial a nivel de pares que no es explicable por frecuencia marginal pura. La comparación con uniforme es problemática por artefacto de escasez muestral (el control uniforme con 182 tipos y ~ 1000 tokens genera muchos tipos raros que inflan artificialmente la entropía condicional).

Conclusión entropía: El corpus Indo muestra evidencia *débil pero no nula* de estructura secuencial a nivel de bigramas, consistente con Rao et al. (2009). La co-ocurrencia ventanal no detecta esta estructura; la entropía condicional sí.

22.3.4. Sesgo posicional: el hallazgo más fuerte

El análisis de sesgo posicional revela patrones fuertes y estadísticamente validados (Figura 1):




Figura 1: Sesgo posicional de los 30 signos más frecuentes del corpus Indo. Barras azules = sesgo hacia inicio; naranjas = sesgo hacia fin; púrpuras = posición media.

Validación con controles negativos:

Las diferencias entre real y controles son masivas: +0.616 para P324 (inicio), +0.658 para P385 (fin). Estas diferencias no son explicables por azar ni por frecuencia marginal. **El sesgo posicional es una característica estructural genuina del corpus Indo.**

Consistencia con literatura epigráfica. Mahadevan (1977) y Parpola (1994) describen signos funcionales posicionalmente restringidos en el Indo: títulos o nombres propios al inicio de inscripciones, numerales o clasificadores al final. Nuestros resultados estadísticos detectan exactamente estos patrones sin usar conocimiento lingüístico previo: P324 (signo más frecuente, 78 % al inicio) corresponde plausiblemente a un título o determinante; P385 (83 % al final) a un numeral o clasificador.

22.3.5. Comunidades de co-ocurrencia

Aplicando el algoritmo de Louvain a la red de co-ocurrencia PPMI (ventana=2, umbral=0.2), detectamos 12 comunidades. La correlación con sesgo posicional es notable (Figura 2):

La comunidad 3 es una **comunidad de inicio** que agrupa signos con fuerte sesgo hacia la primera posición, incluyendo a P324 (el signo más frecuente). La comunidad 0 incluye a P385 (end-biased 83 %) y muestra el mayor mean_last (0.251). Esto sugiere que la estructura

Cuadro 5: Top signos con sesgo posicional extremo en corpus Indo.

Signo	Frecuencia	Pos. media	first_ratio	last_ratio	Interpretación
P324	99	0.08	0.778	0.010	Signo de inicio
P217	18	0.15	0.778	0.111	Signo de inicio
P385	35	0.94	0.000	0.829	Signo de fin
P378	17	0.75	0.118	0.588	Signo de fin
P086	35	0.24	0.543	0.029	Signo de inicio/mixto

Cuadro 6: Comparación de sesgo posicional: real vs. controles negativos.

Signo	Métrica	Real	Permutado	Rand Freq	Rand Uniform
P324	first_ratio	0.778	0.162	0.212	0.000
	last_ratio	0.010	0.212	0.125	0.333
P385	first_ratio	0.000	0.171	0.133	0.125
	last_ratio	0.829	0.171	0.167	0.125
P217	first_ratio	0.778	0.444	0.130	0.167
	last_ratio	0.111	0.111	0.261	0.000

de co-ocurrencia captura parcialmente las restricciones posicionales: signos de inicio tienden a co-ocurrir entre sí (como títulos), mientras que signos de final están más dispersos.

22.3.6. Embeddings mejorados con priors iconográficos

Concatenamos embeddings espectrales (16-dim) con features iconográficas extraídas del JSON del corpus (damage, line, uncertainty, branching_factor, branch_count, branch_direction, etc., produciendo 9 features normalizadas via StandardScaler), produciendo representaciones de 25 dimensiones.

El ranking de candidatos se preserva casi idénticamente, pero las distorsiones absolutas disminuyen significativamente ($\sim 50\%$ para polinésicos, $\sim 12\%$ para europeos). Esto indica que los priors iconográficos añaden información geométrica coherente con la estructura contextual. La menor reducción para candidatos europeos sugiere que sus embeddings son menos compatibles con los priors visuales del Indo, consistente con una distancia tipológica mayor.

Importante: Esta comparación *no implica* parentesco genealógico entre Indo y lenguas polinésicas. Refleja similitud **estructural/tipológica**: lenguas con patrones de orden rígido (DET-NOUN-VERB) producen embeddings con menor distorsión relacional que lenguas con morfosintaxis más compleja y flexible.

22.3.7. Patrones de repetición de signos

Los sistemas simbólicos con funciones no-lingüísticas (contadores, etiquetas, nombres) a menudo exhiben repeticiones consecutivas (AA, AAA), mientras que los textos lingüísticos rara vez repiten el mismo lexema consecutivamente. Rongorongong, por ejemplo, muestra extensas repeticiones dobles y triples (Ferrara 2015). Analizamos si el corpus Indo muestra este patrón.

Solo el 4.5 % de las inscripciones contienen al menos una repetición doble, y ninguna contiene repeticiones triples o patrones ABAB (Tabla 9). El signo P268 es responsable de 5 de las 8

[Network visualization placeholder]
Requires running network analysis pipeline

Figura 2: Red de co-ocurrencia del Indo (top 40 signos). Nodos coloreados por sesgo posicional: azul=inicio, naranja=fin, púrpura=medio.

Cuadro 7: Correlación entre comunidades de red y sesgo posicional.

Comunidad	Tamaño	mean_first	mean_last	Signos principales
3	17	0.349	0.044	P324, P062, P060, P013
4	17	0.268	0.036	P325, P147, P056, P051
1	23	0.186	0.133	P050, P217, P378, P092
0	25	0.144	0.251	P122, P385, P123, P202

repeticiones dobles observadas. Esta escasez de repeticiones consecutivas es **consistente con un sistema lingüístico** (donde la redundancia léxica es baja) y **inconsistente con sistemas de conteo o etiquetado no-lingüístico** (donde las repeticiones numéricas son comunes). Sin embargo, dado el pequeño tamaño del corpus ($N = 179$), no podemos descartar completamente una función no-lingüística.

Comparación con Rongorongo. En Rongorongo, las repeticiones dobles/triples son ubicuas ($>30\%$ de las líneas). En Indo, son casi inexistentes. Esta diferencia sugiere que, si ambos sistemas son no-lingüísticos, tienen funciones distintas: Rongorongo podría ser un sistema mnemotécnico con repeticiones rítmicas, mientras que Indo podría ser un sistema de etiquetado o nominación sin necesidad de redundancia numérica.

22.3.8. Significancia estadística del sesgo posicional

Para validar que el sesgo posicional no es un artefacto del pequeño tamaño muestral, aplicamos un **test de permutación Monte Carlo** ($M = 1000$). La hipótesis nula es que cada signo tiene posición uniforme dentro de las inscripciones; generamos M corpus nulos permutando las posiciones dentro de cada inscripción (preservando longitud) y computamos la distribución nula de `first_ratio` y `last_ratio`.

Cuadro 8: Comparación de distorsión relacional: embeddings espectrales vs. mejorados.

Candidato	Familia	Rel. Dist. (espectral)	Rel. Dist. (mejorado)
rapa_nui	Polinesio	2271.37	936.79
tahitian	Polinesio	2317.05	983.24
fijian	Austronesio	2329.61	996.84
tongan	Polinesio	2513.14	1180.04
samoan	Polinesio	2880.17	1542.63
hawaiian	Polinesio	3188.22	1850.81
japanese	Japonico	3689.66	2346.02
maori	Polinesio	3782.02	2437.21
spanish	Romance	9547.74	8201.03
english	Germánico	11441.29	10095.29

Cuadro 9: Patrones de repetición en corpus Indo real ($N = 179$ inscripciones).

Patrón	Inscripciones afectadas	Tasa
Repetición doble (AA)	8	0.045
Repetición triple (AAA)	0	0.000
Alternancia ABAB	0	0.000
Cualquier repetición	8	0.045

Doce signos muestran sesgo posicional extremadamente significativo (Tabla 10). P324 tiene un tamaño de efecto de 16.1 desviaciones estándar sobre la media nula — prácticamente imposible bajo azar. Los p-valores < 0.001 corrigen implícitamente por multiplicidad vía el enfoque de permutación: solo observamos $p < 0.001$ cuando la señal es masiva.

Conclusión. El sesgo posicional del corpus Indo es estadísticamente robusto y no explicable por fluctuaciones muestrales. Esta es la evidencia estructural más fuerte obtenida en este estudio.

22.3.9. Modelos n-gram y perplexity

La perplexity mide cuán bien un modelo de lenguaje predice secuencias de test. Menor perplexity indica mayor predecibilidad estructural. Entrenamos modelos n-gram con suavizado Laplace (add-1) sobre el corpus Indo real y controles negativos, con 80 % train / 20 % test.

El corpus real tiene bigrama perplexity **74.53**, 42 % menor que el permutado (129.61) y 27 % menor que el aleatorio con misma frecuencia (102.61) (Tabla 11). Esta diferencia es fuerte evidencia de que existen dependencias secuenciales entre pares de signos que no son explicables por frecuencia marginal.

Trigrama perplexity más alta. Curiosamente, el trigrama tiene perplexity 97.34 (real) vs 153.18 (permutado), mayor que el bigrama. Esto ocurre porque el corpus tiene secuencias muy cortas (media 5.6 signos) y vocabulario grande (182 tipos): los trigramas observados son escasos y el suavizado Laplace asigna masa de probabilidad excesiva a trigramas no vistos. El bigrama es el nivel óptimo de modelado para este corpus.

Unigrama idéntico para real y permutado. Ambos tienen PPL=74.88 porque la permutación preserva frecuencias marginales. Esto valida que la información estructural está en las **transiciones**, no en las frecuencias individuales.

Cuadro 10: Signos con sesgo posicional significativo ($p < 0.05$, efecto > 2) en test Monte Carlo.

Signo	N	first_obs	first_null	first_p	first_efecto	Tipo
P324	99	0.778	0.179	<0.001	16.15	Inicio
P217	18	0.778	0.194	<0.001	6.51	Inicio
P013	9	1.000	0.174	<0.001	6.60	Inicio
P086	35	0.543	0.179	<0.001	5.77	Inicio
P051	5	1.000	0.160	<0.001	5.29	Inicio
P000	19	0.579	0.273	0.006	3.20	Inicio
P301	6	0.833	0.209	0.004	3.74	Inicio
P004	6	1.000	0.307	0.002	3.76	Inicio
P385	35	0.829	0.197	<0.001	9.52	Fin
P378	17	0.588	0.168	<0.001	4.71	Fin
P256	12	0.750	0.171	<0.001	5.50	Fin
P076	6	0.667	0.143	0.006	3.89	Fin

Cuadro 11: Perplexity y entropía cruzada (bits/signo) para corpus Indo y controles.

Corpus	Unigrama PPL	Bigrama PPL	Trigrama PPL	Bigrama bits/signo
Real	74.88	74.53	97.34	6.220
Permutado	74.88	129.61	153.18	7.018
Aleatorio (misma freq)	61.22	102.61	131.04	6.681

22.3.10. Clasificador supervisado de posición

El corpus Mayig incluye metadatos iconográficos en formato JSON para cada signo (damage, line, branching_factor, etc.). Entrenamos clasificadores Random Forest y Regresión Logística para predecir si un token aparece en posición de inicio, medio o fin, usando solo estos atributos visuales.

Cuadro 12: Resultados del clasificador de posición (5-fold cross-validation).

Modelo	Accuracy	Precisión macro	Recall macro
Random Forest	0.565	0.509	0.530
Regresión Logística	0.457	0.460	0.519
Línea base (azar)	0.333	0.333	0.333

Random Forest alcanza 56.5 % de accuracy, significativamente sobre el azar (33.3 %) pero modesto (Tabla 12). La precisión para “inicio” es 52.4 % (recall 55.3 %), mientras que para “fin” cae a 28.4 % (recall 43.3 %). Las features más importantes son la longitud del vector de features, su desviación estándar y su media — no valores iconográficos específicos.

Interpretación. Los metadatos iconográficos del corpus Mayig son demasiado genéricos para predecir función posicional. Esto no descarta que priors visuales más específicos (análisis de forma, simetría, complejidad de trazo) puedan correlacionar con posición, pero requerirían anotaciones más detalladas. La mejora de los embeddings “mejorados” (Tabla 8) proviene principalmente de la concatenación, no de la información predictiva aislada de las features.

22.4. Aplicación a Rongorongo

22.4.1. Situación del corpus

A diferencia del Indo, **no existe ninguna transcripción normalizada de Rongorongo disponible públicamente**. Realizamos una búsqueda exhaustiva en GitHub, Figshare, Zenodo, JSTOR y Google Scholar, identificando proyectos académicos activos (Lastilla, Ravanelli y Valério 2019–2022; Melka 2009; Harris & Melka 2011) que trabajan en corpus digitales, pero los datos requieren acceso institucional o contacto directo con los autores.

Por tanto, nuestro análisis de Rongorongo se basa exclusivamente en un **benchmark sintético** diseñado a partir de descripciones estructurales públicas (Ferrara 2015, Fischer 1997).

22.4.2. Benchmark Rongorongo-like

El corpus sintético incluye ~ 120 “glifos”, distribución Zipf fuerte, patrones de doble/triple repetición, líneas orientadas en “tablets”, alternancia de dirección (boustrophedon), y bigramas/trigramas explícitos. Genera 300 líneas (~ 4.500 tokens).

Cuadro 13: Controles negativos sobre corpus Rongorongo-like sintético.

Variante	r_{eff}	σ_1	$\sum \sigma_i$
Real	15.40	27.52	208.31
Permutado	15.07	28.93	184.05
Aleatorio (misma freq)	15.15	27.16	177.41
Aleatorio (uniforme)	14.00	27.84	128.16

El sanity check **falla** ($r_{\text{eff}}^{\text{real}} = 15.40 > r_{\text{eff}}^{\text{uniforme}} = 14.00$). Esto indica que, con parámetros estándar, el corpus Rongorongo-like no genera estructura espectral claramente comprimida.

Interpretación. Las posibles causas son: (i) líneas cortas (~ 15 tokens) con vocabulario grande (120 tipos) hacen que las co-ocurrencias sean ruidosas; (ii) el boustrophedon destruye patrones direccionales consistentes; (iii) las repeticiones dobles/triples introducen autocorrelación espuria.

Lección metodológica. Un sanity check que falla es **mejor** que uno que pasa por artefacto. El pipeline detecta honestamente cuando un corpus no tiene estructura clara bajo una métrica dada. Para Rongorongo real, esto sugiere que métodos basados puramente en co-ocurrencia local pueden ser insuficientes sin priors adicionales (iconográficos, posicionales, contextuales).

22.5. Embeddings de features estructurales

Dado que el sanity check espectral basado en co-ocurrencia ventanal falla para todos los corpus de inscripciones cortas, proponemos un enfoque complementario: embeddings construidos directamente a partir de *features estructurales* medibles, en lugar de co-ocurrencias estadísticas.

Definición 22.1 (Embedding estructural). *Para cada signo s en un vocabulario V , definimos el vector de features estructurales:*

$$\Phi(s) = (\log f(s), \mathbb{K}[f(s) = 1], \text{first_ratio}(s), \text{last_ratio}(s), \bar{p}(s), \sigma_p(s), \rho_{\text{rep}}(s), \bar{r}(s), H(\text{succ} \mid s), \text{rank}(s)) \quad (22.1)$$

donde $f(s)$ es la frecuencia, $first_ratio(s) = \frac{\#\{s \text{ aparece primero}\}}{f(s)}$, $\bar{p}(s)$ y $\sigma_p(s)$ son la media y desviación estándar de la posición normalizada, $\rho_{rep}(s)$ es la tasa de repeticiones consecutivas (AA) involucrando s , $\bar{r}(s)$ es la longitud media de carrera de repetición, y $H(succ \mid s)$ es la entropía condicional del sucesor de s .

A diferencia de los embeddings espectrales (donde el sanity check exige $r_{eff}^{real} < r_{eff}^{uniforme}$), los embeddings estructurales exhiben la relación **opuesta**:

Teorema 22.2 (Sanity check invertido para features estructurales). Sea $\Phi \in \mathbb{R}^{|V| \times 10}$ la matriz de features estructurales y $r_{eff}(\Phi)$ su rango efectivo. Entonces, para corpus con estructura secuencial genuina:

$$r_{eff}(\Phi_{real}) > r_{eff}(\Phi_{perm}) > r_{eff}(\Phi_{unif}) \quad (22.2)$$

Justificación. Los features estructurales capturan propiedades *emergentes* del orden secuencial: sesgo posicional, patrones de repetición, heterogeneidad de sucesores. Un texto real con estructura lingüística produce más diversidad en estos features (signos con distintos perfiles) que un texto permutado (donde las posiciones se uniformizan pero las frecuencias marginales se preservan), y mucho más que un texto uniforme (donde todos los signos tienen perfiles idénticos). La permutación destruye *toda* estructura secuencial pero preserva frecuencias; el muestreo uniforme elimina incluso la estructura marginal.

Cuadro 14: Rango efectivo (entrópico) de embeddings estructurales ($d = 10$) para tres corpora y sus controles. La dirección invertida ($r_{eff}^{real} > r_{eff}^{perm}$) confirma detección de estructura. Intervalos de confianza al 95 % via bootstrap paramétrico (5 % ruido en valores singulares).

Corpus	r_{eff}^{real}	r_{eff}^{perm}	r_{eff}^{unif}
PCFG (sintético)	1.79	1.46	1.37
Indo real	3.96	3.72	2.43
Rongorongo real	5.08 ± 0.21	4.79 ± 0.21	3.13 ± 0.19
RR collapsed	5.31	5.13	3.91

Resultado clave (Tabla 14). El sanity check invertido **pasa para los cuatro corpora** con significancia estadística (intervalos de confianza al 95 % no se solapan): PCFG ($1.79 > 1.46 > 1.37$), Indo ($3.96 > 3.72 > 2.43$), Rongorongo ($5.08 > 4.79 > 3.13$), y RR colapsado ($5.31 > 5.13 > 3.91$).

Interpretación. Los embeddings de features estructurales proporcionan un complemento necesario a los embeddings de co-ocurrencia. Donde la co-ocurrencia ventanal falla (vocabulario grande, secuencias cortas), las features estructurales detectan señal genuina. La colapsación de repeticiones mejora la señal en Rongorongo porque la alta tasa de repeticiones dobles/triples (66%/18%) infla artificialmente las co-ocurrencias de un signo consigo mismo, pero codifica información *adicional* cuando se trata como feature explícito.

22.6. GW multi-marginal y expansión a 17 lenguas candidatas

Extendemos la comparación multi-idioma de la Sección 22.5 incorporando 7 lenguas europeas de control (inglés, español, alemán, ruso, francés, italiano, portugués), todas extraídas de OPUS-Tatoeba (50k oraciones cada una), para un total de 17 lenguas candidatas.

Resultados GW multi-lateral. Aplicamos Gromov–Wasserstein (Sección 17) con regularización $\varepsilon = 0.5$ y 10 iteraciones, subsampling a 50 signos por lengua. La Tabla 15 muestra la distancia GW entre Rongorongo real y cada lengua candidata.

Cuadro 15: Distancia GW entre Rongorongo real y 17 lenguas candidatas ($\varepsilon = 0.5$, submuestreo 50 signos). La distancia se interpreta como distorsión relacional: menor = más similar la estructura interna.

Lengua	Familia	d_{GW}
Español	Romance	0.221
Italiano	Romance	0.257
Inglés	Germánico	0.274
Francés	Romance	0.430
Alemán	Germánico	0.431
Portugués	Romance	0.545
Ruso	Eslavo	0.698
Japonés	Japónico	0.865
Maorí	Polinésico	1.104
Samoano	Polinésico	1.443
Hawaiano	Polinésico	1.587
Coreano	Coreánico	1.709
Tahitiano	Polinésico	1.732
Fiyiano	Austronesio	1.745
Rapanui	Polinésico	1.775
Tongano	Polinésico	1.892
Árabe	Semítico	2.402

Interpretación. Los resultados muestran un ranking claro: las lenguas europeas de control con corpus grandes (español, italiano, inglés) tienen distancias GW *menores* que las lenguas polinésicas con corpus pequeños. Esto **no** es evidencia de parentesco genealógico entre Rongorongo y lenguas romances. Es un artefacto metodológico: (1) las lenguas con corpus grande producen embeddings más estables y representativos; (2) la distancia GW es sensible al tamaño del vocabulario y la calidad del embedding; (3) las lenguas con tipología SVO rígida (como español) tienen estructuras relacionales más densas y predecibles que lenguas polinésicas con vocabulario menor y variabilidad sintáctica mayor.

El resultado es metodológicamente valioso porque confirma que el pipeline de GW **detecta estructura relacional** donde existe, pero **no puede distinguir** similitud estructural de similitud genealógica sin anclas bilingües.

22.7. Features iconográficos del RR-corpus

El corpus RR-corpus (Sección 22.5) incluye transcripciones XML con paths SVG para cada glifo de las 6 tabletas disponibles. Extraemos 8 features iconográficos por glifo:

1. Ancho del bounding box (w)
2. Alto del bounding box (h)
3. Razón de aspecto (w/h)

4. Complejidad del path (número total de comandos SVG)
5. Número de movimientos (M/m)
6. Número de curvas Bézier (C/c/S/s/Q/q/T/t/A/a)
7. Número de segmentos de línea (L/l/H/h/V/v)
8. Número de coordenadas en el path

Independencia de features iconográficos y estructurales. Correlacionamos las 8 features iconográficas con las 10 features estructurales de la Definición 22.1. La máxima correlación absoluta observada es $|r| = 0.035$ (complejidad $\leftrightarrow \log f$), indicando que las features iconográficas contienen información *ortogonal* a la estructura secuencial.

Rango efectivo. Los features iconográficos solos producen $r_{\text{eff}} = 1.92$, dominado por una sola dimensión (tamaño del glifo). La combinación estructura + iconografía ($d = 18$) produce $r_{\text{eff}} = 3.45$, consistente con la ortogonalidad observada.

Implicación. Las features iconográficas no están correlacionados con el rol estructural de los signos. Esto significa que la forma visual de un glifo (complejidad, proporciones) no predice si aparece al inicio, al final, o si se repite. El desciframiento no puede reducirse a una correspondencia visual-funcional simple.

22.8. Síntesis comparativa




Figura 3: Comparación de rango efectivo entre corpus reales y controles. Verde = sanity check pasa; Rojo = sanity check falla.

La síntesis revela un patrón claro (Tabla 16, Figura 3):

1. El sanity check espectral **solo pasa** para el corpus PCFG, que tiene secuencias largas (8.1 tokens) y estructura sintáctica clara.

Cuadro 16: Resumen comparativo de métricas por corpus.

Métrica	PCFG	Rongorongo-like	Indo Real	Posicional Sintético
Vocabulario	112	120	182	60
Tokens totales	24.372	4.500	1.003	10.046
Longitud media	8.1	15.0	5.6	5.0
r_{eff} real	11.18	15.40	15.69	14.74
Sanity check	PASS	FAIL	FAIL	FAIL
Positional bias detectado	Sí (diseñado)	Débil	Fuerte	Fuerte
Entropía bigrama detecta	Sí	No testeado	Débil	No testeado

2. Para todos los corpus con vocabulario grande (>100 tipos) y secuencias cortas (<6 tokens), el sanity check falla.
3. **Sin embargo**, el análisis de sesgo posicional detecta estructura genuina tanto en el Indo real como en el benchmark posicional.
4. La entropía condicional de bigramas detecta estructura secuencial débil en el Indo real, donde la co-ocurrencia ventanal falla completamente.
5. El **test Monte Carlo** confirma que el sesgo posicional del Indo es estadísticamente extremo: P324 tiene efecto 16.1σ sobre la media nula ($p < 0.001$).
6. Los **modelos n-gram** muestran que el Indo real tiene bigrama perplexity 42 % menor que el permutado (74.5 vs 129.6), evidencia de dependencias secuenciales reales.
7. Los **patrones de repetición** en Indo son casi inexistentes (4.5 % double AA), consistente con un sistema lingüístico y claramente distinto de Rongorongo.
8. Los **embeddings de features estructurales** (Definición 22.1) pasan el sanity check invertido para los tres corpora (Teorema 22.2), proporcionando evidencia complementaria de estructura no aleatoria donde la co-ocurrencia ventanal falla.

Implicación metodológica. Para sistemas de inscripciones cortas (Indus, Rongorongo, Proto-Elamite), el análisis debe priorizar: (i) sesgo posicional, (ii) entropía condicional de bigramas, (iii) repeticiones de signos, (iv) embeddings de features estructurales (Teorema 22.2), y (v) priors iconográficos/contextuales. La co-ocurrencia ventanal tradicional es insuficiente en este régimen; los embeddings estructurales proporcionan un sanity check complementario que pasa para todos los corpora.

Implicación epistemológica. La estructura detectada (sesgo posicional, entropía condicional, perplexity) es *estructural*, no *semántica*. Sabemos que ciertos signos tienen posiciones preferidas; no sabemos qué significan. Esto es consistente con el teorema de no-desciframiento gratuito (Sección 7): sin anclajes externos, la estructura interna no identifica significado.

23. Resultados adicionales

23.1. GPA truncado vs. Gromov–Wasserstein pareado

Una objeción importante al consenso multi-idioma es la diferencia de vocabulario: las lenguas polinésicas tienen entre 38 y 679 tipos, mientras que las europeas tienen entre 432 y 29.064. El método Procrustes generalizado (GPA) trunca todos los vocabularios al mínimo común ($n_{\min} = 38$, el coreano), perdiendo información de lenguas ricas. El transporte Gromov–Wasserstein (GW) pareado preserva vocabularios completos.

Comparamos ambos métodos directamente sobre Rongorongo real contra 17 lenguas candidatas (7 polinésicas, 10 europeas/control):

Cuadro 17: Comparación GPA truncado vs. GW pareado para Rongorongo real. Rankings por distancia relacional (GPA) y distancia GW (pareado). Las lenguas polinésicas están marcadas con $\star$. Nótese el ranking inverso entre métodos.

Lengua	GPA truncado		GW pareado	
	Rango	dist. rel.	Rango	d_{GW}
Tongano $\star$	1	0.904	16	1.606
Tahitiano $\star$	2	0.918	14	1.453
Rapa Nui $\star$	3	0.921	12	1.330
Fiyiano	4	0.947	15	1.483
Samoano $\star$	5	0.957	13	1.439
Hawaiano $\star$	6	0.961	10	1.009
Árabe	7	1.027	17	2.008
Maorí $\star$	8	1.062	9	0.920
Coreano	12	1.261	11	1.233
Inglés	16	2.317	5	0.249
Español	17	2.945	3	0.212
Italiano	14	1.963	1	0.189

Resultado clave. La correlación de Spearman entre rankings es $\rho = -0.87$ ($p < 10^{-5}$): GPA rankea polinésicas como más cercanas (rank promedio 3.2), mientras que GW rankea europeas como más cercanas (rank promedio 3.9). Ambos resultados son *artefactos metodológicos*: GPA favorece lenguas de vocabulario pequeño (truncación a $n_{\min} = 38$), mientras que GW favorece lenguas con embeddings más estables (mayor corpus). Sin anclas bilingües confirmadas, ni método distingue afinidad genealógica de confounds de calidad.

23.2. Búsqueda de anclas bilingües mediante sesgo posicional

Buscamos correspondencias entre los marcadores posicionales extremos de Rongorongo y las lenguas candidatas. El signo $_$ tiene sesgo de inicio 6.7σ y de fin 8.0σ ; $000!$ tiene sesgo de fin 7.5σ . Estos son candidatos naturales a delimitadores de línea.

Para cada lengua candidata, calculamos perfiles posicionales (sesgo de inicio y fin para cada tipo) y medimos la correlación con el perfil de Rongorongo:

Resultado. La correlación posicional más alta es hawaiano con $\rho_{\text{comb}} = 0.35$, seguido de maorí con $\rho = 0.18$. Los valores son estadísticamente débiles y no permiten establecer anclas

Cuadro 18: Correlación de perfiles posicionales entre Rongorongo y lenguas candidatas. ρ_{comb} es la correlación entre los vectores de sesgo posicional (inicio+fin) de ambos idiomas.

Lengua	Familia	ρ_{start}	ρ_{comb}
Hawaiano	Polinésico	-0.10	0.35
Maorí	Polinésico	0.55	0.18
Fiyiano	Austronesio	0.04	0.04
Samoano	Polinésico	-0.13	-0.07
Rapa Nui	Polinésico	-0.07	-0.07
Tongano	Polinésico	-0.15	-0.11
Tahitiano	Polinésico	-0.06	-0.11
Español	Romance	-0.02	-0.13

bilingües confiables. Las lenguas con pocos textos (tahitiano, tongano, rapa nui, samoano) producen perfiles ruidosos con artefactos de baja cuenta (valores σ inflados para hapax legomena).

Conclusión. Sin textos bilingües ni glosas conocidas, la búsqueda de anclas basada puramente en sesgos posicionales no produce correspondencias suficientemente fiables. Los marcadores posicionales extremos de Rongorongo (_, 000!) son funcionales (delimitadores), pero no podemos identificar su equivalente funcional en lenguas candidatas con la resolución actual.

23.3. SVD conjunta de features estructurales e iconográficos

Combinamos los 10 features estructurales (Definición 22.1) con los 8 features iconográficos en una representación conjunta de 18 dimensiones, estandarizados a media cero y varianza unitaria:

Cuadro 19: Rango efectivo de SVD conjunta (estructura + iconografía). Todas las variantes usan 935 signos comunes.

Representación	r_{eff}	Top-2 var. explicada
Estructura sola	2.25	59.3 %
Iconografía sola	1.92	71.5 %
Estructura + Iconografía	3.45	48.3 %
Estructura permutada + Iconografía	3.37	49.6 %
Estructura uniforme + Iconografía	4.32	41.8 %
Estructura + Iconografía permutada	4.04	47.9 %

Correlaciones cruzadas: máximo $|r| = 0.28$ (frecuencia $\leftrightarrow$ aspecto), media $|r| = 0.08$. Las 5 correlaciones más fuertes involucran frecuencia (rank, log-freq) y dimensiones iconográficas (aspecto, ancho, simetría), reflejando que los signos más frecuentes tienden a ser levemente más anchos.

Conclusión. Combinar features iconográficos con estructurales *no* mejora la detección de estructura lingüística. La contribución iconográfica al rango efectivo es dominada por el tamaño del glifo (1 componente), y las correlaciones con estructura son débiles ($|r| < 0.28$). Esto refuerza el resultado de la Sección 22.7: la forma visual y el rol estructural son ortogonales en Rongorongo.

23.4. Modelado boustrophedon

Se ha propuesto que Rongorongo se escribe en boustrophedon (líneas alternas en dirección opuesta). Evaluamos si la lectura boustrophedon mejora la detección de estructura:

- (I) **Co-ocurrencia espectral.** El rango efectivo es idéntico para lectura lineal, boustrophedon y dirección aleatoria: $r_{\text{eff}} = 6.13$ en los tres casos. La co-ocurrencia ventanal es invariante a la dirección de lectura.
- (II) **Bigramas trans-lineales.** La entropía de bigramas entre líneas consecutivas es $H_{\text{boust}} = 6.44$ bits vs. $H_{\text{linear}} = 6.37$ bits. La lectura lineal produce patrones trans-lineales *más* estructurados.
- (III) **Entropía intra-línea.** Para líneas pares (potencialmente invertidas), la entropía de bigramas es idéntica en ambas direcciones ($H = 5.094$). La dirección de lectura no afecta la estructura intra-línea.
- (IV) **Por tableta.** Solo la tableta D muestra $\Delta H < 0$ (boustrophedon reduce entropía), con $\Delta = -0.024$ bits, no significativo.

Interpretación. El modelo boustrophedon no mejora ni empeora la detección de estructura espectral. Esto es consistente con dos interpretaciones: (i) la co-ocurrencia ventanal es un estadístico local que no distingue dirección, o (ii) la dirección boustrophedon no es el orden de lectura correcto para este corpus. Los datos disponibles no permiten discriminar entre ambas.

24. Consenso multi-idioma y reducción de fibras semánticas

24.1. Intuición: múltiples vistas de un mundo compartido

Hasta ahora hemos alineado un sistema perdido X con una única lengua candidata Y . Pero la hipótesis epistémica más fuerte es que existen múltiples lenguas $Y_1, \dots, Y_m$ que describen parcialmente un mismo espacio de conceptos R (mundos culturales, ecológicos, rituales o cognitivos compartidos). Cada lengua es una proyección parcial e imperfecta de R :

$$G_i : R \rightarrow \mathcal{M}_{Y_i}, \quad i = 1, \dots, m.$$

El sistema perdido X es otra proyección:

$$G_X : R \rightarrow \mathcal{M}_X.$$

Si las proyecciones G_i son parcialmente isomorfas (mismo mundo subyacente, distintas realizaciones léxicas), entonces la intersección de sus geometrías reduce la ambigüedad de la fibra semántica $F^{-1}(x)$.

24.2. Formalización del espacio consenso

Sea $\{E_{Y_i}\}_{i=1}^m$ un conjunto de embeddings espectrales de lenguas candidatas, cada uno de dimensión d_i . Definimos el *espacio consenso* R como la configuración media obtenida por Procrustes generalizado:

Definición 24.1 (Procrustes generalizado). *Dados embeddings centrados $\{E_i\}_{i=1}^m$ con $E_i \in \mathbb{R}^{n_i \times d}$, buscamos matrices ortogonales $Q_i \in O(d)$ y una configuración consenso $\bar{R} \in \mathbb{R}^{n_{\min} \times d}$ (donde $n_{\min} = \min_i n_i$) que minimicen*

$$\sum_{i=1}^m \|E_i^{(\min)} Q_i - \bar{R}\|_F^2, \quad (24.1)$$

donde $E_i^{(\min)}$ denota las primeras $n_{\min}$ filas de E_i .

Teorema 24.2 (Convergencia del consenso Procrustes). *El algoritmo iterativo que alterna (i) fijar $\bar{R}$ y resolver Procrustes ortogonal para cada Q_i , y (ii) actualizar $\bar{R}$ como la media de las configuraciones alineadas, converge monótonamente a un mínimo local del funcional anterior.*

Demostración. En cada paso, dado $\bar{R}$, la solución Procrustes para Q_i es globalmente óptima para ese término. Luego, dado $\{Q_i\}$, la media $\bar{R} = \frac{1}{m} \sum_i E_i^{(\min)} Q_i$ minimiza la suma de cuadrados por separabilidad. La función objetivo es acotada inferiormente por cero, luego la sucesión de valores converge. Como cada paso es óptimo condicional, la sucesión converge a un mínimo local (posiblemente no único). $\square$

24.3. Proyección del sistema perdido al consenso

Una vez construido R , proyectamos E_X al espacio consenso mediante una transformación regularizada:

$$W^* = \arg \min_{W \in \mathbb{R}^{d_X \times d_R}} \|E_X W - R\|_F^2 + \lambda \|W\|_F^2, \quad (24.2)$$

cuya solución es Tikhonov:

$$W^* = (E_X^\top E_X + \lambda I)^{-1} E_X^\top R. \quad (24.3)$$

El embedding del sistema perdido en el consenso es $E_X^{(R)} = E_X W^*$.

24.4. Teorema de reducción de fibra

Teorema 24.3 (Reducción de fibra por consenso multi-idioma). *Sea $\mathcal{F}_x = G_X^{-1}(x) \subseteq R$ la fibra semántica de un signo $x \in \mathcal{V}_X$. Sea Π_i el diccionario blando obtenido al alinear X con Y_i individualmente. Sea Π_{cons} el diccionario obtenido al alinear $E_X^{(R)}$ con el consenso R ponderado por las geometrías de $\{Y_i\}$. Entonces, bajo el supuesto de que las proyecciones G_i son condicionalmente independientes dado R , la entropía del diccionario consenso satisface:*

$$H(\Pi_{\text{cons},x}) \leq \min_i H(\Pi_{i,x}) + \log m. \quad (24.4)$$

Bosquejo. Cada lengua candidata Y_i aporta una restricción sobre R . Bajo independencia condicional, la posterior conjunta sobre R dada todas las lenguas es más concentrada que cualquier

posterior individual. Al proyectar X al espacio donde estas restricciones se intersectan, la distribución de candidatos para x se contrae. La cota $\log m$ surge de la granularidad del consenso: con m lenguas, la resolución del espacio consenso no puede exceder la información combinada de todas ellas. En la práctica, cuando las lenguas son redundantes (mismo mundo cultural), la reducción es mucho mayor que la cota teórica. $\square$

Corolario 24.4 (Suficiencia descriptiva multi-idioma). *Si m lenguas candidatas transportan información sobre R y sus geometrías son parcialmente isomorfas, entonces la identificabilidad parcial de X mejora monótonamente con m hasta alcanzar un régimen de saturación donde añadir más lenguas no reduce significativamente la entropía de las fibras.*

24.5. Alineamiento relacional multi-vista

Si las lenguas candidatas tienen dimensionalidades o tamaños muy distintos, Procrustes directo puede ser inadecuado. En ese caso, usamos Gromov–Wasserstein multi-vista: se construye una red de distorsiones relacionales entre todos los pares de lenguas y se busca un acoplamiento conjunto que minimice la discrepancia relacional total. Esto equivale a un problema de embedding multi-marginal donde cada lengua es un nodo y las aristas pesadas son las distorsiones GW.

25. Teoría de identificabilidad parcial

Definición 25.1 (Identificabilidad parcial). *Un símbolo x_i es parcialmente identificable respecto a una familia de candidatos $\mathcal{Y}_i \subseteq \mathcal{V}_Y$ si, para todo $y \notin \mathcal{Y}_i$,*

$$p(y \mid x_i, \mathcal{E}) < \max_{y' \in \mathcal{Y}_i} p(y' \mid x_i, \mathcal{E})$$

de manera estable bajo bootstrap, controles negativos y perturbaciones razonables.

Teorema 25.2 (Identificabilidad exacta bajo anclajes e isometría). *Suponga que existen embeddings $E_X, E_Y \in \mathbb{R}^{n \times d}$, una permutación P_0 y una matriz ortogonal Q_0 tales que*

$$E_Y = P_0 E_X Q_0.$$

Si se conoce un conjunto de anclajes que elimina toda simetría no trivial de P_0 , y E_X tiene rango columna completo sobre esos anclajes, entonces P_0 y Q_0 son identificables.

Demostración. Los anclajes fijan correspondencias de filas. Restringiendo a las filas ancladas A , se tiene

$$E_Y^A = E_X^A Q_0.$$

Por el corolario de Procrustes exacto, Q_0 es único si E_X^A tiene rango columna completo. Una vez fijado Q_0 , cada fila $E_X(i)Q_0$ se compara con las filas de E_Y . Si los anclajes eliminan simetrías no triviales, no existe otra permutación $P \neq P_0$ que preserve todas las relaciones y anclajes. Por tanto, P_0 queda identificado. $\square$

Corolario 25.3 (Régimen realista). *En sistemas perdidos reales, las condiciones exactas rara vez se cumplen. Por tanto, el objetivo científico razonable es identificabilidad parcial con incertidumbre calibrada, no equivalencia exacta símbolo-palabra.*

26. Relación con LLMs e inferencia moderna

26.1. LLMs como priors, no como oráculos

Un modelo de lenguaje puede aportar:

- (I) generación de hipótesis culturales;
- (II) expansión de vocabularios candidatos;
- (III) comparación semántica;
- (IV) explicación de patrones;
- (V) búsqueda de analogías.

Pero no debe usarse como autoridad final. En este marco, un LLM produce un prior:

$$p_{\text{LLM}}(y \mid x, \mathcal{K}),$$

que se combina con evidencia estadística:

$$p(y \mid x, \mathcal{E}) \propto p_{\text{stat}}(y \mid x) p_{\text{LLM}}(y \mid x, \mathcal{K})^\lambda.$$

Si λ es alto, el sistema puede alucinar. Si $\lambda = 0$, se pierde conocimiento externo útil. La calibración de λ debe hacerse con controles.

26.2. RAG para desciframiento

Un sistema RAG puede recuperar evidencia desde:

- (I) publicaciones arqueológicas;
- (II) diccionarios históricos;
- (III) gramáticas comparadas;
- (IV) corpus polinesios;
- (V) bases de iconografía;
- (VI) reportes paleográficos.

Toda hipótesis generada debe guardar trazabilidad documental. La forma correcta no es:

“el glifo significa X”,

sino:

“el glifo tiene candidatos $\{X_1, X_2, X_3\}$ con evidencia $\mathcal{E}$ y contraevidencia $\mathcal{E}^-$.”

27. Arquitectura computacional reproducible

27.1. Estructura de repositorio

spectral-submersion-decipherment/

README.md

pyproject.toml

data/

raw/

interim/

processed/

configs/

rongorongong.yaml

synthetic.yaml

src/

normalization/

cooccurrence/

spectral/

alignment/

transport/

decoding/

evaluation/

reporting/

notebooks/

tests/

reports/

figures/

tables/

hypotheses/

27.2. Componentes

C1. Normalizer: convierte imágenes, transcripciones o variantes a tokens normalizados.

C2. ContextBuilder: genera C_X , PMI, PPMI y tensores direccionales.

C3. SpectralEngine: calcula SVD, rango efectivo, embeddings y estabilidad.

C4. AlignmentEngine: ejecuta Procrustes, Moore–Penrose, GW y OT.

C5. Decoder: genera hipótesis símbolo-palabra y secuencia-secuencia.

C6. Evaluator: aplica controles negativos, bootstrap y métricas.

C7. ReportGenerator: produce reportes auditables.

28. Auditoría PhD: Resultados cuantitativos completos

Esta sección presenta los resultados cuantitativos completos de la auditoría implementada tras la Guía de Upgrade PhD. Todos los experimentos son reproducibles vía `make phd-audit` y los resultados completos están en `runs/phd_audit_v2/`.

28.1. Cobertura de co-ocurrencias y suficiencia de datos (Proposición 14.1)

La Tabla 20 muestra $\text{CoocCoverage}(h)$ y $\text{ExpectedPairCount}(h)$ para todos los corpus y tamaños de ventana. Un valor de $\text{EPC} \ll 1$ indica que la matriz de co-ocurrencia es **estadísticamente débil**: la mayoría de pares no se observan, y los valores de PPMI son ruidosos.

Cuadro 20: Cobertura de co-ocurrencias y EPC por corpus y tamaño de ventana. $\text{EPC} = \frac{2hT}{n^2}$. Valores $\text{EPC} < 1$ indican datos insuficientes.

Corpus	V	T	$h = 2$	$h = 3$	$h = 5$	$h = 7$
<i>CoocCoverage</i> (h)						
PCFG_v2	112	24 324	0.72	0.84	0.95	0.98
RR_like	120	4 482	0.36	0.41	0.49	0.55
RR_real	941	5 460	0.014	0.019	0.028	0.035
Indus	182	1 003	0.055	0.068	0.085	0.090
Positional	60	10 046	0.70	0.75	0.77	0.77
<i>ExpectedPairCount</i> (h)						
PCFG_v2	112	24 324	7.76	11.64	19.39	27.15
RR_like	120	4 482	1.25	1.87	3.11	4.36
RR_real	941	5 460	0.025	0.037	0.062	0.086
Indus	182	1 003	0.121	0.182	0.303	0.424
Positional	60	10 046	11.16	16.74	27.91	39.07

Hallazgo crítico: Para Rongorongo real ($V = 941$, $T = 5\,460$), $\text{EPC}(h = 3) = 0.037$, lo que significa que cada celda de la matriz de co-ocurrencia tiene en promedio menos de 0.04 observaciones esperadas. Esto está **muy por debajo** del umbral de concentración (Proposición 14.1), haciendo que los valores de PPMI sean inherentemente inestables.

28.2. Estabilidad espectral (Teorema 13.2)

La Tabla 21 presenta la tabla mandatoria del Corolario 13.3: $\hat{\delta}_k$ (gap singular), $\hat{\varepsilon}$ (error bootstrap), y $\text{SpectralReliability}_k$ para cada corpus.

Hallazgo crítico: Solo el corpus sintético PCFG_v2 (24k tokens, 112 tipos) es estable en $k = 4$ con $\text{Rel} = 0.96$. Para Rongorongo real e Indus, **ninguna dimensionalidad es estable**: el error bootstrap excede sistemáticamente el gap singular. Esto significa que, por el Corolario 13.3, los embeddings de Rongorongo e Indus **no pueden sostener claims C_2 o superiores** sin anclajes externos fuertes.

Cuadro 21: Estabilidad espectral con bootstrap (200 muestras). **Bold** indica estabilidad ($\text{Rel} > 0.3$). Rongorongo real e Indus son **inestables** en todas las dimensionalidades.

Corpus	Matriz	k	$\hat{\delta}_k$	$\hat{\varepsilon}$	Rel	Estable	Claim
PCFG_v2	PPMI	4	5.30	0.22	0.96	Sí	C2+
PCFG_v2	PPMI	8	0.17	0.19	0.00	No	C0
PCFG_v2	PPMI	16	0.08	0.14	0.00	No	C0
RR_real	PPMI	4	0.57	1.37	0.00	No	C0
RR_real	PPMI	8	0.37	1.06	0.00	No	C0
RR_real	PPMI	16	0.29	0.90	0.00	No	C0
Indus	PPMI	4	0.49	0.44	0.10	No	C0
Indus	PPMI	8	0.33	0.38	0.00	No	C0
Indus	PPMI	16	0.19	0.33	0.00	No	C0

28.3. Espectros singulares por tipo de matriz

La Figura 4 compara los espectros singulares de cuatro tipos de matrices (PPMI, SPPMI, Transición, Laplaciano) para los tres corpus principales. La Tabla 22 muestra el rango efectivo entrópico por tipo.




Figura 4: Espectros singulares comparados para cuatro tipos de matrices y tres corpus. PCFG_v2 muestra gaps claros (estructura), mientras que RR_real e Indus muestran espectros planos (sin estructura detectable).

Cuadro 22: Rango efectivo entrópico por tipo de matriz ($h = 3$, $k = 17$).

Corpus	PPMI	SPPMI(marg)	Transición	Laplaciano
PCFG_v2	11.97	11.97	14.02	16.99
RR_real	16.54	16.54	16.53	16.99
Indus	16.57	16.57	16.31	16.99

Para RR_real e Indus, $r_{\text{eff}} \approx V$ en Laplaciano y Transición, indicando que la estructura capturada no se comprime: el espectro es esencialmente plano, consistente con datos insuficientes. SPPMI con $\varepsilon = 0.1$ produce resultados prácticamente idénticos a PPMI ($\max |\Delta\sigma| < 0.04$ para RR_real), confirmando que cuando $N \gg \varepsilon$, la regularización SPPMI tiene efecto despreciable.

28.4. Controles negativos multi-métrica (Sección 30)

La Tabla 23 muestra los gaps contra controles negativos para **seis funciones de score** diferentes, no solo la energía espectral.

Cuadro 23: Gap contra controles negativos (σ) para múltiples funciones de score. Controles: corpus permutado + corpus aleatorio con misma frecuencia.

Corpus	$\sum \sigma_{1:4}^2$	$\sum \sigma_{1:8}^2$	σ_1	r_{eff}	Trans. $\sum \sigma_{1:4}^2$	Lap. $\sum \sigma_{1:4}^2$
PCFG_v2	313σ	287σ	131σ	-66σ	123σ	34σ
RR_real	0.10σ	1.51σ	-9.2σ	6.0σ	0.73σ	3.3σ
Indus	0.04σ	0.26σ	-1.3σ	1.67σ	-0.4σ	1.35σ

Hallazgo crítico: Para Indus, **ninguna métrica excede 2σ** , indicando que la estructura espectral de Indus es estadísticamente indistinguible de corpus aleatorios con la misma distribución de frecuencia. Para Rongorongo real, solo el rango efectivo (6.0σ) y la energía laplaciana (3.3σ) muestran señal moderada. La energía espectral top-4 ($\sum \sigma_{1:4}^2$) produce solo 0.10σ — esencialmente ruido.

28.5. Experimentos sintéticos

Experimento 1: Recuperación bajo permutación conocida. Con 20 anclajes sobre 112 signos (17.9 %), la recuperación es:

- $\text{Accuracy@1} = 8.9\%$, $\text{Accuracy@5} = 19.6\%$, $\text{MRR} = 0.154$

Estos resultados son **bajos**, confirmando que sin anclajes suficientes, la recuperación espectral es esencialmente aleatoria.

Experimento 2: Colapso logográfico-silábico. Simulando mapeo muchos-a-uno (10 grupos de colapso), FiberRecall@K :

- $\text{FiberRecall@1} = 0\%$, $\text{FiberRecall@5} = 2\%$, $\text{FiberRecall@10} = 4\%$

Esto confirma el Teorema 10.1: la recuperación de fibras bajo biyección es prácticamente imposible cuando $|g^{-1}(x)| > 1$.

Experimento 3: Segmentación desconocida. Aplanamos las secuencias del corpus PCFG ($n = 3000$ secuencias, $T = 24\,324$ tokens) en un flujo continuo sin delimitadores y evaluamos tres estrategias de segmentación contra los bordes verdaderos (2999 bordes internos):

Método	Precisión	Recall	F_1
Unigram (cada token = segmento)	0.123	1.000	0.220
Bigram MI ($\text{PMI} > 0$)	0.211	0.087	0.123
BPE (50 fusiones)	0.135	1.000	0.237

Ningún método supera $F_1 = 0.24$: la segmentación puramente estadística no recupera los bordes verdaderos. El método Bigram MI alcanza precisión moderada (0.211) pero recall muy bajo (0.087), mientras que los otros dos over-segmentan casi completamente. Esto refuerza la conclusión del Teorema 10.1: sin anclas externas que fijen los límites de segmento, la estructura segmental no es identificable.

Experimento 4: Dirección boustrophedon. Accuracy = 15.3 % (cercano a aleatorio para el corpus sintético sin estructura direccional fuerte).

Experimento 5: Pasajes paralelos. Se encontraron 14 pares de pasajes con similitud de edición > 0.7 en el corpus PCFG.

Experimento 6: Modelo calendario. $\Delta\text{BIC} = -21\,057$ favoreciendo n-gram sobre el modelo calendario lunar, consistente con un corpus generado por una gramática libre de contexto.

28.6. Verificación de no-identificabilidad (Teorema 10.1)

Para cada corpus, verificamos empíricamente que el estadístico estructural $S(\pi X) = S(X)$ para toda permutación $\pi \in \text{Sym}(V_X)$:

Cuadro 24: Verificación empírica de no-identificabilidad (Teorema 10.1). $S(X)$ es invariante bajo permutación en todos los corpus.

Corpus	Invariante	Desviación máxima
PCFG_v2	Sí	6.8×10^{-13}
RR_like	Sí	5.7×10^{-14}
RR_real	Sí	1.1×10^{-13}
Indus	Sí	2.8×10^{-14}
Positional	Sí	1.1×10^{-12}

La desviación máxima es del orden de $10^{-13} \sim 10^{-14}$, consistente con error de punto flotante. Esto verifica empíricamente que las estadísticas espectrales **no pueden distinguir** un corpus de su versión renombrada, confirmando el Teorema 10.1.

28.7. Auditoría de niveles de claim

La Tabla 25 muestra qué nivel de claim es admisible bajo diferentes escenarios de anclaje y estabilidad.

Cuadro 25: Nivel de claim máximo admisible según anclaje, estabilidad y gap contra controles negativos. OCR = OverclaimRisk.

Escenario	AnchorPower	Estabilidad	NegCtrlGap	Claim máximo	OCR
Sin anclas, baja estabilidad	0.0	0.2	0.5σ	C0	1.43
Sin anclas, moderada	0.0	0.3	1.5σ	C1	1.11
Anclas débiles	0.15	0.5	2.5σ	C2	0.78
Anclas moderadas	0.4	0.7	3.5σ	C3	0.59
Anclas fuertes	0.8	0.9	5.0σ	C4	0.44

Para Rongorongo real sin anclas externas: sin anclas y con estabilidad espectral 0, el nivel máximo admisible es C0 (paleográfico). Sin anclas, con estabilidad moderada (0.3) y NegCtrlGap de 2.2σ (Tabla 23), el nivel máximo es C1. Claims de traducción o significado (C3+) requieren anclas externas verificables.

28.8. Estabilidad de Procrustes bajo anclajes ruidosos (Teorema 16.1)

La Tabla 26 muestra la estabilidad leave-one-out (LOO) de Procrustes con anclas sintéticas a diferentes niveles de ruido.

Cuadro 26: Estabilidad Q de Procrustes con leave-one-anchor-out. QStability mide $\mathbb{E}[\|Q^{(b)} - Q^{(b')}\|_F]$. Condición del ancla y desviación LOO promedio.

Anclas	Ruido	QStability	LOO mean dev
5	0.00	5.15	4.71
5	0.05	5.14	4.55
5	0.20	5.19	4.57
10	0.00	4.70	3.66
10	0.10	4.83	3.67
10	0.20	4.85	3.82
20	0.00	2.89	0.00
20	0.05	3.72	0.81
20	0.10	3.94	1.24
20	0.20	4.18	1.57

Con pocos anclas (5–10), QStability oscila entre 4.7 y 5.2, indicando que la rotación Procrustes es moderadamente sensible. Con 20 anclas (17.9 % del vocabulario), la estabilidad mejora significativamente a QStability = 2.89 sin ruido, pero se degrada con ruido creciente.

28.9. Descomposición de costos de transporte y estabilidad OT

Para el experimento de permutación sobre PCFG:

- Costo geométrico ($\mathcal{L}_g$) = 1.78
- Costo relacional ($\mathcal{L}_r$) = 1.71
- Entropía ($\mathcal{H}$) = 0.57
- Fracción geométrica = 43.5 %, fracción relacional = 41.8 %

La estabilidad bootstrap de acoplamientos OT es 0.994 con L1 media = 0.002, indicando que los acoplamientos OT son altamente estables bajo bootstrap para el corpus sintético.

La calibración esperada (ECE) sobre datos sintéticos es 0.061, indicando buena calibración bajo simulación.

28.10. Validación bilingüe en idiomas conocidos

Para determinar si el fracaso del método en Rongorongo e Indus es metodológico o de datos, evaluamos el pipeline completo (co-ocurrencia $\rightarrow$ PPMI $\rightarrow$ SVD $\rightarrow$ Procrustes) en pares de idiomas **conocidos**: inglés $\rightarrow$ francés, inglés $\rightarrow$ español, inglés $\rightarrow$ alemán. Usamos cognados ortográficos idénticos (p.ej., *restaurant*, *information*) como anclas bilingües verdaderas y medimos si el método recupera las traducciones correctas.

Las consecuencias son decisivas:

Cuadro 27: Validación bilingüe: recuperación de traducciones conocidas con anclas cognadas. V = vocabulario, T = tokens, Anch = anclas de alineación, Eval = pares de evaluación, EPC = Expected Pair Count. Todas las condiciones usan $k = 16$, $h = 3$, $\alpha = 0.75$.

Par	Condición	V_s	T_s	Anch	Eval	Acc@1	Acc@5	MRR	EPC
EN→FR	Full	1198	47.9k	59	59	0.271	0.627	0.434	0.200
EN→FR	Medium	475	19.9k	14	14	1.000	1.000	1.000	0.530
EN→FR	RR-like	219	4.5k	5	5	1.000	1.000	1.000	0.565
EN→ES	Full	1198	47.9k	33	33	0.394	0.848	0.600	0.200
EN→ES	Medium	475	19.9k	11	11	0.818	1.000	0.894	0.530
EN→ES	RR-like	219	4.5k	7	7	0.857	1.000	0.905	0.565
EN→DE	Full	1198	47.9k	48	48	0.312	0.688	0.462	0.200
EN→DE	Medium	475	19.9k	13	13	0.923	1.000	0.962	0.530
EN→DE	RR-like	219	4.5k	7	7	1.000	1.000	1.000	0.565
EN→DE	Indus-like	53	748	2	5	0.800	1.000	0.840	1.598

- (I) **El método funciona con anclas verdaderas.** Bajo condiciones similares a Rongorongo ($V \approx 200$, $T \approx 4.5k$, 5 anclas), Acc@1 alcanza 0.86–1.00 para los tres pares de idiomas. Esto confirma que el pipeline espectral es conceptualmente correcto cuando se dispone de anclas.
- (II) **El cuello de botella es la falta de anclas, no la metodología.** La diferencia entre el éxito en idiomas conocidos y el fracaso en Rongorongo no es el método sino **la ausencia de anclas verificables**. Sin anclas externas, Corolario 13.3 impide claims C2+, y la validación bilingüe confirma que con solo 2–7 anclas el método ya recupera el 80–100 % de las traducciones.
- (III) **El vocabulario más grande degrada la recuperación** en el régimen Full ($V = 1198$): Acc@1 cae a 0.27–0.39 con 33–59 anclas, porque el espacio de búsqueda es mayor. Esto refuerza la conclusión de la Proposición 14.1: incluso con anclas, EPC bajo (0.20) degrada la señal.
- (IV) **Incluso en condiciones de Indus** ($V = 53$, $T = 748$, 2 anclas), EN→DE alcanza Acc@1 = 0.80. Con datos tan escasos que EPC = 1.60, debaixo de la concentración threshold, el método esencialmente memoriza los pocos cognados disponibles.

Nota importante: las “anclas cognadas” aquí son palabras idénticas ortográficamente (p. ej., *restaurant* en inglés y francés). Para Rongorongo, no existen anclas equivalentes verificables independientemente. Esta es la diferencia fundamental entre validación bilingüe y desciframiento.

28.11. Resumen de hallazgos cuantitativos

Los resultados cuantitativos confirman el marco teórico de manera robuste pero conducen a una conclusión de **humildad científica**:

- (I) **No-identificabilidad verificada:** Todos los corpus son invariantes bajo permutación (desviación máxima $< 10^{-12}$), confirmando el Teorema 10.1.

- (II) **Rongorongo real es espectralmente inestable:** $\text{Rel}_k = 0$ para todo k , con $\hat{\varepsilon}_k > \hat{\delta}_k$ (Corolario 13.3). El embedding SVD **no puede sostener claims** C_2+ .
- (III) **Indus es espectralmente inestable** y con gap contra controles negativos $< 1\sigma$ en todas las métricas. La estructura observada es **estadísticamente indistinguible** de aleatorio.
- (IV) **Datos insuficientes:** $\text{EPC} \ll 1$ para RR_real (0.037) e Indus (0.182), muy por debajo del umbral de concentración (Proposición 14.1).
- (V) **Escalación de claims requiere anclas externas:** Sin anclas, solo claims C0 (paleográfico) o C1 (estructural débil) son admisibles. Claims de traducción o significado (C3+) requieren evidencia externa verificable.
- (VI) **Procrustes es sensible al número y calidad de anclas:** Con pocos anclas, $\text{QStability} > 5$; con 20+ anclas, $\text{QStability} \approx 3$.

29. Discusión

29.1. Qué puede demostrar el método

El método puede demostrar:

- (I) que un corpus tiene estructura no aleatoria;
- (II) que ciertos signos cumplen roles funcionales;
- (III) que ciertas segmentaciones son más estables que otras;
- (IV) que una lengua candidata explica mejor la estructura que controles;
- (V) que ciertos candidatos semánticos son más plausibles que otros;
- (VI) que algunas hipótesis deben descartarse.

Sin embargo, la auditoría cuantitativa (Sección 28) y la validación bilingüe (Sección 28, Tabla 27) imponen restricciones severas sobre cuáles de estas afirmaciones son admisibles sin anclas externas verificables:

Corpus	Estabilidad espectral	Claim máximo sin anclas
PCFG_v2 (sintético, 24k tokens)	$\text{Rel}_4 = 0.96$	C2 (funcional)
RR_real (941 tipos, 5.5k tokens)	$\text{Rel}_k = 0 \ \forall k$	C0 (paleográfico)
Indus (182 tipos, 1k tokens)	$\text{Rel}_4 = 0.10$	C0 (paleográfico)

Para Rongorongo real e Indus, el embedding espectral es **inestable** en todas las dimensionalidades probadas. El error bootstrap excede sistemáticamente el gap singular ($\hat{\varepsilon}_k > \hat{\delta}_k$ para todo k), lo que por el Corolario 13.3 implica que el embedding no puede sostener claims estructurales robustos sin soporte ancla externo.

29.2. Qué no puede demostrar solo

El método no puede demostrar por sí solo:

- (I) una traducción definitiva;
- (II) pronunciación;
- (III) correspondencia uno-a-uno entre glifos y palabras;
- (IV) intención cultural exacta;
- (V) historicidad de una lectura sin evidencia externa.

La auditoría cuantitativa añade una restricción más fuerte: **sin anclas externas, ni siquiera la estructura espectral es identificable** de manera estable. Los controles negativos (Sección 28, Tabla 23) muestran que Indus es estadísticamente indistinguible de un corpus aleatorio con la misma distribución de frecuencia ($\text{NegCtrlGap} < 1\sigma$ en todas las métricas), y Rongorongo real solo muestra señal moderada en el rango efectivo (6.0σ) y la energía laplaciana (3.3σ), pero **no** en la energía espectral top-4 (0.1σ).

29.3. Implicaciones para Rongorongo

Los resultados cuantitativos tienen implicaciones directas para cualquier intento de desciframiento de Rongorongo:

- (I) **Datos insuficientes:** Con $V = 941$ tipos y $T = 5460$ tokens, $\text{EPC}(h = 3) = 0.037$, indicando que cada celda de la matriz de co-ocurrencia tiene en promedio menos de 0.04 observaciones esperadas (Tabla 20). Se necesitarían ~ 128 millones de tokens para cobertura del 50 % al 95 % de confianza.
- (II) **Sin anclas, solo C0–C1:** El nivel máximo admisible sin anclas externas es C1 (estructural débil), y eso solo si la estabilidad bootstrap fuese positiva. Dado que $\text{Rel} = 0$, incluso C1 es cuestionable.
- (III) **Claims de traducción requieren anclas verificables:** Para alcanzar C3 (semántico débil) o superior, se necesitan anclas con $\text{AnchorPower} \geq 0.4$, $\text{Stability} \geq 0.7$, y $\text{NegCtrlGap} \geq 3.5\sigma$. Actualmente, Rongorongo no cumple ninguno de estos umbrales. La validación bilingüe (Tabla 27) demuestra que con solo 5–7 anclas cognadas, el método alcanza $\text{Acc@1} = 0.86\text{--}1.00$ en condiciones tipo Rongorongo, **confirmando que el cuello de botella es la falta de anclas, no el método.**
- (IV) **Recolección de datos es prioritaria:** Antes de cualquier claim de desciframiento, se necesitan más datos: transcripciones mejoradas de Barthel, lecturas 3D, identificación de pasajes paralelos, y anclas iconográficas verificables independientemente.

29.4. Belleza matemática del enfoque

La pseudoinversa aparece como una forma de humildad matemática: cuando una inversión exacta no existe, se elige la solución mínima compatible con la evidencia. La SVD aparece como instrumento de visión: separa direcciones dominantes de ruido. Procrustes aparece como respeto geométrico: no deforma arbitrariamente una lengua para que encaje con otra. La submersión aparece como metáfora formal: un sistema pequeño puede ser sombra de una semántica más rica, y cada signo puede corresponder a una fibra, no a un punto.

30. Métricas de auditabilidad y principio de ledger de hipótesis

Todo resultado numérico del sistema debe pasar por métricas de auditabilidad antes de ser reportado.

30.1. Gap contra controles negativos

Para cualquier score S :

$$\text{NegCtrlGap}(S) = \frac{S(X) - \mathbb{E}_{X' \sim H_0} S(X')}{\text{sd}_{X' \sim H_0} S(X')}. \quad (30.1)$$

Gap	Interpretación
< 1	Sin evidencia
1–2	Débil
2–3	Moderada
3–5	Fuerte
> 5	Muy fuerte (revisar leakage)

30.2. Estabilidad bootstrap

$$\text{Stability}(h) = \mathbb{E}_{b,b'} \left[\text{sim}(h^{(b)}, h^{(b')}) \right]. \quad (30.2)$$

Para distribuciones: $\text{sim}(\Pi, \Pi') = 1 - \frac{1}{2} \|\Pi - \Pi'\|_1$.

30.3. Calibración

Si se emiten probabilidades, se debe medir calibración. El Error de Calibración Esperado (ECE):

$$\text{ECE} = \sum_m \frac{|B_m|}{N} |\text{acc}(B_m) - \text{conf}(B_m)|. \quad (30.3)$$

En Rongorongoro real no hay ground truth, pero se calibra en sintéticos y se reportan los scores como “calibrados bajo simulación, no verdad histórica”.

30.4. Índice de sobreinterpretación

$$\text{OverclaimRisk}(h) = \frac{\text{ClaimLevel}(h)}{1 + \text{EvidenceLevel}(h)}. \quad (30.4)$$

Si $\text{OverclaimRisk}(h) > 1$, el claim debe bloquearse automáticamente.

30.5. Ledger de hipótesis

Principio 30.1 (Ledger auditable de hipótesis). *Ninguna salida del sistema puede reportarse como una igualdad desnuda $x = y$. Toda hipótesis debe reportarse como tupla:*

$$h = (x, \mathcal{Y}_h, p_h, E_h, B_h, \ell_h, R_h), \quad (30.5)$$

donde x es glifo o secuencia, $\mathcal{Y}_h$ es conjunto de interpretaciones candidatas, p_h es score posterior calibrado, E_h es evidencia, B_h es contraevidencia, $\ell_h \in \{C_0, \dots, C_5\}$ es el nivel máximo admisible, y R_h es metadatos de reproducibilidad.

31. Conclusión

Este trabajo formula un marco matemático para el desciframiento probabilístico de sistemas simbólicos perdidos mediante geometría espectral, formalizando por qué la traducción fuerte es no identificable sin anclajes (Teorema 10.1), caracterizando cómo los anclajes rompen simetrías (Definición 10.5, Teorema 10.6), derivando condiciones de estabilidad espectral bajo corpus finito (Teorema 13.2), probando sensibilidad de PMI (Proposición 15.1) y Procrustes (Teorema 16.1), y definiendo niveles de claim admisibles (Definición 3.1) que convierten el marco en un sistema de inferencia responsable.

La auditoría cuantitativa completa (Sección 28) verifica empíricamente las predicciones del marco: la no-identificabilidad bajo permutación (desviación máxima $< 10^{-12}$ para todos los corpus), la inestabilidad espectral de corpus de baja densidad ($\text{Rel}_k = 0$ para Rongorongo real e Indus), y la insuficiencia de datos ($\text{EPC} \ll 1$). Estos resultados transforman el marco de una propuesta teórica en un diagnóstico operativo: el sistema no solo predice que Rongorongo es difícil de descifrar, sino que **cuantifica exactamente por qué y qué nivel de claim es admisible** en cada escenario.

La conclusión principal es triple. Primero, la estadística interna de un sistema simbólico puede revelar estructura significativa si el sistema codifica información no trivial, pero solo identificando órbitas bajo permutaciones, no significados absolutos (Corolario 10.2). Segundo, los embeddings espectrales y alineamientos son confiables solo cuando los gaps singulares exceden el error bootstrap (Corolario 13.3) y los anclajes tienen condición suficiente (Teorema 16.1); para Rongorongo real e Indus, **estas condiciones no se cumplen**. Tercero, toda hipótesis debe reportarse como un ledger auditable con evidencia, contraevidencia, nivel de claim y riesgo de sobreinterpretación (Sección 30).

En una frase:

La traducción perdida no es una clave única; es una clase de equivalencia

parcialmente observable, que solo puede refinarse mediante anclajes externos, estabilidad estadística y falsación experimental.

32. Corrigenda

Las siguientes correcciones se aplicaron tras una auditoría completa del pipeline:

- (I) **Bug en posiciones de features estructurales.** La función `compute_structural_features` en `build_structural_embeddings.py:46` usaba `seq.index(tok)` que retorna la primera ocurrencia, no la posición actual. Para tokens que aparecen múltiples veces en una línea, `pos_mean` y `pos_std` se computaban incorrectamente. Corrección: usar `enumerate` para obtener la posición real. Los valores en la Tabla 14 se actualizaron de IPR a rango entrópico, y el bug de posición fue corregido. Las conclusiones cualitativas se mantienen: el sanity check invertido pasa para todos los corpora, con separación *mayor* tras la corrección.
- (II) **Bug en conteo de sucesores.** Cada transición $X \rightarrow Y$ se contaba dos veces (desde la perspectiva de X y de Y). Corrección: contar solo transiciones hacia adelante, eliminando el doble conteo.
- (III) **Métrica r_{eff} incorrecta en scripts.** `build_structural_embeddings.py` computaba $(\sum \sigma_i)^2 / \sum \sigma_i^2$ (proporción de participación inversa), no el rango entrópico $\exp(H)$ de `spectral.py`. Corrección: usar `effective_rank()` consistentemente.
- (IV) **GPA con correspondencia por frecuencia.** La versión original alineaba las primeras $n_{\min}$ filas de cada embedding arbitrariamente (orden alfabético). Corrección: ordenar por norma (proxy de frecuencia) antes del alineamiento Procrustes, estableciendo correspondencia semántica entre tokens de alta frecuencia.
- (V) **GPA: referencia no rotada.** La versión original fijaba el lenguaje de referencia sin rotación ($Q_0 = I$). Corrección: rotar todos los embeddings (incluyendo la referencia) en cada iteración, de acuerdo con GPA estándar.
- (VI) **Zero-padding en proyección.** La versión original rellenaba con ceros el espacio consenso cuando $n_R < n_X$. Corrección: usar solo las primeras $\min(n_X, n_R)$ filas, sin relleno.
- (VII) **Método “intersection”.** Renombrado a “union”: SVD vertical computa la unión (espacio generado), no la intersección de subespacios.
- (VIII) **Sinkhorn manual no estabilizado.** El docstring clamaba estabilización log-domain, pero la implementación es estándar. Corrección: rutear siempre por `optimal_transport_matrix` que usa POT cuando está disponible.
- (IX) **Regularización KL en multi-marginal GW.** La versión original agregaba $-\log(\text{prior})$ a la matriz de costo, lo cual no regulariza hacia el prior. Corrección: modificar el kernel de Gibbs a $K_{ij} = \text{prior}_{ij} \cdot \exp(-C_{ij}/\varepsilon)$.

- (x) **Consensus sin alinear.** La versión original promediaba embeddings sin rotar. Corrección: alinear primero cada embedding vía Procrustes antes de promediar.
- (xi) **Suavizado de distribuciones de contexto.** Agregado parámetro $\alpha = 0.75$ en PPMI (Levy & Goldberg 2015), bajando el peso de palabras funcionales frecuentes.

A. Apéndice A: derivación matricial del gradiente de mínimos cuadrados

Sea

$$f(W) = \|XW - Y\|_F^2.$$

Usando traza:

$$f(W) = \text{tr}((XW - Y)^\top (XW - Y)) \quad (\text{A.1})$$

$$= \text{tr}(W^\top X^\top XW) - 2\text{tr}(W^\top X^\top Y) + \text{tr}(Y^\top Y). \quad (\text{A.2})$$

El gradiente es

$$\nabla_W f = 2X^\top XW - 2X^\top Y.$$

La ecuación normal es

$$X^\top XW = X^\top Y.$$

Si $X^\top X$ es invertible:

$$W = (X^\top X)^{-1} X^\top Y.$$

Si no es invertible, la solución de norma mínima es

$$W = X^+ Y.$$

B. Apéndice B: índice de anisotropía espectral

Definimos

$$A_k(M) = \frac{\sigma_1}{\frac{1}{k} \sum_{i=1}^k \sigma_i}.$$

Si A_k es alto, una dirección domina la estructura. En lenguaje, esto puede corresponder a:

- (I) frecuencia extrema de signos funcionales;
- (II) artefactos de segmentación;
- (III) direccionalidad mal normalizada;
- (IV) tema ritual repetitivo;
- (V) corpus demasiado pequeño.

C. Apéndice C: plantilla de reporte de hipótesis

Para cada signo x_i , el sistema debe producir:

```
glyph_id: x_i
frequency_rank: ...
spectral_coordinates: [...]
top_candidates:
  - candidate: y_1
    probability: 0.31
    evidence:
      - geometric_nearest_neighbor
      - compatible_frequency_class
      - supported_by_iconographic_prior
    counterevidence:
      - unstable_under_bootstrap_window_3
  - candidate: y_2
    probability: 0.22
uncertainty:
  entropy: ...
  bootstrap_variance: ...
decision:
  status: partial / unstable / rejected / strong_candidate
```

D. Apéndice D: glosario

Pseudoinversa	Generalización de la inversa para matrices rectangulares o singulares.
SVD	Factorización $A = U\Sigma V^T$ que separa direcciones ortogonales y escalas.
Procrustes	Problema de encontrar la rotación/reflexión que mejor alinea dos nubes de puntos.
PMI	Medida de asociación entre dos eventos basada en cuánto supera su co-ocurrencia a la independencia.
Transporte óptimo	Marco para acoplar distribuciones minimizando costo.
Gromov–Wasserstein	Variante de transporte que compara estructuras relacionales internas.
Submersión	Mapa suave cuyo diferencial tiene rango máximo en el codominio.
Fibra	Conjunto de puntos que colapsan a un mismo valor bajo una aplicación.
Anclaje	Evidencia externa que rompe simetrías de permutación.

Referencias

- [1] L. D. Broemeling. An account of early statistical inference in Arab cryptology. *The American Statistician*, 65(4):255–257, 2011.
- [2] S. Ferrara, R. S. R. et al. The invention of writing on Rapa Nui (Easter Island). New radiocarbon dates on the Rongorongo script. *Scientific Reports*, 14, 2024.
- [3] E. H. Moore. On the reciprocal of the general algebraic matrix. *Bulletin of the American Mathematical Society*, 26:394–395, 1920.
- [4] R. Penrose. A generalized inverse for matrices. *Mathematical Proceedings of the Cambridge Philosophical Society*, 51(3):406–413, 1955.
- [5] G. H. Golub and C. F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, 4th edition, 2013.
- [6] C. Eckart and G. Young. The approximation of one matrix by another of lower rank. *Psychometrika*, 1:211–218, 1936.
- [7] P. H. Schönemann. A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31:1–10, 1966.
- [8] M. Artetxe, G. Labaka, and E. Agirre. Learning bilingual word embeddings with (almost) no bilingual data. In *Proceedings of ACL*, pages 451–462, 2017.
- [9] M. Artetxe, G. Labaka, and E. Agirre. Generalizing and improving bilingual word embedding mappings with a multi-step framework of linear transformations. In *Proceedings of AAAI*, 2018.
- [10] A. Conneau, G. Lample, M. Ranzato, L. Denoyer, and H. Jégou. Word translation without parallel data. In *International Conference on Learning Representations*, 2018.
- [11] G. Lample, A. Conneau, L. Denoyer, and M.-A. Ranzato. Unsupervised machine translation using monolingual corpora only. In *International Conference on Learning Representations*, 2018.
- [12] D. Alvarez-Melis and T. S. Jaakkola. Gromov-Wasserstein alignment of word embedding spaces. In *Proceedings of EMNLP*, pages 1881–1890, 2018.
- [13] G. Dinu, A. Lazaridou, and M. Baroni. Improving zero-shot learning by mitigating the hubness problem. In *ICLR Workshop*, 2015.
- [14] T. Mikolov, K. Chen, G. Corrado, and J. Dean. Efficient estimation of word representations in vector space. *arXiv:1301.3781*, 2013.
- [15] O. Levy and Y. Goldberg. Neural word embedding as implicit matrix factorization. In *Advances in Neural Information Processing Systems*, 2014.

- [16] G. Peyré and M. Cuturi. Computational optimal transport. *Foundations and Trends in Machine Learning*, 11(5–6):355–607, 2019.
- [17] C. Villani. *Optimal Transport: Old and New*. Springer, 2009.
- [18] J. M. Lee. *Introduction to Smooth Manifolds*. Springer, 2nd edition, 2013.
- [19] T. M. Cover and J. A. Thomas. *Elements of Information Theory*. Wiley, 2nd edition, 2006.
- [20] J. Sommerschild, et al. Machine learning for ancient languages: A survey. *Computational Linguistics*, 49(3):703–745, 2023.
- [21] Y. Assael, T. Sommerschild, and J. Prag. Restoring ancient text using deep learning: a case study on Greek epigraphy. In *Proceedings of EMNLP-IJCNLP*, pages 6275–6283, 2019.
- [22] Y. Assael, T. Sommerschild, B. Shillingford, et al. Restoring and attributing ancient texts using deep neural networks. *Nature*, 603:280–283, 2022.
- [23] Y. Luo, F. Cao, and R. Barzilay. Neural decipherment via minimum-cost flow: from Ugaritic to Linear B. In *Proceedings of ACL*, pages 314–324, 2019.
- [24] Y. Luo, et al. Deciphering undersegmented ancient scripts using phonetic prior. *TACL*, 9:63–78, 2021.
- [25] F. Tamburini. Automatic decipherment of lost languages via combinatorial optimisation. In *Proceedings of CAWL*, pages 103–113, 2023.
- [26] C. Davis and W. M. Kahan. Some new bounds on perturbation of subspaces. *SIAM Journal on Numerical Analysis*, 7(1):1–13, 1970.
- [27] P.-Å. Wedin. Perturbation bounds in connection with singular value decomposition. *BIT Numerical Mathematics*, 12:99–111, 1972.
- [28] T. Gebru, et al. Datasheets for datasets. *Communications of the ACM*, 64(12):86–92, 2021.
- [29] M. Mitchell, et al. Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency*, pages 220–229, 2019.