

Submersión Espectral de Lenguajes Perdidos

Pseudoinversa de Moore–Penrose, SVD, Procrustes, Transporte Óptimo y Geometría Latente para el Desciframiento Probabilístico de Sistemas Simbólicos de Bajo Recurso

David Alexander Astudillo Muñoz

CEO & CTO, Baskerville AI

Ingeniero Civil Matemático, Universidad de Chile

Deep Learning para Trading Cuantitativo

Arquitecturas Neuronales + RL + Time Series Forecasting

david@baskerville.ai

28 de abril de 2026

Resumen

Este artículo propone un marco matemático para estudiar sistemas simbólicos perdidos o no descifrados mediante una combinación de análisis espectral, pseudoinversa de Moore–Penrose, alineamiento Procrustes, transporte óptimo relacional y modelos probabilísticos de lenguaje. La tesis central es que un sistema de signos funcional, si codifica regularidades de un mundo cultural o físico compartido, induce una geometría estadística interna parcialmente observable. Esta geometría puede extraerse desde matrices de co-ocurrencia, PMI/PPMI, grafos de transición y tensores de contexto; puede comprimirse mediante descomposición en valores singulares; y puede alinearse, bajo hipótesis explícitas, con espacios latentes de lenguas conocidas. El resultado no es un “traductor mágico” ni un desciframiento concluyente, sino una máquina de generación, ranking y falsación de hipótesis de equivalencia semántica. Formalizamos el problema como inferencia bajo simetrías, demostramos imposibilidades sin anclajes o restricciones externas, caracterizamos soluciones lineales de mínimos cuadrados mediante Moore–Penrose, derivamos el alineamiento ortogonal mediante SVD, y planteamos una extensión geométrica como submersión entre variedades semánticas de distinta dimensión. El caso Rongorongo se usa como motivación de bajo recurso extremo, no como afirmación de desciframiento. La contribución principal es una arquitectura rigurosa, verificable y falsable para pasar desde frecuencia de símbolos al estilo de Al-Kindi hacia una teoría moderna de desciframiento espectral probabilístico.

Palabras clave: Moore–Penrose, SVD, pseudoinversa, Procrustes, embeddings cross-linguales, traducción no supervisada, Rongorongo, Al-Kindi, geometría diferencial, transporte óptimo, inferencia bayesiana, lenguajes perdidos, análisis espectral.

Índice

1. Introducción

5

2. Motivación histórica y técnica	5
2.1. De Al-Kindi al aprendizaje no supervisado	5
2.2. Rongorongo como motivación de bajo recurso extremo	6
3. Planteamiento formal del problema	6
3.1. Sistema simbólico observado	6
3.2. Matriz de co-ocurrencia	7
3.3. Embedding espectral	7
4. Axiomas epistémicos	8
5. Moore–Penrose y la inversión lineal mínima	8
5.1. La pseudoinversa como solución canónica	8
5.2. Traducción lineal de mínimos cuadrados	9
6. Bajo rango, compresión semántica y Eckart–Young	10
7. Alineamiento Procrustes	10
7.1. Mapa ortogonal	10
8. Teorema de no-desciframiento gratuito	12
8.1. Simetría por permutación	12
9. Diccionario blando y transporte óptimo	13
9.1. Asignación probabilística	13
9.2. Costo geométrico	13
9.3. Costo relacional tipo Gromov–Wasserstein	13
9.4. Regularización entrópica	13
10. Submersión entre variedades semánticas	14
10.1. Lenguajes como variedades estadísticas	14
10.2. Pseudoinversa diferencial	14
11. Regularización, estabilidad y ruido	15
11.1. Tikhonov espectral	15
12. Modelo probabilístico completo	16
12.1. Posterior de traducción de signos	16
12.2. Decodificación secuencial	16
12.3. Principio de auditabilidad	17
13. Algoritmo propuesto	17
14. Diseño experimental	17
14.1. Experimento sintético controlado	17
14.2. Controles negativos	18

14.3. Métricas	18
15.Aplicación exploratoria a sistemas tipo Rongorongo	18
15.1. Advertencia metodológica	18
15.2. Unidades candidatas	19
15.3. Hipótesis candidatas	19
16.Resultados Empíricos	19
16.1. Benchmark sintético PCFG (control estructurado)	20
16.2. Corpus sintético con sesgo posicional	20
16.3. Corpus real del Indo (Parpola CISI)	21
16.3.1. Descripción del corpus	21
16.3.2. Sanity check espectral	21
16.3.3. Entropía condicional de pares	22
16.3.4. Sesgo posicional: el hallazgo más fuerte	22
16.3.5. Comunidades de co-ocurrencia	23
16.3.6. Embeddings mejorados con priors iconográficos	24
16.3.7. Patrones de repetición de signos	24
16.3.8. Significancia estadística del sesgo posicional	25
16.3.9. Modelos n-gram y perplexity	26
16.3.10. Clasificador supervisado de posición	27
16.4. Aplicación a Rongorongo	28
16.4.1. Situación del corpus	28
16.4.2. Benchmark Rongorongo-like	28
16.5. Embeddings de features estructurales	28
16.6. GW multi-marginal y expansión a 17 lenguas candidatas	29
16.7. Features iconográficos del RR-corpus	30
16.8. Síntesis comparativa	31
17.Consenso multi-idioma y reducción de fibras semánticas	33
17.1. Intuición: múltiples vistas de un mundo compartido	33
17.2. Formalización del espacio consenso	33
17.3. Proyección del sistema perdido al consenso	34
17.4. Teorema de reducción de fibra	34
17.5. Alineamiento relacional multi-vista	34
18.Teoría de identificabilidad parcial	35
19.Relación con LLMs e inferencia moderna	35
19.1. LLMs como priors, no como oráculos	35
19.2. RAG para desciframiento	36

20.Arquitectura computacional reproducible	36
20.1. Estructura de repositorio	36
20.2. Componentes	37
21.Discusión	37
21.1. Qué puede demostrar el método	37
21.2. Qué no puede demostrar solo	38
21.3. Belleza matemática del enfoque	38
22.Conclusión	38
A. Apéndice A: derivación matricial del gradiente de mínimos cuadrados	38
B. Apéndice B: índice de anisotropía espectral	39
C. Apéndice C: plantilla de reporte de hipótesis	39
D. Apéndice D: glosario	40

1. Introducción

El desciframiento de un sistema simbólico perdido puede entenderse como un problema inverso: se observa una secuencia finita de signos, pero se desconoce la aplicación que conecta esos signos con unidades semánticas, fonológicas, rituales, calendáricas o administrativas. En su versión más simple, el problema recuerda al criptoanálisis por frecuencia asociado históricamente a Al-Kindi: un texto cifrado conserva regularidades estadísticas del idioma original, y esas regularidades pueden explotarse para proponer correspondencias entre signos y letras [1]. Sin embargo, un sistema como Rongorongo no es un cifrado monoalfabético con una lengua original conocida; es un objeto de bajo recurso, culturalmente situado, con corpus pequeño, sin bilingües confirmados y con múltiples fuentes de incertidumbre [2].

La pregunta de este trabajo es más general:

¿Puede una geometría estadística inducida por un sistema simbólico perdido alinearse con la geometría estadística de una o varias lenguas conocidas, de modo que se generen hipótesis de traducción probabilísticas, auditables y falsables?

La respuesta propuesta es condicional. Sí, si se cumplen restricciones fuertes: existencia de estructura lingüística o semiótica no trivial, corpus suficiente para estimar relaciones de co-ocurrencia, espacios comparables, anclajes débiles, regularización cultural y validación negativa. No, si se espera recuperar significado completo desde frecuencias marginales aisladas.

El marco que desarrollamos combina cinco niveles.

- N1. Nivel estadístico:** frecuencias, co-ocurrencias, PMI, transición y grafos de contexto.
- N2. Nivel espectral:** SVD, rango efectivo, pseudoinversa y aproximaciones de bajo rango.
- N3. Nivel geométrico:** alineamientos ortogonales, Procrustes, variedades latentes, submersión y fibras semánticas.
- N4. Nivel probabilístico:** diccionarios blandos, posterior semántico, decodificación secuencial y calibración.
- N5. Nivel epistémico:** límites de identificabilidad, imposibilidad sin anclajes, validación por controles negativos.

La idea central puede expresarse informalmente así:

La traducción perdida no es una clave única; es una geometría latente parcialmente invertible.

2. Motivación histórica y técnica

2.1. De Al-Kindi al aprendizaje no supervisado

El criptoanálisis por frecuencia parte de una observación simple: si una sustitución simbólica conserva el orden textual, entonces las letras más frecuentes del idioma base tienden a seguir siendo frecuentes, aunque aparezcan con otros símbolos. Esta idea no descifra por sí sola lenguajes

completos, pero inaugura una familia de métodos estadísticos: inferir estructura invisible desde distribuciones observables.

En NLP moderno, una idea análoga aparece en embeddings multilingües y traducción no supervisada. Métodos como los de Artetxe, Labaka y Agirre [8, 9], Conneau et al. [10], Lample et al. [11] y Alvarez-Melis y Jaakkola [12] exploran cómo alinear espacios vectoriales monolingües sin grandes corpus paralelos. Muchos de estos métodos dependen de una hipótesis geométrica: lenguas distintas que describen mundos comparables inducen espacios semánticos con estructura relacional parcialmente isomorfa.

Este trabajo traslada esa intuición a un régimen más extremo: sistemas simbólicos pequeños, posiblemente no fonéticos, sin corpus paralelo y con semántica culturalmente densa.

2.2. Rongorongo como motivación de bajo recurso extremo

Rongorongo, escritura asociada a Rapa Nui, permanece sin descifrar. La literatura reciente destaca que los objetos conservados son escasos y que su origen histórico sigue siendo tema de investigación [2]. Por ello, cualquier propuesta de desciframiento debe distinguir cuidadosamente entre:

- (I) **desciframiento fuerte:** lectura semántica o fonética verificable;
- (II) **desciframiento débil:** segmentación, direccionalidad, clases funcionales, repeticiones;
- (III) **desciframiento probabilístico:** ranking de hipótesis con incertidumbre;
- (IV) **análisis estructural:** evidencia de que el sistema posee regularidades no aleatorias.

Nuestro marco apunta primero a los niveles débil, probabilístico y estructural. El nivel fuerte requiere evidencia externa adicional.

3. Planteamiento formal del problema

3.1. Sistema simbólico observado

Sea X un sistema simbólico perdido. Observamos un corpus finito

$$\mathcal{C}_X = (s_1, s_2, \dots, s_T), \quad s_t \in \mathcal{V}_X, \quad (3.1)$$

donde $\mathcal{V}_X = \{x_1, \dots, x_{n_X}\}$ es el vocabulario de signos, glifos, variantes normalizadas o unidades segmentadas.

Sea Y una lengua conocida o un conjunto de lenguas conocidas:

$$\mathcal{C}_Y = (w_1, w_2, \dots, w_M), \quad w_m \in \mathcal{V}_Y, \quad (3.2)$$

donde $\mathcal{V}_Y = \{y_1, \dots, y_{n_Y}\}$.

El objetivo no es encontrar una función determinista

$$\tau : \mathcal{V}_X \rightarrow \mathcal{V}_Y$$

sino una distribución posterior

$$\Pi_{ij} = p(y_j \mid x_i, \mathcal{C}_X, \mathcal{C}_Y, \mathcal{K}), \quad (3.3)$$

donde $\mathcal{K}$ representa conocimiento adicional: iconografía, arqueología, lengua comparada, direccionalidad, soporte material, calendario, genealogía, tradición oral o restricciones antropológicas.

3.2. Matriz de co-ocurrencia

Definimos una función de contexto $K : \mathbb{N} \rightarrow \mathbb{R}_{\geq 0}$, por ejemplo

$$K(d) = \mathbf{1}\{1 \leq d \leq h\} \quad \text{o} \quad K(d) = \exp(-d/\rho).$$

La matriz de co-ocurrencia de X es

$$C_{ij}^{(X)} = \sum_{t=1}^T \mathbf{1}\{s_t = x_i\} \sum_{\substack{u=1 \\ u \neq t}}^T K(|u - t|) \mathbf{1}\{s_u = x_j\}. \quad (3.4)$$

Análogamente se define $C^{(Y)}$. A partir de C se construyen probabilidades suavizadas:

$$\hat{p}_{ij} = \frac{C_{ij} + \epsilon}{\sum_{a,b} C_{ab} + \epsilon n^2}, \quad \hat{p}_{i\cdot} = \sum_j \hat{p}_{ij}, \quad \hat{p}_{\cdot j} = \sum_i \hat{p}_{ij}. \quad (3.5)$$

La matriz PMI es

$$\text{PMI}_{ij} = \log \frac{\hat{p}_{ij}}{\hat{p}_{i\cdot} \hat{p}_{\cdot j}}. \quad (3.6)$$

La versión positiva se define como

$$\text{PPMI}_{ij} = \max\{\text{PMI}_{ij}, 0\}. \quad (3.7)$$

3.3. Embedding espectral

Sea $M_X \in \mathbb{R}^{n_X \times n_X}$ una matriz estructural del sistema perdido: co-ocurrencia normalizada, PMI, PPMI, transición, Laplaciano de grafo o una combinación ponderada. Su descomposición en valores singulares es

$$M_X = U_X \Sigma_X V_X^\top. \quad (3.8)$$

Para dimensión latente k , definimos el embedding espectral

$$E_X(k, \alpha) = U_{X,k} \Sigma_{X,k}^\alpha, \quad \alpha \in [0, 1]. \quad (3.9)$$

Cuando M_X es simétrica positiva semidefinida, esto coincide con una descomposición espectral clásica. Cuando no lo es, U y V capturan roles direccionales distintos: contexto izquierdo/derecho, emisor/receptor, signo actual/siguiente signo.

4. Axiomas epistémicos

Axioma 4.1 (Suficiencia descriptiva). *Un sistema simbólico X es descifrable en sentido débil solo si existe una variable latente R , representando estados relevantes del mundo cultural o físico, tal que*

$$I(X; R) > 0. \quad (4.1)$$

Este axioma no dice que todo signo tenga significado léxico. Dice que el sistema completo debe transportar información no nula sobre algo externo o interno: eventos, nombres, conteos, clases rituales, secuencias, taxonomías o instrucciones.

Teorema 4.2 (Independencia implica imposibilidad inferencial). *Si X y R son independientes, entonces ningún procedimiento basado únicamente en X puede actualizar racionalmente la creencia sobre R . En particular,*

$$p(R | X) = p(R). \quad (4.2)$$

Demostración. Por independencia,

$$p(X, R) = p(X)p(R).$$

Si $p(X) > 0$, la regla de Bayes entrega

$$p(R | X) = \frac{p(X, R)}{p(X)} = \frac{p(X)p(R)}{p(X)} = p(R).$$

Por lo tanto, observar X no modifica la distribución posterior de R . Cualquier algoritmo que afirme recuperar R desde X en este caso está introduciendo información externa no declarada o ruido interpretativo. $\square$

Corolario 4.3 (Frecuencia sin estructura no basta). *Las frecuencias marginales $p(x_i)$ pueden sugerir clases funcionales, pero no identifican semántica por sí solas. Dos sistemas con las mismas frecuencias y estructuras relacionales distintas pueden tener interpretaciones incompatibles.*

5. Moore–Penrose y la inversión lineal mínima

5.1. La pseudoinversa como solución canónica

Sea $A \in \mathbb{R}^{m \times n}$. Si A es rectangular o singular, no existe en general una inversa clásica. La pseudoinversa de Moore–Penrose A^+ es la única matriz que satisface las cuatro ecuaciones:

$$AA^+A = A, \quad (5.1)$$

$$A^+AA^+ = A^+, \quad (5.2)$$

$$(AA^+)^T = AA^+, \quad (5.3)$$

$$(A^+A)^T = A^+A. \quad (5.4)$$

Teorema 5.1 (Pseudoinversa vía SVD). *Sea $A \in \mathbb{R}^{m \times n}$ una matriz de rango r con SVD*

$$A = U\Sigma V^T, \quad (5.5)$$

donde

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots), \quad \sigma_1 \geq \dots \geq \sigma_r > 0.$$

Entonces

$$A^+ = V\Sigma^+U^\top, \quad (5.6)$$

donde Σ^+ reemplaza cada $\sigma_i > 0$ por $1/\sigma_i$ y transpone la forma rectangular.

Demostración. Como U y V son ortogonales, basta verificar las cuatro condiciones de Moore–Penrose para Σ . Para cada valor singular no nulo,

$$\sigma_i \cdot \sigma_i^{-1} \cdot \sigma_i = \sigma_i, \quad \sigma_i^{-1} \cdot \sigma_i \cdot \sigma_i^{-1} = \sigma_i^{-1}.$$

Para valores singulares nulos, los productos permanecen nulos. Además, $\Sigma\Sigma^+$ y $\Sigma^+\Sigma$ son matrices diagonales con entradas 0 o 1, luego son simétricas. Multiplicar por U, V preserva las identidades correspondientes, pues $U^\top U = I$ y $V^\top V = I$. $\square$

5.2. Traducción lineal de mínimos cuadrados

Supongamos que existen representaciones $X \in \mathbb{R}^{n \times d_X}$ y $Y \in \mathbb{R}^{n \times d_Y}$ de n unidades alineadas parcialmente. Buscamos

$$W^* = \arg \min_{W \in \mathbb{R}^{d_X \times d_Y}} \|XW - Y\|_F^2. \quad (5.7)$$

Teorema 5.2 (Solución Moore–Penrose matricial). *El conjunto de minimizadores de (5.7) contiene*

$$W^* = X^+Y. \quad (5.8)$$

Además, X^+Y es el minimizador de norma Frobenius mínima.

Demostración. El problema se separa por columnas. Sea $Y = [y_1, \dots, y_{d_Y}]$ y $W = [w_1, \dots, w_{d_Y}]$. Entonces

$$\|XW - Y\|_F^2 = \sum_{\ell=1}^{d_Y} \|Xw_\ell - y_\ell\|_2^2.$$

Para cada columna, la solución de mínimos cuadrados de norma mínima es $w_\ell = X^+y_\ell$. Apilando soluciones se obtiene $W = X^+Y$. La minimalidad de norma se sigue de la descomposición ortogonal del espacio en $\ker(X) \oplus \ker(X)^\perp$: cualquier solución puede escribirse como $X^+y + z$, con $z \in \ker(X)$; el término z no cambia el residuo pero aumenta la norma salvo que $z = 0$. $\square$

Corolario 5.3 (Decodificador lineal canónico). *Si E_X y E_Y son embeddings espectrales comparables, entonces*

$$W_{\text{MP}} = E_X^+ E_Y \quad (5.9)$$

es el traductor lineal de mínimos cuadrados de norma mínima entre ambos espacios.

Observación 5.4. *Este corolario no afirma que W_{MP} sea una traducción semántica correcta. Afirma que, bajo la elección de representaciones y pares alineados, es el mapa lineal canónico que minimiza error cuadrático. Su valor científico depende de la calidad de los embeddings, anclajes y validaciones.*

6. Bajo rango, compresión semántica y Eckart–Young

Teorema 6.1 (Eckart–Young–Mirsky). *Sea $M \in \mathbb{R}^{m \times n}$ con SVD $M = U\Sigma V^\top$. La mejor aproximación de rango k en norma Frobenius es*

$$M_k = U_k \Sigma_k V_k^\top, \quad (6.1)$$

y satisface

$$M_k = \arg \min_{\text{rank}(B) \leq k} \|M - B\|_F. \quad (6.2)$$

Además,

$$\|M - M_k\|_F^2 = \sum_{i>k} \sigma_i^2. \quad (6.3)$$

Demostración. Por invariancia unitaria de la norma Frobenius,

$$\|M - B\|_F = \|\Sigma - U^\top B V\|_F.$$

Si $\text{rank}(B) \leq k$, entonces $U^\top B V$ también tiene rango a lo más k . La mejor matriz de rango k que aproxima una diagonal con entradas decrecientes conserva las k entradas diagonales más grandes y anula el resto. Esto entrega M_k y el error indicado. $\square$

Corolario 6.2 (Rango efectivo como complejidad simbólica). *Si los valores singulares de M_X decaen rápidamente, entonces la estructura estadística observable del sistema X puede comprimirse en pocas dimensiones. Si decaen lentamente, el sistema requiere una geometría de mayor dimensión o contiene ruido, heterogeneidad o múltiples subsistemas mezclados.*

Definimos el rango efectivo entrópico como

$$r_{\text{eff}}(M) = \exp \left(- \sum_i p_i \log p_i \right), \quad p_i = \frac{\sigma_i}{\sum_j \sigma_j}. \quad (6.4)$$

Este número sirve como indicador de complejidad latente, aunque no debe interpretarse directamente como número de categorías semánticas.

7. Alineamiento Procrustes

7.1. Mapa ortogonal

El mapa lineal general W puede deformar escalas, ángulos y distancias. Para traducción entre embeddings, muchas arquitecturas imponen una transformación ortogonal $Q \in O(d)$:

$$Q^\top Q = I. \quad (7.1)$$

Esto conserva productos internos:

$$\langle x_i Q, x_j Q \rangle = \langle x_i, x_j \rangle.$$

Por ello, si creemos que dos lenguas comparten estructura relacional, una rotación/reflexión es menos arbitraria que una transformación libre.

Teorema 7.1 (Procrustes ortogonal). *Sean $X, Y \in \mathbb{R}^{n \times d}$. El problema*

$$Q^* = \arg \min_{Q^T Q = I} \|XQ - Y\|_F^2 \quad (7.2)$$

se resuelve mediante la SVD

$$X^T Y = U \Sigma V^T, \quad (7.3)$$

con

$$Q^* = UV^T. \quad (7.4)$$

Demostración. Expandimos:

$$\|XQ - Y\|_F^2 = \text{tr}(Q^T X^T X Q) - 2 \text{tr}(Q^T X^T Y) + \text{tr}(Y^T Y).$$

Como $Q^T Q = I$,

$$\text{tr}(Q^T X^T X Q) = \text{tr}(X^T X),$$

que no depende de Q . Minimizar equivale a maximizar

$$\text{tr}(Q^T X^T Y).$$

Sea $X^T Y = U \Sigma V^T$. Entonces

$$\text{tr}(Q^T U \Sigma V^T) = \text{tr}(V^T Q^T U \Sigma).$$

Definiendo $Z = U^T Q V$, se tiene que Z es ortogonal y

$$\text{tr}(V^T Q^T U \Sigma) = \text{tr}(Z^T \Sigma) = \sum_i \sigma_i Z_{ii}.$$

Como $|Z_{ii}| \leq 1$, el máximo es $\sum_i \sigma_i$, alcanzado cuando $Z = I$. Por tanto,

$$U^T Q V = I \quad \Rightarrow \quad Q = UV^T.$$

□

Corolario 7.2 (Alineamiento exacto bajo isometría). *Si existe $Q_0 \in O(d)$ tal que $Y = XQ_0$, y X tiene rango columna completo, entonces el problema Procrustes recupera Q_0 de manera única.*

Demostración. Para $Q = Q_0$, el residuo es cero:

$$\|XQ_0 - Y\|_F = 0.$$

Si otro Q también alcanza residuo cero, entonces $XQ = XQ_0$, luego

$$X(Q - Q_0) = 0.$$

Como X tiene rango columna completo, su núcleo derecho es trivial y $Q = Q_0$. $\square$

8. Teorema de no-desciframiento gratuito

8.1. Simetría por permutación

Un peligro central en desciframiento es la ilusión de identificabilidad. Sin anclajes, todo sistema simbólico es invariante bajo renombramiento de símbolos.

Teorema 8.1 (No-free-decipherment). *Sea $X = (s_1, \dots, s_T)$ un corpus sobre vocabulario $\mathcal{V}_X$. Sea $\pi : \mathcal{V}_X \rightarrow \mathcal{V}_X$ una permutación. Defina $\pi(X) = (\pi(s_1), \dots, \pi(s_T))$. Cualquier estadístico puramente estructural que sea invariante a nombres de símbolos no puede distinguir X de $\pi(X)$. Por tanto, no puede identificar una semántica absoluta sin anclajes externos.*

Demostración. Un estadístico puramente estructural depende de patrones de igualdad, distancias, repeticiones, co-ocurrencias o topología relacional, pero no de los nombres arbitrarios de los símbolos. Si aplicamos π , las relaciones de igualdad se preservan:

$$s_t = s_u \iff \pi(s_t) = \pi(s_u).$$

Las matrices de co-ocurrencia se transforman por conjugación:

$$C_{\pi(X)} = P_\pi C_X P_\pi^\top,$$

donde P_π es una matriz de permutación. Los valores singulares, espectro del Laplaciano, distancias relacionales y rangos se preservan. Luego todo método que observe solo estructura interna obtiene la misma evidencia para X y $\pi(X)$. Cualquier elección entre ambas requiere información externa. $\square$

Corolario 8.2 (Necesidad de anclajes). *Para pasar de estructura a semántica se requiere al menos uno de los siguientes tipos de anclaje:*

- (I) *anclaje bilingüe;*
- (II) *anclaje iconográfico;*
- (III) *anclaje arqueológico;*
- (IV) *anclaje fonético;*
- (V) *anclaje numérico/calendárico;*
- (VI) *anclaje comparativo con lenguas emparentadas;*
- (VII) *anclaje por regularidad pragmática.*

Observación 8.3. *Este resultado es deliberadamente restrictivo. Protege contra una mala práctica común: presentar una traducción única donde matemáticamente solo existe una clase de equivalencia bajo simetrías.*

9. Diccionario blando y transporte óptimo

9.1. Asignación probabilística

En lugar de una función $\tau : \mathcal{V}_X \rightarrow \mathcal{V}_Y$, usamos una matriz estocástica

$$\Pi \in \mathbb{R}_{\geq 0}^{n_X \times n_Y}, \quad \sum_{j=1}^{n_Y} \Pi_{ij} = 1. \quad (9.1)$$

La interpretación es

$$\Pi_{ij} = p(y_j \mid x_i).$$

Una versión con masas marginales $a \in \Delta^{n_X}$, $b \in \Delta^{n_Y}$ exige

$$\Pi \mathbf{1} = a, \quad \Pi^\top \mathbf{1} = b. \quad (9.2)$$

9.2. Costo geométrico

Dado un alineamiento ortogonal Q , definimos

$$D_{ij}(Q) = \|e_i^{(X)} Q - e_j^{(Y)}\|_2^2. \quad (9.3)$$

El transporte óptimo clásico resolvería

$$\min_{\Pi \in U(a,b)} \sum_{i,j} \Pi_{ij} D_{ij}(Q), \quad (9.4)$$

donde

$$U(a,b) = \{\Pi \geq 0 : \Pi \mathbf{1} = a, \Pi^\top \mathbf{1} = b\}.$$

9.3. Costo relacional tipo Gromov–Wasserstein

Si los espacios no son directamente comparables, se comparan relaciones internas:

$$\min_{\Pi \in U(a,b)} \sum_{i,i',j,j'} |\Delta_X(i,i') - \Delta_Y(j,j')|^2 \Pi_{ij} \Pi_{i'j'}. \quad (9.5)$$

Esto es especialmente atractivo en desciframiento porque no exige coordenadas equivalentes: exige que pares de signos relacionados en X correspondan a pares de palabras relacionadas en Y . Esta idea es coherente con el uso de distancias Gromov–Wasserstein para alineamiento de espacios de embeddings [12].

9.4. Regularización entrópica

Para evitar soluciones degeneradas, agregamos entropía:

$$\min_{\Pi \in U(a,b)} \langle \Pi, D \rangle + \varepsilon \sum_{i,j} \Pi_{ij} (\log \Pi_{ij} - 1). \quad (9.6)$$

Cuando ε es grande, Π es difusa; cuando $\varepsilon \rightarrow 0$, se aproxima a un acoplamiento duro.

10. Submersión entre variedades semánticas

10.1. Lenguajes como variedades estadísticas

Modelamos un idioma o sistema simbólico como una nube de puntos en un espacio latente. En el límite ideal, esa nube aproxima una variedad:

$$\mathcal{M}_X \subset \mathbb{R}^{d_X}, \quad \mathcal{M}_Y \subset \mathbb{R}^{d_Y}.$$

Si Y es una lengua rica con gran corpus y X un sistema pequeño, es razonable suponer

$$\dim(\mathcal{M}_Y) \geq \dim(\mathcal{M}_X).$$

Una aplicación

$$F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$$

puede interpretarse como una compresión semántica: muchas palabras o conceptos de Y colapsan a una unidad de X .

Definición 10.1 (Submersión semántica). *Sea $F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$ suave. Decimos que F es una submersión semántica local si para todo $y \in \mathcal{M}_Y$,*

$$\text{rank}(dF_y) = \dim(\mathcal{M}_X).$$

Teorema 10.2 (Fibras de una submersión). *Si $F : \mathcal{M}_Y \rightarrow \mathcal{M}_X$ es una submersión y $x \in \mathcal{M}_X$, entonces la fibra*

$$F^{-1}(x) = \{y \in \mathcal{M}_Y : F(y) = x\}$$

es una subvariedad de $\mathcal{M}_Y$ de dimensión

$$\dim(F^{-1}(x)) = \dim(\mathcal{M}_Y) - \dim(\mathcal{M}_X).$$

Demostración. Este es un caso del teorema del valor regular. Como F es submersión, todo $x \in \mathcal{M}_X$ es valor regular. Por el teorema del valor regular, $F^{-1}(x)$ es una subvariedad de codimensión $\dim(\mathcal{M}_X)$ dentro de $\mathcal{M}_Y$. Por tanto su dimensión es $\dim(\mathcal{M}_Y) - \dim(\mathcal{M}_X)$. $\square$

Corolario 10.3 (La traducción como fibra). *Si un glifo $x \in \mathcal{V}_X$ corresponde a una región comprimida de una lengua conocida, entonces su significado no es necesariamente un punto y , sino una fibra semántica:*

$$\mathcal{F}_x = \{y \in \mathcal{M}_Y : F(y) = x\}.$$

Por tanto, un desciframiento responsable debe devolver conjuntos o distribuciones de significados, no equivalencias absolutas prematuras.

10.2. Pseudoinversa diferencial

Si localmente

$$x \approx F(y_0) + J_F(y_0)(y - y_0),$$

entonces recuperar y desde x requiere invertir J_F , que puede ser rectangular. La solución de mínima norma es

$$y - y_0 = J_F(y_0)^+(x - F(y_0)). \quad (10.1)$$

Aquí aparece Moore–Penrose como inversa local de una submersión linealizada.

11. Regularización, estabilidad y ruido

11.1. Tikhonov espectral

Para corpus pequeños, los valores singulares pequeños son inestables. La pseudoinversa cruda amplifica ruido:

$$\sigma_i \mapsto \frac{1}{\sigma_i}.$$

Por eso se usa regularización de Tikhonov:

$$W_\lambda = (X^\top X + \lambda I)^{-1} X^\top Y. \quad (11.1)$$

Si $X = U\Sigma V^\top$, entonces

$$W_\lambda = V \operatorname{diag} \left(\frac{\sigma_i}{\sigma_i^2 + \lambda} \right) U^\top Y. \quad (11.2)$$

Teorema 11.1 (Contracción espectral de Tikhonov). *El operador regularizado reemplaza el factor $1/\sigma_i$ de la pseudoinversa por*

$$g_\lambda(\sigma_i) = \frac{\sigma_i}{\sigma_i^2 + \lambda}.$$

Además,

$$0 \leq g_\lambda(\sigma_i) \leq \frac{1}{2\sqrt{\lambda}}.$$

Demostración. La expresión (11.2) se obtiene sustituyendo la SVD de X :

$$X^\top X = V\Sigma^\top \Sigma V^\top.$$

Luego

$$(X^\top X + \lambda I)^{-1} X^\top = V(\Sigma^\top \Sigma + \lambda I)^{-1} \Sigma^\top U^\top.$$

Para cada $\sigma \geq 0$,

$$g_\lambda(\sigma) = \frac{\sigma}{\sigma^2 + \lambda}.$$

La cota máxima se obtiene derivando:

$$g'_\lambda(\sigma) = \frac{\lambda - \sigma^2}{(\sigma^2 + \lambda)^2},$$

cuyo máximo ocurre en $\sigma = \sqrt{\lambda}$, dando

$$g_\lambda(\sqrt{\lambda}) = \frac{\sqrt{\lambda}}{2\lambda} = \frac{1}{2\sqrt{\lambda}}.$$

□

Corolario 11.2 (Bajo recurso exige regularización). *En corpus pequeños, donde muchas direcciones espectrales tienen σ_i bajo, la pseudoinverta sin regularización puede transformar ruido en hipótesis semánticas artificiales. Tikhonov limita esta amplificación.*

12. Modelo probabilístico completo

12.1. Posterior de traducción de signos

Proponemos el siguiente posterior no normalizado:

$$p(y_j \mid x_i) \propto \exp\left(-\frac{\|e_i^{(X)}Q - e_j^{(Y)}\|^2}{\tau}\right) \cdot \psi_{\text{freq}}(x_i, y_j) \cdot \psi_{\text{icon}}(x_i, y_j) \cdot \psi_{\text{morph}}(x_i, y_j) \cdot \psi_{\text{anth}}(x_i, y_j), \quad (12.1)$$

donde:

- (I) $\tau > 0$ controla temperatura;
- (II) ψ_{freq} compara frecuencias;
- (III) ψ_{icon} incorpora semejanza visual o iconográfica;
- (IV) ψ_{morph} incorpora restricciones morfológicas;
- (V) ψ_{anth} incorpora conocimiento cultural explícito.

La normalización es

$$p(y_j \mid x_i) = \frac{\exp(-D_{ij}/\tau) \prod_r \psi_r(x_i, y_j)}{\sum_\ell \exp(-D_{i\ell}/\tau) \prod_r \psi_r(x_i, y_\ell)}.$$

12.2. Decodificación secuencial

Para una secuencia $x_{1:T}$, buscamos una secuencia $y_{1:T}$ maximizando:

$$\begin{aligned} \mathcal{S}(y_{1:T} \mid x_{1:T}) &= \sum_{t=1}^T \log p(y_t \mid x_t) \\ &\quad + \beta \sum_{t=1}^T \log p_Y(y_t \mid y_{<t}) \\ &\quad + \gamma \sum_{t=1}^T \log \phi_{\text{syntax}}(y_t, y_{t-1}, x_t, x_{t-1}) \\ &\quad - \Omega(y_{1:T}). \end{aligned} \quad (12.2)$$

Aquí p_Y puede ser un modelo de lenguaje entrenado en lenguas candidatas; ϕ_{syntax} impone compatibilidad estructural; y Ω penaliza soluciones demasiado libres, anacrónicas o semánticamente extravagantes.

12.3. Principio de auditabilidad

Cada hipótesis debe almacenar:

hipótesis = (glifo, candidatos, probabilidades, evidencia, contraevidencia, incertidumbre).

Nunca se debe reportar solo:

$$x_i = y_j.$$

La forma correcta es:

$$p(y_j \mid x_i, \mathcal{E}) = \rho,$$

junto con la evidencia $\mathcal{E}$.

13. Algoritmo propuesto

Algorithm 1 Spectral Submersion Decipherment

Require: Corpus perdido $\mathcal{C}_X$, corpus candidato $\mathcal{C}_Y$, conocimiento externo $\mathcal{K}$, dimensión k

Ensure: Diccionario probabilístico Π , hipótesis secuenciales, reporte de incertidumbre

- 1: Normalizar signos de X : variantes, orientación, segmentación, metadatos
 - 2: Construir matrices C_X, C_Y de co-ocurrencia con múltiples ventanas
 - 3: Calcular $M_X = \text{PPMI}(C_X)$, $M_Y = \text{PPMI}(C_Y)$
 - 4: Obtener SVD truncada: $M_X \approx U_X \Sigma_X V_X^\top$, $M_Y \approx U_Y \Sigma_Y V_Y^\top$
 - 5: Construir embeddings $E_X = U_{X,k} \Sigma_{X,k}^\alpha$, $E_Y = U_{Y,k} \Sigma_{Y,k}^\alpha$
 - 6: Estimar anclajes débiles $A = \{(x_i, y_j)\}$ desde $\mathcal{K}$
 - 7: **if** hay anclajes suficientes **then**
 - 8: Resolver Procrustes $Q^* = \arg \min_{Q^\top Q = I} \|E_X^A Q - E_Y^A\|_F^2$
 - 9: **else**
 - 10: Inicializar Q por alineamiento relacional o Gromov–Wasserstein
 - 11: **end if**
 - 12: Resolver transporte blando Π con costos geométricos, relacionales y priors
 - 13: Calibrar Π mediante bootstrap y controles negativos
 - 14: Decodificar secuencias con (12.2)
 - 15: Reportar hipótesis rankeadas y falsables, no traducciones absolutas
-

14. Diseño experimental

14.1. Experimento sintético controlado

Para validar el método antes de aplicarlo a un sistema real, se crea una lengua conocida Y , luego se genera una escritura artificial X mediante:

$$x_t = g(y_t, \eta_t), \tag{14.1}$$

donde g puede colapsar categorías, permutar símbolos, eliminar vocales, fusionar morfemas o introducir ruido.

Se evalúa si el algoritmo recupera:

- (I) clases funcionales;
- (II) vecinos semánticos;
- (III) anclajes;
- (IV) secuencias probables;
- (V) fibras semánticas.

14.2. Controles negativos

Un marco serio debe fallar cuando debe fallar. Proponemos:

- (I) **corpus permutado:** destruir orden pero mantener frecuencias;
- (II) **corpus aleatorio:** muestrear signos i.i.d.;
- (III) **lengua no relacionada:** usar corpus candidato incompatible;
- (IV) **anclajes falsos:** introducir priors incorrectos;
- (V) **bootstrap extremo:** medir sensibilidad a subconjuntos del corpus.

14.3. Métricas

$$\text{GraphDistortion} = \sum_{i,i',j,j'} |\Delta_X(i,i') - \Delta_Y(j,j')|^2 \Pi_{ij} \Pi_{i'j'}, \quad (14.2)$$

$$\text{Entropy}(\Pi_i) = - \sum_j \Pi_{ij} \log \Pi_{ij}, \quad (14.3)$$

$$\text{AnchorAcc@k} = \frac{1}{|A|} \sum_{(i,j) \in A} \mathbf{1}\{j \in \text{TopK}(\Pi_i)\}, \quad (14.4)$$

$$\text{Stability} = \mathbb{E}_b \left[\text{sim}(\Pi, \Pi^{(b)}) \right]. \quad (14.5)$$

La entropía alta indica incertidumbre; entropía baja con controles negativos malos indica sobreconfianza.

15. Aplicación exploratoria a sistemas tipo Rongorongo

15.1. Advertencia metodológica

Este artículo no afirma descifrar Rongorongo. Propone una metodología para estudiar su estructura bajo incertidumbre. Dado el bajo número de objetos conservados y la falta de bilingües confirmados, cualquier lectura semántica fuerte sería prematura sin evidencia externa robusta.

15.2. Unidades candidatas

Para un corpus rongorongo normalizado, se pueden construir varias granularidades:

- (I) glifo individual;
- (II) variante paleográfica;
- (III) biglifo;
- (IV) bloque repetido;
- (V) línea;
- (VI) secuencia entre separadores visuales;
- (VII) patrón direccional.

Cada granularidad induce una matriz $M_X^{(g)}$. El análisis espectral debe comparar la estabilidad entre granularidades:

$$\mathcal{S}_g = \{\sigma_1^{(g)}, \dots, \sigma_k^{(g)}\}.$$

15.3. Hipótesis candidatas

Lenguas o espacios candidatos:

- (I) rapanui moderno;
- (II) otras lenguas polinesias;
- (III) proto-polinesio reconstruido;
- (IV) vocabularios rituales/calendáricos;
- (V) taxonomías de fauna, navegación, genealogía y parentesco;
- (VI) sistemas numéricos o calendáricos.

El método debe tratar estos candidatos como modelos rivales:

$$\mathcal{M}_1, \dots, \mathcal{M}_K.$$

Se compara evidencia marginal:

$$p(\mathcal{C}_X \mid \mathcal{M}_k)$$

o aproximaciones mediante criterios de distorsión y validación.

16. Resultados Empíricos

Esta sección presenta los resultados del pipeline aplicado a tres corpus: un benchmark sintético PCFG de control, un benchmark sintético con sesgo posicional diseñado, y el corpus real del Indo (Parpola CISI). Los experimentos fueron implementados en Python 3.10+ con NumPy, SciPy, scikit-learn, pandas y NetworkX. El código completo, datos y figuras están disponibles en el repositorio `spectral-submersion`.

16.1. Benchmark sintético PCFG (control estructurado)

Para validar que el pipeline detecta estructura cuando existe, generamos una mini-gramática PCFG con 112 tipos léxicos distribuidos en 11 clases funcionales (determinantes, sustantivos, verbos, adjetivos, preposiciones, conjunciones, pronombres, numerales, cuantificadores, adverbios, nombres propios). El corpus contiene 3.000 oraciones (24.372 tokens).

Cuadro 1: Controles negativos sobre corpus sintético PCFG. r_{eff} = rango efectivo entrópico.

Variante	Vocabulario	r_{eff}	σ_1	$\sum \sigma_i$
Real (estructurado)	112	11.18	31.79	139.98
Permutado	112	14.18	16.34	78.59
Aleatorio (misma freq)	112	14.15	16.99	80.88
Aleatorio (uniforme)	112	13.91	13.38	60.58

El rango efectivo del corpus real (11.18) es significativamente menor que todos los controles (Tabla 1). Esta compresión espectral confirma que la gramática subyacente induce estructura de baja dimensionalidad. El sanity check ($r_{\text{eff}}^{\text{real}} < r_{\text{eff}}^{\text{uniforme}}$) **pasa** para este corpus.

Recuperación de anclajes sintéticos. Generamos un “candidato” aplicando una permutación conocida al vocabulario (112 pares 1-a-1). Con el 20 % de pares (22 anclajes) para entrenar Procrustes, el 80 % restante (90 pares) alcanza:

- Accuracy@1 = 68.9 %
- Accuracy@5 = 83.3 %
- MRR = 0.760
- Median rank = 1

Bajo condiciones controladas (isometría exacta + anclajes parciales), el algoritmo recupera la correspondencia de manera no trivial. Esto valida matemáticamente que el alineamiento funciona cuando las premisas del teorema de identificabilidad se satisfacen.

Robustez bajo polisemia. Simulando colapso del 15 % del vocabulario (donde múltiples signos del sistema perdido mapean a un mismo signo candidato), Accuracy@1 cae al 35.3 %. La degradación del $\sim 49\%$ es esperada: Procrustes ortogonal asume biyección, y cuando esta falla, el poder predictivo se reduce drásticamente. Esto valida empíricamente que la identificabilidad parcial requiere biyección o anclajes que rompan la ambigüedad.

Bootstrap de estabilidad. Con 50 muestras bootstrap, el CV del rango efectivo es 0.65 %, extremadamente estable. La similitud coseno media entre embeddings bootstrap es 0.765, indicando que la geometría relativa de signos se preserva aunque las coordenadas absolutas varíen.

16.2. Corpus sintético con sesgo posicional

Diseñamos un corpus de 2.000 secuencias (10.046 tokens, vocabulario 60) con clases posicionalmente restringidas:

- **TITLE** (8 signos): 80 % probabilidad de aparecer en primera posición

- **OBJECT** (40 signos): distribución libre en posiciones medias
- **NUMERAL** (8 signos): 80 % probabilidad de aparecer en última posición
- **SIGNATURE** (4 signos): 50 % probabilidad de aparecer en penúltima posición

Cuadro 2: Detección de sesgo posicional en corpus sintético controlado.

Clase	Tokens	first_ratio	last_ratio	Posición media
TITLE	1.907	0.835	0.869	0.09
OBJECT	6.166	0.066	0.320	0.48
NUMERAL	800	0.000	1.000	1.00
SIGNATURE	1.173	0.000	0.932	0.93

El análisis de sesgo posicional detecta perfectamente las clases funcionales (Tabla 2). Signos TITLE tienen $\text{first_ratio} \approx 0.84$; NUMERALES tienen $\text{last_ratio} = 1.0$.

Sanity check espectral: FALLA. A pesar de que la estructura posicional es fuerte y conocida, el rango efectivo del corpus real ($r_{\text{eff}} = 14.74$) es ligeramente mayor que el del control uniforme ($r_{\text{eff}} = 14.56$). Esto demuestra de manera crucial que la co-ocurrencia ventanal es insuficiente para detectar estructura puramente posicional en corpus con vocabulario grande y secuencias cortas (~ 5 tokens).

16.3. Corpus real del Indo (Parpola CISI)

16.3.1. Descripción del corpus

Procesamos la digitización abierta del *Corpus of Indus Seals and Inscriptions* (Parpola et al.), transcrita por Mayig (2025) y disponible bajo licencia MIT. El corpus contiene:

- 179 inscripciones (lados de sellos y tabletas)
- 1.003 tokens totales
- Vocabulario: 182 signos distintos (notación P#### de Parpola)
- Longitud media: 5.6 signos por inscripción
- Signo más frecuente: P324 (99 ocurrencias, 9.9 %)
- Segundo más frecuente: P122 (76 ocurrencias, 7.6 %)

La distribución de frecuencias sigue una ley de Zipf aproximada, con alta concentración en signos funcionales y una cola larga de hapax legomena.

16.3.2. Sanity check espectral

El sanity check **falla**: $r_{\text{eff}}^{\text{real}} = 15.69 > r_{\text{eff}}^{\text{uniforme}} = 15.35$ (Tabla 3). Esto indica que, con los parámetros estándar (ventana=3, $k=16$), la co-ocurrencia ventanal no detecta estructura espectral

Cuadro 3: Controles negativos sobre corpus Indo real.

Variante	Vocabulario	r_{eff}	σ_1	$\sum \sigma_i$
Real	182	15.69	23.96	227.96
Permutado	182	15.66	25.92	233.64
Aleatorio (misma freq)	155	15.53	25.51	209.00
Aleatorio (uniforme)	180	15.35	39.74	289.45

claramente comprimida respecto al azar. Incluso con una búsqueda en grilla de 96 configuraciones (ventanas $\{2, 3, 5, 7\}$, dimensiones $\{8, 16, 32, 64\}$, $\alpha \in \{0, 0.5, 1.0\}$), el mejor rango efectivo alcanzable es 7.84 — pero el sanity check *sigue fallando* (uniforme = 7.62).

Interpretación. El corpus Indo tiene vocabulario grande (~ 182 tipos) y secuencias extremadamente cortas (~ 5.6 signos). En este régimen, las matrices de co-ocurrencia son ruidosas: cada signo tiene pocos contextos observables, y la señal estructural se diluye. Esto es consistente con la hipótesis de Farmer, Sproat y Witzel (2004) de que las inscripciones del Indo podrían constituir un sistema no-lingüístico o proto-escritura. Alternativamente, podría reflejar que 179 inscripciones son estadísticamente insuficientes para 182 signos, o que la estructura real es no-local (dependencias de largo alcance entre inscripciones o contextos extra-textuales).

16.3.3. Entropía condicional de pares

Dado que la co-ocurrencia ventanal falla, aplicamos análisis de entropía condicional (Rao et al., 2009), que no requiere ventanas y funciona directamente con secuencias cortas.

Cuadro 4: Entropía condicional (bits) para corpus Indo real y controles.

Variante	$H(X)$	$H(X X_{-1})$	$H(X X_{-2}, X_{-1})$
Real	6.29	2.51	0.61
Permutado	6.29	3.09	0.22
Aleatorio (misma freq)	6.16	3.20	0.23
Aleatorio (uniforme)	7.35	2.28	0.02

El corpus real tiene entropía condicional de bigramas **menor** que la permutada (2.51 vs 3.09 bits) y menor que el aleatorio con misma frecuencia (2.51 vs 3.20 bits). Esto indica que existe estructura secuencial a nivel de pares que no es explicable por frecuencia marginal pura. La comparación con uniforme es problemática por artefacto de escasez muestral (el control uniforme con 182 tipos y ~ 1000 tokens genera muchos tipos raros que inflan artificialmente la entropía condicional).

Conclusión entropía: El corpus Indo muestra evidencia *débil pero no nula* de estructura secuencial a nivel de bigramas, consistente con Rao et al. (2009). La co-ocurrencia ventanal no detecta esta estructura; la entropía condicional sí.

16.3.4. Sesgo posicional: el hallazgo más fuerte

El análisis de sesgo posicional revela patrones fuertes y estadísticamente validados (Figura 1):




Figura 1: Sesgo posicional de los 30 signos más frecuentes del corpus Indo. Barras azules = sesgo hacia inicio; naranjas = sesgo hacia fin; púrpuras = posición media.

Validación con controles negativos:

Las diferencias entre real y controles son masivas: +0.616 para P324 (inicio), +0.658 para P385 (fin). Estas diferencias no son explicables por azar ni por frecuencia marginal. **El sesgo posicional es una característica estructural genuina del corpus Indo.**

Consistencia con literatura epigráfica. Mahadevan (1977) y Parpola (1994) describen signos funcionales posicionalmente restringidos en el Indo: títulos o nombres propios al inicio de inscripciones, numerales o clasificadores al final. Nuestros resultados estadísticos detectan exactamente estos patrones sin usar conocimiento lingüístico previo: P324 (signo más frecuente, 78 % al inicio) corresponde plausiblemente a un título o determinante; P385 (83 % al final) a un numeral o clasificador.

16.3.5. Comunidades de co-ocurrencia

Aplicando el algoritmo de Louvain a la red de co-ocurrencia PPMI (ventana=2, umbral=0.2), detectamos 12 comunidades. La correlación con sesgo posicional es notable (Figura 2):

La comunidad 3 es una **comunidad de inicio** que agrupa signos con fuerte sesgo hacia la primera posición, incluyendo a P324 (el signo más frecuente). La comunidad 0 incluye a P385 (end-biased 83 %) y muestra el mayor mean_last (0.251). Esto sugiere que la estructura

Cuadro 5: Top signos con sesgo posicional extremo en corpus Indo.

Signo	Frecuencia	Pos. media	first_ratio	last_ratio	Interpretación
P324	99	0.08	0.778	0.010	Signo de inicio
P217	18	0.15	0.778	0.111	Signo de inicio
P385	35	0.94	0.000	0.829	Signo de fin
P378	17	0.75	0.118	0.588	Signo de fin
P086	35	0.24	0.543	0.029	Signo de inicio/mixto

Cuadro 6: Comparación de sesgo posicional: real vs. controles negativos.

Signo	Métrica	Real	Permutado	Rand Freq	Rand Uniform
P324	first_ratio	0.778	0.162	0.212	0.000
	last_ratio	0.010	0.212	0.125	0.333
P385	first_ratio	0.000	0.171	0.133	0.125
	last_ratio	0.829	0.171	0.167	0.125
P217	first_ratio	0.778	0.444	0.130	0.167
	last_ratio	0.111	0.111	0.261	0.000

de co-ocurrencia captura parcialmente las restricciones posicionales: signos de inicio tienden a co-ocurrir entre sí (como títulos), mientras que signos de final están más dispersos.

16.3.6. Embeddings mejorados con priors iconográficos

Concatenamos embeddings espectrales (16-dim) con features iconográficas extraídas del JSON del corpus (damage, line, uncertainty, branching_factor, branch_count, branch_direction, etc. 9 features normalizadas via StandardScaler), produciendo representaciones de 25 dimensiones.

El ranking de candidatos se preserva casi idénticamente, pero las distorsiones absolutas disminuyen significativamente ($\sim 50\%$ para polinésicos, $\sim 12\%$ para europeos). Esto indica que los priors iconográficos añaden información geométrica coherente con la estructura contextual. La menor reducción para candidatos europeos sugiere que sus embeddings son menos compatibles con los priors visuales del Indo, consistente con una distancia tipológica mayor.

Importante: Esta comparación *no implica* parentesco genealógico entre Indo y lenguas polinésicas. Refleja similitud **estructural/tipológica**: lenguas con patrones de orden rígido (DET-NOUN-VERB) producen embeddings con menor distorsión relacional que lenguas con morfosintaxis más compleja y flexible.

16.3.7. Patrones de repetición de signos

Los sistemas simbólicos con funciones no-lingüísticas (contadores, etiquetas, nombres) a menudo exhiben repeticiones consecutivas (AA, AAA), mientras que los textos lingüísticos rara vez repiten el mismo lexema consecutivamente. Rongorongong, por ejemplo, muestra extensas repeticiones dobles y triples (Ferrara 2015). Analizamos si el corpus Indo muestra este patrón.

Solo el 4.5 % de las inscripciones contienen al menos una repetición doble, y ninguna contiene repeticiones triples o patrones ABAB (Tabla 9). El signo P268 es responsable de 5 de las 8

[Network visualization placeholder]
Requires running network analysis pipeline

Figura 2: Red de co-ocurrencia del Indo (top 40 signos). Nodos coloreados por sesgo posicional: azul=inicio, naranja=fin, púrpura=medio.

Cuadro 7: Correlación entre comunidades de red y sesgo posicional.

Comunidad	Tamaño	mean_first	mean_last	Signos principales
3	17	0.349	0.044	P324, P062, P060, P013
4	17	0.268	0.036	P325, P147, P056, P051
1	23	0.186	0.133	P050, P217, P378, P092
0	25	0.144	0.251	P122, P385, P123, P202

repeticiones dobles observadas. Esta escasez de repeticiones consecutivas es **consistente con un sistema lingüístico** (donde la redundancia léxica es baja) y **inconsistente con sistemas de conteo o etiquetado no-lingüístico** (donde las repeticiones numéricas son comunes). Sin embargo, dado el pequeño tamaño del corpus ($N = 179$), no podemos descartar completamente una función no-lingüística.

Comparación con Rongorongo. En Rongorongo, las repeticiones dobles/triples son ubicuas ($>30\%$ de las líneas). En Indo, son casi inexistentes. Esta diferencia sugiere que, si ambos sistemas son no-lingüísticos, tienen funciones distintas: Rongorongo podría ser un sistema mnemotécnico con repeticiones rítmicas, mientras que Indo podría ser un sistema de etiquetado o nominación sin necesidad de redundancia numérica.

16.3.8. Significancia estadística del sesgo posicional

Para validar que el sesgo posicional no es un artefacto del pequeño tamaño muestral, aplicamos un **test de permutación Monte Carlo** ($M = 1000$). La hipótesis nula es que cada signo tiene posición uniforme dentro de las inscripciones; generamos M corpus nulos permutando las posiciones dentro de cada inscripción (preservando longitud) y computamos la distribución nula de `first_ratio` y `last_ratio`.

Cuadro 8: Comparación de distorsión relacional: embeddings espectrales vs. mejorados.

Candidato	Familia	Rel. Dist. (espectral)	Rel. Dist. (mejorado)
rapa_nui	Polinesio	2271.37	936.79
tahitian	Polinesio	2317.05	983.24
fijian	Austronesio	2329.61	996.84
tongan	Polinesio	2513.14	1180.04
samoan	Polinesio	2880.17	1542.63
hawaiian	Polinesio	3188.22	1850.81
japanese	Japonico	3689.66	2346.02
maori	Polinesio	3782.02	2437.21
spanish	Romance	9547.74	8201.03
english	Germánico	11441.29	10095.29

Cuadro 9: Patrones de repetición en corpus Indo real ($N = 179$ inscripciones).

Patrón	Inscripciones afectadas	Tasa
Repetición doble (AA)	8	0.045
Repetición triple (AAA)	0	0.000
Alternancia ABAB	0	0.000
Cualquier repetición	8	0.045

Doce signos muestran sesgo posicional extremadamente significativo (Tabla 10). P324 tiene un tamaño de efecto de 16.1 desviaciones estándar sobre la media nula — prácticamente imposible bajo azar. Los p-valores < 0.001 corrigen implícitamente por multiplicidad vía el enfoque de permutación: solo observamos $p < 0.001$ cuando la señal es masiva.

Conclusión. El sesgo posicional del corpus Indo es estadísticamente robusto y no explicable por fluctuaciones muestrales. Esta es la evidencia estructural más fuerte obtenida en este estudio.

16.3.9. Modelos n-gram y perplexity

La perplexity mide cuán bien un modelo de lenguaje predice secuencias de test. Menor perplexity indica mayor predecibilidad estructural. Entrenamos modelos n-gram con suavizado Laplace (add-1) sobre el corpus Indo real y controles negativos, con 80 % train / 20 % test.

El corpus real tiene bigrama perplexity **74.53**, 42 % menor que el permutado (129.61) y 27 % menor que el aleatorio con misma frecuencia (102.61) (Tabla 11). Esta diferencia es fuerte evidencia de que existen dependencias secuenciales entre pares de signos que no son explicables por frecuencia marginal.

Trigrama perplexity más alta. Curiosamente, el trigrama tiene perplexity 97.34 (real) vs 153.18 (permutado), mayor que el bigrama. Esto ocurre porque el corpus tiene secuencias muy cortas (media 5.6 signos) y vocabulario grande (182 tipos): los trigramas observados son escasos y el suavizado Laplace asigna masa de probabilidad excesiva a trigramas no vistos. El bigrama es el nivel óptimo de modelado para este corpus.

Unigrama idéntico para real y permutado. Ambos tienen PPL=74.88 porque la permutación preserva frecuencias marginales. Esto valida que la información estructural está en las **transiciones**, no en las frecuencias individuales.

Cuadro 10: Signos con sesgo posicional significativo ($p < 0.05$, efecto > 2) en test Monte Carlo.

Signo	N	first_obs	first_null	first_p	first_efecto	Tipo
P324	99	0.778	0.179	<0.001	16.15	Inicio
P217	18	0.778	0.194	<0.001	6.51	Inicio
P013	9	1.000	0.174	<0.001	6.60	Inicio
P086	35	0.543	0.179	<0.001	5.77	Inicio
P051	5	1.000	0.160	<0.001	5.29	Inicio
P000	19	0.579	0.273	0.006	3.20	Inicio
P301	6	0.833	0.209	0.004	3.74	Inicio
P004	6	1.000	0.307	0.002	3.76	Inicio
P385	35	0.829	0.197	<0.001	9.52	Fin
P378	17	0.588	0.168	<0.001	4.71	Fin
P256	12	0.750	0.171	<0.001	5.50	Fin
P076	6	0.667	0.143	0.006	3.89	Fin

Cuadro 11: Perplexity y entropía cruzada (bits/signo) para corpus Indo y controles.

Corpus	Unigrama PPL	Bigrama PPL	Trigrama PPL	Bigrama bits/signo
Real	74.88	74.53	97.34	6.220
Permutado	74.88	129.61	153.18	7.018
Aleatorio (misma freq)	61.22	102.61	131.04	6.681

16.3.10. Clasificador supervisado de posición

El corpus Mayig incluye metadatos iconográficos en formato JSON para cada signo (damage, line, branching_factor, etc.). Entrenamos clasificadores Random Forest y Regresión Logística para predecir si un token aparece en posición de inicio, medio o fin, usando solo estos atributos visuales.

Cuadro 12: Resultados del clasificador de posición (5-fold cross-validation).

Modelo	Accuracy	Precisión macro	Recall macro
Random Forest	0.565	0.509	0.530
Regresión Logística	0.457	0.460	0.519
Línea base (azar)	0.333	0.333	0.333

Random Forest alcanza 56.5 % de accuracy, significativamente sobre el azar (33.3 %) pero modesto (Tabla 12). La precisión para “inicio” es 52.4 % (recall 55.3 %), mientras que para “fin” cae a 28.4 % (recall 43.3 %). Las features más importantes son la longitud del vector de features, su desviación estándar y su media — no valores iconográficos específicos.

Interpretación. Los metadatos iconográficos del corpus Mayig son demasiado genéricos para predecir función posicional. Esto no descarta que priors visuales más específicos (análisis de forma, simetría, complejidad de trazo) puedan correlacionar con posición, pero requerirían anotaciones más detalladas. La mejora de los embeddings “mejorados” (Tabla 8) proviene principalmente de la concatenación, no de la información predictiva aislada de las features.

16.4. Aplicación a Rongorongo

16.4.1. Situación del corpus

A diferencia del Indo, **no existe ninguna transcripción normalizada de Rongorongo disponible públicamente**. Realizamos una búsqueda exhaustiva en GitHub, Figshare, Zenodo, JSTOR y Google Scholar, identificando proyectos académicos activos (Lastilla, Ravanelli y Valério 2019–2022; Melka 2009; Harris & Melka 2011) que trabajan en corpus digitales, pero los datos requieren acceso institucional o contacto directo con los autores.

Por tanto, nuestro análisis de Rongorongo se basa exclusivamente en un **benchmark sintético** diseñado a partir de descripciones estructurales públicas (Ferrara 2015, Fischer 1997).

16.4.2. Benchmark Rongorongo-like

El corpus sintético incluye ~ 120 “glifos”, distribución Zipf fuerte, patrones de doble/triple repetición, líneas orientadas en “tablets”, alternancia de dirección (boustrophedon), y bigramas/trigramas explícitos. Genera 300 líneas (~ 4.500 tokens).

Cuadro 13: Controles negativos sobre corpus Rongorongo-like sintético.

Variante	r_{eff}	σ_1	$\sum \sigma_i$
Real	15.40	27.52	208.31
Permutado	15.07	28.93	184.05
Aleatorio (misma freq)	15.15	27.16	177.41
Aleatorio (uniforme)	14.00	27.84	128.16

El sanity check **falla** ($r_{\text{eff}}^{\text{real}} = 15.40 > r_{\text{eff}}^{\text{uniforme}} = 14.00$). Esto indica que, con parámetros estándar, el corpus Rongorongo-like no genera estructura espectral claramente comprimida.

Interpretación. Las posibles causas son: (i) líneas cortas (~ 15 tokens) con vocabulario grande (120 tipos) hacen que las co-ocurrencias sean ruidosas; (ii) el boustrophedon destruye patrones direccionales consistentes; (iii) las repeticiones dobles/triples introducen autocorrelación espuria.

Lección metodológica. Un sanity check que falla es **mejor** que uno que pasa por artefacto. El pipeline detecta honestamente cuando un corpus no tiene estructura clara bajo una métrica dada. Para Rongorongo real, esto sugiere que métodos basados puramente en co-ocurrencia local pueden ser insuficientes sin priors adicionales (iconográficos, posicionales, contextuales).

16.5. Embeddings de features estructurales

Dado que el sanity check espectral basado en co-ocurrencia ventanal falla para todos los corpus de inscripciones cortas, proponemos un enfoque complementario: embeddings construidos directamente a partir de *features estructurales* medibles, en lugar de co-ocurrencias estadísticas.

Definición 16.1 (Embedding estructural). *Para cada signo s en un vocabulario V , definimos el vector de features estructurales:*

$$\Phi(s) = (\log f(s), \mathbb{K}[f(s) = 1], \text{first_ratio}(s), \text{last_ratio}(s), \bar{p}(s), \sigma_p(s), \rho_{\text{rep}}(s), \bar{r}(s), H(\text{succ} \mid s), \text{rank}(s)) \quad (16.1)$$

donde $f(s)$ es la frecuencia, $\text{first_ratio}(s) = \frac{\#\{s \text{ aparece primero}\}}{f(s)}$, $\bar{p}(s)$ y $\sigma_p(s)$ son la media y desviación estándar de la posición normalizada, $\rho_{\text{rep}}(s)$ es la tasa de repeticiones consecutivas (AA) involucrando s , $\bar{r}(s)$ es la longitud media de carrera de repetición, y $H(\text{succ} \mid s)$ es la entropía condicional del sucesor de s .

A diferencia de los embeddings espectrales (donde el sanity check exige $r_{\text{eff}}^{\text{real}} < r_{\text{eff}}^{\text{uniforme}}$), los embeddings estructurales exhiben la relación **opuesta**:

Teorema 16.2 (Sanity check invertido para features estructurales). Sea $\Phi \in \mathbb{R}^{|V| \times 10}$ la matriz de features estructurales y $r_{\text{eff}}(\Phi)$ su rango efectivo. Entonces, para corpus con estructura secuencial genuina:

$$r_{\text{eff}}(\Phi_{\text{real}}) > r_{\text{eff}}(\Phi_{\text{perm}}) > r_{\text{eff}}(\Phi_{\text{unif}}) \quad (16.2)$$

Justificación. Los features estructurales capturan propiedades *emergentes* del orden secuencial: sesgo posicional, patrones de repetición, heterogeneidad de sucesores. Un texto real con estructura lingüística produce más diversidad en estos features (signos con distintos perfiles) que un texto permutado (donde las posiciones se uniformizan pero las frecuencias marginales se preservan), y mucho más que un texto uniforme (donde todos los signos tienen perfiles idénticos). La permutación destruye *toda* estructura secuencial pero preserva frecuencias; el muestreo uniforme elimina incluso la estructura marginal.

Cuadro 14: Rango efectivo de embeddings estructurales ($d = 10$) para tres corpora y sus controles. La dirección invertida ($r_{\text{eff}}^{\text{real}} > r_{\text{eff}}^{\text{perm}}$) confirma detección de estructura.

Corpus	$r_{\text{eff}}^{\text{real}}$	$r_{\text{eff}}^{\text{perm}}$	$r_{\text{eff}}^{\text{unif}}$
PCFG (sintético)	1.79	1.46	1.37
Indo real	3.96	3.72	2.43
Rongorongo real	3.58	3.34	1.95
RR collapsed	3.79	3.65	2.49

Resultado clave (Tabla 14). El sanity check invertido **pasa para los tres corpora**: PCFG ($1.79 > 1.46 > 1.37$), Indo ($3.96 > 3.72 > 2.43$), y Rongorongo ($3.58 > 3.34 > 1.95$). La versión “colapsada” de Rongorongo —donde repeticiones consecutivas se codifican como tokens compuestos (e.g., s_REP3)— muestra una separación aún más clara ($3.79 > 3.65 > 2.49$).

Interpretación. Los embeddings de features estructurales proporcionan un complemento necesario a los embeddings de co-ocurrencia. Donde la co-ocurrencia ventanal falla (vocabulario grande, secuencias cortas), las features estructurales detectan señal genuina. La colapsación de repeticiones mejora la señal en Rongorongo porque la alta tasa de repeticiones dobles/triples (66%/18%) infla artificialmente las co-ocurrencias de un signo consigo mismo, pero codifica información *adicional* cuando se trata como feature explícito.

16.6. GW multi-marginal y expansión a 17 lenguas candidatas

Extendemos la comparación multi-idioma de la Sección ?? incorporando 7 lenguas europeas de control (inglés, español, alemán, ruso, francés, italiano, portugués), todas extraídas de OPUS-Tatoeba (50k oraciones cada una), para un total de 17 lenguas candidatas.

Resultados GW multi-lateral. Aplicamos Gromov–Wasserstein (Sección ??) con regularización $\varepsilon = 0.5$ y 10 iteraciones, subsampling a 50 signos por lengua. La Tabla 15 muestra la distancia GW entre Rongorongo real y cada lengua candidata.

Cuadro 15: Distancia GW entre Rongorongo real y 17 lenguas candidatas ($\varepsilon = 0.5$, submuestreo 50 signos). La distancia se interpreta como distorsión relacional: menor = más similar la estructura interna.

Lengua	Familia	d_{GW}
Español	Romance	0.221
Italiano	Romance	0.257
Inglés	Germánico	0.274
Francés	Romance	0.430
Alemán	Germánico	0.431
Portugués	Romance	0.545
Ruso	Eslavo	0.698
Japonés	Japónico	0.865
Maorí	Polinésico	1.104
Samoano	Polinésico	1.443
Hawaiano	Polinésico	1.587
Coreano	Coreánico	1.709
Tahitiano	Polinésico	1.732
Fiyiano	Austronesio	1.745
Rapanui	Polinésico	1.775
Tongano	Polinésico	1.892
Árabe	Semítico	2.402

Interpretación. Los resultados muestran un ranking claro: las lenguas europeas de control con corpus grandes (español, italiano, inglés) tienen distancias GW *menores* que las lenguas polinésicas con corpus pequeños. Esto **no** es evidencia de parentesco genealógico entre Rongorongo y lenguas romances. Es un artefacto metodológico: (1) las lenguas con corpus grande producen embeddings más estables y representativos; (2) la distancia GW es sensible al tamaño del vocabulario y la calidad del embedding; (3) las lenguas con tipología SVO rígida (como español) tienen estructuras relacionales más densas y predecibles que lenguas polinésicas con vocabulario menor y variabilidad sintáctica mayor.

El resultado es metodológicamente valioso porque confirma que el pipeline de GW **detecta estructura relacional** donde existe, pero **no puede distinguir** similitud estructural de similitud genealógica sin anclas bilingües.

16.7. Features iconográficos del RR-corpus

El corpus RR-corpus (Sección ??) incluye transcripciones XML con paths SVG para cada glifo de las 6 tabletas disponibles. Extraemos 8 features iconográficos por glifo:

1. Ancho del bounding box (w)
2. Alto del bounding box (h)
3. Razón de aspecto (w/h)

4. Complejidad del path (número total de comandos SVG)
5. Número de movimientos (M/m)
6. Número de curvas Bézier ($C/c/S/s/Q/q/T/t/A/a$)
7. Número de segmentos de línea ($L/l/H/h/V/v$)
8. Número de coordenadas en el path

Independencia de features iconográficos y estructurales. Correlacionamos las 8 features iconográficos con las 10 features estructurales de la Definición 16.1. La máxima correlación absoluta observada es $|r| = 0.035$ (complejidad $\leftrightarrow \log f$), indicando que las features iconográficos contienen información *ortogonal* a la estructura secuencial.

Rango efectivo. Los features iconográficos solos producen $r_{\text{eff}} = 1.31$, dominado por una sola dimensión (tamaño del glifo). La combinación estructura + iconografía ($d = 18$) produce $r_{\text{eff}} = 1.33$, consistente con la ortogonalidad observada.

Implicación. Las features iconográficos no están correlacionados con el rol estructural de los signos. Esto significa que la forma visual de un glifo (complejidad, proporciones) no predice si aparece al inicio, al final, o si se repite. El desciframiento no puede reducirse a una correspondencia visual-funcional simple.

16.8. Síntesis comparativa




Figura 3: Comparación de rango efectivo entre corpus reales y controles. Verde = sanity check pasa; Rojo = sanity check falla.

La síntesis revela un patrón claro (Tabla 16, Figura 3):

1. El sanity check espectral **solo pasa** para el corpus PCFG, que tiene secuencias largas (8.1 tokens) y estructura sintáctica clara.

Cuadro 16: Resumen comparativo de métricas por corpus.

Métrica	PCFG	Rongorongo-like	Indo Real	Posicional Sintético
Vocabulario	112	120	182	60
Tokens totales	24.372	4.500	1.003	10.046
Longitud media	8.1	15.0	5.6	5.0
r_{eff} real	11.18	15.40	15.69	14.74
Sanity check	PASS	FAIL	FAIL	FAIL
Positional bias detectado	Sí (diseñado)	Débil	Fuerte	Fuerte
Entropía bigrama detecta	Sí	No testeado	Débil	No testeado

2. Para todos los corpus con vocabulario grande (>100 tipos) y secuencias cortas (<6 tokens), el sanity check falla.
3. **Sin embargo**, el análisis de sesgo posicional detecta estructura genuina tanto en el Indo real como en el benchmark posicional.
4. La entropía condicional de bigramas detecta estructura secuencial débil en el Indo real, donde la co-ocurrencia ventanal falla completamente.
5. El **test Monte Carlo** confirma que el sesgo posicional del Indo es estadísticamente extremo: P324 tiene efecto 16.1σ sobre la media nula ($p < 0.001$).
6. Los **modelos n-gram** muestran que el Indo real tiene bigrama perplexity 42 % menor que el permutado (74.5 vs 129.6), evidencia de dependencias secuenciales reales.
7. Los **patrones de repetición** en Indo son casi inexistentes (4.5 % double AA), consistente con un sistema lingüístico y claramente distinto de Rongorongo.
8. Los **embeddings de features estructurales** (Definición 16.1) pasan el sanity check invertido para los tres corpora (Teorema 16.2), proporcionando evidencia complementaria de estructura no aleatoria donde la co-ocurrencia ventanal falla.

Implicación metodológica. Para sistemas de inscripciones cortas (Indus, Rongorongo, Proto-Elamite), el análisis debe priorizar: (i) sesgo posicional, (ii) entropía condicional de bigramas, (iii) repeticiones de signos, (iv) embeddings de features estructurales (Teorema 16.2), y (v) priors iconográficos/contextuales. La co-ocurrencia ventanal tradicional es insuficiente en este régimen; los embeddings estructurales proporcionan un sanity check complementario que pasa para todos los corpora.

Implicación epistemológica. La estructura detectada (sesgo posicional, entropía condicional, perplexity) es *estructural*, no *semántica*. Sabemos que ciertos signos tienen posiciones preferidas; no sabemos qué significan. Esto es consistente con el teorema de no-desciframiento gratuito (Sección 7): sin anclajes externos, la estructura interna no identifica significado.

17. Consenso multi-idioma y reducción de fibras semánticas

17.1. Intuición: múltiples vistas de un mundo compartido

Hasta ahora hemos alineado un sistema perdido X con una única lengua candidata Y . Pero la hipótesis epistémica más fuerte es que existen múltiples lenguas $Y_1, \dots, Y_m$ que describen parcialmente un mismo espacio de conceptos R (mundos culturales, ecológicos, rituales o cognitivos compartidos). Cada lengua es una proyección parcial e imperfecta de R :

$$G_i : R \rightarrow \mathcal{M}_{Y_i}, \quad i = 1, \dots, m.$$

El sistema perdido X es otra proyección:

$$G_X : R \rightarrow \mathcal{M}_X.$$

Si las proyecciones G_i son parcialmente isomorfas (mismo mundo subyacente, distintas realizaciones léxicas), entonces la intersección de sus geometrías reduce la ambigüedad de la fibra semántica $F^{-1}(x)$.

17.2. Formalización del espacio consenso

Sea $\{E_{Y_i}\}_{i=1}^m$ un conjunto de embeddings espectrales de lenguas candidatas, cada uno de dimensión d_i . Definimos el *espacio consenso* R como la configuración media obtenida por Procrustes generalizado:

Definición 17.1 (Procrustes generalizado). *Dados embeddings centrados $\{E_i\}_{i=1}^m$ con $E_i \in \mathbb{R}^{n_i \times d}$, buscamos matrices ortogonales $Q_i \in O(d)$ y una configuración consenso $\bar{R} \in \mathbb{R}^{n_{\min} \times d}$ (donde $n_{\min} = \min_i n_i$) que minimicen*

$$\sum_{i=1}^m \left\| E_i^{(\min)} Q_i - \bar{R} \right\|_F^2, \quad (17.1)$$

donde $E_i^{(\min)}$ denota las primeras $n_{\min}$ filas de E_i .

Teorema 17.2 (Convergencia del consenso Procrustes). *El algoritmo iterativo que alterna (i) fijar $\bar{R}$ y resolver Procrustes ortogonal para cada Q_i , y (ii) actualizar $\bar{R}$ como la media de las configuraciones alineadas, converge monótonamente a un mínimo local del funcional anterior.*

Demostración. En cada paso, dado $\bar{R}$, la solución Procrustes para Q_i es globalmente óptima para ese término. Luego, dado $\{Q_i\}$, la media $\bar{R} = \frac{1}{m} \sum_i E_i^{(\min)} Q_i$ minimiza la suma de cuadrados por separabilidad. La función objetivo es acotada inferiormente por cero, luego la sucesión de valores converge. Como cada paso es óptimo condicional, la sucesión converge a un mínimo local (posiblemente no único). $\square$

17.3. Proyección del sistema perdido al consenso

Una vez construido R , proyectamos E_X al espacio consenso mediante una transformación regularizada:

$$W^* = \arg \min_{W \in \mathbb{R}^{d_X \times d_R}} \|E_X W - R\|_F^2 + \lambda \|W\|_F^2, \quad (17.2)$$

cuya solución es Tikhonov:

$$W^* = (E_X^\top E_X + \lambda I)^{-1} E_X^\top R. \quad (17.3)$$

El embedding del sistema perdido en el consenso es $E_X^{(R)} = E_X W^*$.

17.4. Teorema de reducción de fibra

Teorema 17.3 (Reducción de fibra por consenso multi-idioma). *Sea $\mathcal{F}_x = G_X^{-1}(x) \subseteq R$ la fibra semántica de un signo $x \in \mathcal{V}_X$. Sea Π_i el diccionario blando obtenido al alinear X con Y_i individualmente. Sea Π_{cons} el diccionario obtenido al alinear $E_X^{(R)}$ con el consenso R ponderado por las geometrías de $\{Y_i\}$. Entonces, bajo el supuesto de que las proyecciones G_i son condicionalmente independientes dado R , la entropía del diccionario consenso satisface:*

$$H(\Pi_{cons,x}) \leq \min_i H(\Pi_{i,x}) + \log m. \quad (17.4)$$

Bosquejo. Cada lengua candidata Y_i aporta una restricción sobre R . Bajo independencia condicional, la posterior conjunta sobre R dada todas las lenguas es más concentrada que cualquier posterior individual. Al proyectar X al espacio donde estas restricciones se intersectan, la distribución de candidatos para x se contrae. La cota $\log m$ surge de la granularidad del consenso: con m lenguas, la resolución del espacio consenso no puede exceder la información combinada de todas ellas. En la práctica, cuando las lenguas son redundantes (mismo mundo cultural), la reducción es mucho mayor que la cota teórica. $\square$

Corolario 17.4 (Suficiencia descriptiva multi-idioma). *Si m lenguas candidatas transportan información sobre R y sus geometrías son parcialmente isomorfas, entonces la identificabilidad parcial de X mejora monótonamente con m hasta alcanzar un régimen de saturación donde añadir más lenguas no reduce significativamente la entropía de las fibras.*

17.5. Alineamiento relacional multi-vista

Si las lenguas candidatas tienen dimensionalidades o tamaños muy distintos, Procrustes directo puede ser inadecuado. En ese caso, usamos Gromov–Wasserstein multi-vista: se construye una red de distorsiones relacionales entre todos los pares de lenguas y se busca un acoplamiento conjunto que minimice la discrepancia relacional total. Esto equivale a un problema de embedding multi-marginal donde cada lengua es un nodo y las aristas pesadas son las distorsiones GW.

18. Teoría de identificabilidad parcial

Definición 18.1 (Identificabilidad parcial). *Un símbolo x_i es parcialmente identificable respecto a una familia de candidatos $\mathcal{Y}_i \subseteq \mathcal{V}_Y$ si, para todo $y \notin \mathcal{Y}_i$,*

$$p(y \mid x_i, \mathcal{E}) < \max_{y' \in \mathcal{Y}_i} p(y' \mid x_i, \mathcal{E})$$

de manera estable bajo bootstrap, controles negativos y perturbaciones razonables.

Teorema 18.2 (Identificabilidad exacta bajo anclajes e isometría). *Suponga que existen embeddings $E_X, E_Y \in \mathbb{R}^{n \times d}$, una permutación P_0 y una matriz ortogonal Q_0 tales que*

$$E_Y = P_0 E_X Q_0.$$

Si se conoce un conjunto de anclajes que elimina toda simetría no trivial de P_0 , y E_X tiene rango columna completo sobre esos anclajes, entonces P_0 y Q_0 son identificables.

Demostración. Los anclajes fijan correspondencias de filas. Restringiendo a las filas ancladas A , se tiene

$$E_Y^A = E_X^A Q_0.$$

Por el corolario de Procrustes exacto, Q_0 es único si E_X^A tiene rango columna completo. Una vez fijado Q_0 , cada fila $E_X(i)Q_0$ se compara con las filas de E_Y . Si los anclajes eliminan simetrías no triviales, no existe otra permutación $P \neq P_0$ que preserve todas las relaciones y anclajes. Por tanto, P_0 queda identificado. $\square$

Corolario 18.3 (Régimen realista). *En sistemas perdidos reales, las condiciones exactas rara vez se cumplen. Por tanto, el objetivo científico razonable es identificabilidad parcial con incertidumbre calibrada, no equivalencia exacta símbolo-palabra.*

19. Relación con LLMs e inferencia moderna

19.1. LLMs como priors, no como oráculos

Un modelo de lenguaje puede aportar:

- (I) generación de hipótesis culturales;
- (II) expansión de vocabularios candidatos;
- (III) comparación semántica;
- (IV) explicación de patrones;
- (V) búsqueda de analogías.

Pero no debe usarse como autoridad final. En este marco, un LLM produce un prior:

$$p_{\text{LLM}}(y \mid x, \mathcal{K}),$$

que se combina con evidencia estadística:

$$p(y \mid x, \mathcal{E}) \propto p_{\text{stat}}(y \mid x) p_{\text{LLM}}(y \mid x, \mathcal{K})^\lambda.$$

Si λ es alto, el sistema puede alucinar. Si $\lambda = 0$, se pierde conocimiento externo útil. La calibración de λ debe hacerse con controles.

19.2. RAG para desciframiento

Un sistema RAG puede recuperar evidencia desde:

- (I) publicaciones arqueológicas;
- (II) diccionarios históricos;
- (III) gramáticas comparadas;
- (IV) corpus polinesios;
- (v) bases de iconografía;
- (VI) reportes paleográficos.

Toda hipótesis generada debe guardar trazabilidad documental. La forma correcta no es:

“el glifo significa X”,

sino:

“el glifo tiene candidatos $\{X_1, X_2, X_3\}$ con evidencia $\mathcal{E}$ y contraevidencia $\mathcal{E}^-$.”

20. Arquitectura computacional reproducible

20.1. Estructura de repositorio

```
spectral-submersion-decipherment/  
  README.md  
  pyproject.toml  
  data/  
    raw/  
    interim/  
    processed/  
  configs/  
    rongorongong.yaml  
    synthetic.yaml  
  src/  
    normalization/  
    cooccurrence/
```

spectral/
alignment/
transport/
decoding/
evaluation/
reporting/
notebooks/
tests/
reports/
figures/
tables/
hypotheses/

20.2. Componentes

- C1. Normalizer:** convierte imágenes, transcripciones o variantes a tokens normalizados.
- C2. ContextBuilder:** genera C_X , PMI, PPMI y tensores direccionales.
- C3. SpectralEngine:** calcula SVD, rango efectivo, embeddings y estabilidad.
- C4. AlignmentEngine:** ejecuta Procrustes, Moore–Penrose, GW y OT.
- C5. Decoder:** genera hipótesis símbolo-palabra y secuencia-secuencia.
- C6. Evaluator:** aplica controles negativos, bootstrap y métricas.
- C7. ReportGenerator:** produce reportes auditables.

21. Discusión

21.1. Qué puede demostrar el método

El método puede demostrar:

- (I) que un corpus tiene estructura no aleatoria;
- (II) que ciertos signos cumplen roles funcionales;
- (III) que ciertas segmentaciones son más estables que otras;
- (IV) que una lengua candidata explica mejor la estructura que controles;
- (V) que ciertos candidatos semánticos son más plausibles que otros;
- (VI) que algunas hipótesis deben descartarse.

21.2. Qué no puede demostrar solo

El método no puede demostrar por sí solo:

- (I) una traducción definitiva;
- (II) pronunciación;
- (III) correspondencia uno-a-uno entre glifos y palabras;
- (IV) intención cultural exacta;
- (V) historicidad de una lectura sin evidencia externa.

21.3. Belleza matemática del enfoque

La pseudoinversa aparece como una forma de humildad matemática: cuando una inversión exacta no existe, se elige la solución mínima compatible con la evidencia. La SVD aparece como instrumento de visión: separa direcciones dominantes de ruido. Procrustes aparece como respeto geométrico: no deforma arbitrariamente una lengua para que encaje con otra. La submersión aparece como metáfora formal: un sistema pequeño puede ser sombra de una semántica más rica, y cada signo puede corresponder a una fibra, no a un punto.

22. Conclusión

Este trabajo formula un marco matemático para el desciframiento probabilístico de sistemas simbólicos perdidos mediante geometría espectral. La propuesta parte de una intuición antigua, la frecuencia como huella estadística, y la eleva a una arquitectura moderna basada en SVD, Moore–Penrose, Procrustes, transporte óptimo, submersión de variedades e inferencia bayesiana.

La conclusión principal es doble. Primero, la estadística interna de un sistema simbólico puede revelar estructura significativa si el sistema codifica información no trivial. Segundo, esa estructura no basta para traducción fuerte sin anclajes externos. Por ello, el método propuesto no busca reemplazar a la filología, arqueología o lingüística histórica; busca entregarles una máquina rigurosa de hipótesis, falsación y ranking probabilístico.

En una frase:

descifrar no es invertir una matriz; es construir una inversa regularizada de la evidencia.

A. Apéndice A: derivación matricial del gradiente de mínimos cuadrados

Sea

$$f(W) = \|XW - Y\|_F^2.$$

Usando traza:

$$f(W) = \text{tr}((XW - Y)^\top (XW - Y)) \quad (\text{A.1})$$

$$= \text{tr}(W^\top X^\top XW) - 2 \text{tr}(W^\top X^\top Y) + \text{tr}(Y^\top Y). \quad (\text{A.2})$$

El gradiente es

$$\nabla_W f = 2X^\top XW - 2X^\top Y.$$

La ecuación normal es

$$X^\top XW = X^\top Y.$$

Si $X^\top X$ es invertible:

$$W = (X^\top X)^{-1} X^\top Y.$$

Si no es invertible, la solución de norma mínima es

$$W = X^+ Y.$$

B. Apéndice B: índice de anisotropía espectral

Definimos

$$A_k(M) = \frac{\sigma_1}{\frac{1}{k} \sum_{i=1}^k \sigma_i}.$$

Si A_k es alto, una dirección domina la estructura. En lenguaje, esto puede corresponder a:

- (I) frecuencia extrema de signos funcionales;
- (II) artefactos de segmentación;
- (III) direccionalidad mal normalizada;
- (IV) tema ritual repetitivo;
- (V) corpus demasiado pequeño.

C. Apéndice C: plantilla de reporte de hipótesis

Para cada signo x_i , el sistema debe producir:

```
glyph_id: x_i
frequency_rank: ...
spectral_coordinates: [...]
top_candidates:
  - candidate: y_1
    probability: 0.31
    evidence:
      - geometric_nearest_neighbor
      - compatible_frequency_class
```

```

    - supported_by_iconographic_prior
counterevidence:
    - unstable_under_bootstrap_window_3
- candidate: y_2
  probability: 0.22
uncertainty:
  entropy: ...
  bootstrap_variance: ...
decision:
  status: partial / unstable / rejected / strong_candidate

```

D. Apéndice D: glosario

Pseudoinversa	Generalización de la inversa para matrices rectangulares o singulares.
SVD	Factorización $A = U\Sigma V^\top$ que separa direcciones ortogonales y escalas.
Procrustes	Problema de encontrar la rotación/reflexión que mejor alinea dos nubes de puntos.
PMI	Medida de asociación entre dos eventos basada en cuánto supera su co-ocurrencia a la independencia.
Transporte óptimo	Marco para acoplar distribuciones minimizando costo.
Gromov–Wasserstein	Variante de transporte que compara estructuras relacionales internas.
Submersión	Mapa suave cuyo diferencial tiene rango máximo en el codominio.
Fibra	Conjunto de puntos que colapsan a un mismo valor bajo una aplicación.
Anclaje	Evidencia externa que rompe simetrías de permutación.

Referencias

- [1] L. D. Broemeling. An account of early statistical inference in Arab cryptology. *The American Statistician*, 65(4):255–257, 2011.
- [2] S. Ferrara, R. S. R. et al. The invention of writing on Rapa Nui (Easter Island). New radiocarbon dates on the Rongorongo script. *Scientific Reports*, 14, 2024.
- [3] E. H. Moore. On the reciprocal of the general algebraic matrix. *Bulletin of the American Mathematical Society*, 26:394–395, 1920.
- [4] R. Penrose. A generalized inverse for matrices. *Mathematical Proceedings of the Cambridge Philosophical Society*, 51(3):406–413, 1955.

- [5] G. H. Golub and C. F. Van Loan. *Matrix Computations*. Johns Hopkins University Press, 4th edition, 2013.
- [6] C. Eckart and G. Young. The approximation of one matrix by another of lower rank. *Psychometrika*, 1:211–218, 1936.
- [7] P. H. Schönemann. A generalized solution of the orthogonal Procrustes problem. *Psychometrika*, 31:1–10, 1966.
- [8] M. Artetxe, G. Labaka, and E. Agirre. Learning bilingual word embeddings with (almost) no bilingual data. In *Proceedings of ACL*, pages 451–462, 2017.
- [9] M. Artetxe, G. Labaka, and E. Agirre. Generalizing and improving bilingual word embedding mappings with a multi-step framework of linear transformations. In *Proceedings of AAAI*, 2018.
- [10] A. Conneau, G. Lample, M. Ranzato, L. Denoyer, and H. Jégou. Word translation without parallel data. In *International Conference on Learning Representations*, 2018.
- [11] G. Lample, A. Conneau, L. Denoyer, and M.-A. Ranzato. Unsupervised machine translation using monolingual corpora only. In *International Conference on Learning Representations*, 2018.
- [12] D. Alvarez-Melis and T. S. Jaakkola. Gromov-Wasserstein alignment of word embedding spaces. In *Proceedings of EMNLP*, pages 1881–1890, 2018.
- [13] G. Dinu, A. Lazaridou, and M. Baroni. Improving zero-shot learning by mitigating the hubness problem. In *ICLR Workshop*, 2015.
- [14] T. Mikolov, K. Chen, G. Corrado, and J. Dean. Efficient estimation of word representations in vector space. *arXiv:1301.3781*, 2013.
- [15] O. Levy and Y. Goldberg. Neural word embedding as implicit matrix factorization. In *Advances in Neural Information Processing Systems*, 2014.
- [16] G. Peyré and M. Cuturi. Computational optimal transport. *Foundations and Trends in Machine Learning*, 11(5–6):355–607, 2019.
- [17] C. Villani. *Optimal Transport: Old and New*. Springer, 2009.
- [18] J. M. Lee. *Introduction to Smooth Manifolds*. Springer, 2nd edition, 2013.
- [19] T. M. Cover and J. A. Thomas. *Elements of Information Theory*. Wiley, 2nd edition, 2006.